



南京大学

研究生毕业论文 (申请博士学位)

论文题目 最优间隔分布学习机

作者姓名 张腾

学科、专业方向 计算机科学与技术

研究方向 机器学习与数据挖掘

指导教师 周志华 教授

2019 年 2 月 20 日

学 号： **DG1233035**

论文答辩日期： **2019 年 2 月 26 日**

指 导 教 师： (签字)

Optimal Margin Distribution Machine

by

ZHANG Teng

Supervised by

Professor ZHOU Zhi-Hua

A dissertation submitted to
the graduate school of Nanjing University
in partial fulfilment of the requirements for the degree of
DOCTOR OF PHILOSOPHY
in
Computer Science and Technology



Department of Computer Science and Technology
Nanjing University

February 20, 2019

南京大学研究生毕业论文中文摘要首页用纸

毕业论文题目： 最优间隔分布学习机

计算机科学与技术 专业 2012 级博士生姓名： 张腾
指导教师（姓名、职称）： 周志华 教授

摘 要

统计学习中经典的大间隔方法以“最小间隔”为优化目标，而近期 Boosting 的研究表明优化最小间隔并不能保证良好的泛化性能，更为重要的概念是“间隔分布”，因此如何在常用框架下高效地优化间隔分布成为机器学习面临的一个新挑战。本文针对四种常见的机器学习任务，分别提出相应的显式优化间隔分布的方法，从而完整地建立起了这一新型统计学习范型，主要工作包括：

1. **二分类最优间隔分布学习机 ODM**。针对二分类问题，通过将任务形式化为最大化间隔均值同时最小化间隔方差来优化间隔分布，并提出一种基于对偶坐标下降的求解方法。实验结果表明 ODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的传统大间隔方法。
2. **多分类最优间隔分布学习机 mcODM**。针对多分类问题，通过将多类间隔定义为每类与“其他类”的二类间隔的最小值来优化间隔分布，并提出一种基于对偶块坐标下降的求解方法。实验结果表明 mcODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的多分类方法。
3. **聚类最优间隔分布学习机 ODMC**。针对聚类问题，通过寻找一个超平面使得在将簇标记指派给每个簇的同时得到最优间隔分布，并提出一种基于随机镜像下降的求解方法。实验结果表明 ODMC 的聚类性能显著优于、且在最坏情况下不差于优化最小间隔的聚类方法。
4. **半监督最优间隔分布学习机 ssODM**。针对半监督学习问题，通过寻找一个超平面使得在将类别标记指派给未标记样本的同时得到最优间隔分布，并提出一种基于随机镜像近端下降的求解方法。实验结果表明 ssODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的半监督学习方法。

关键词： 机器学习；数据挖掘；监督学习；无监督学习；半监督学习；最优间

隔分布学习；二分类；多分类；聚类；间隔；间隔分布

南京大学研究生毕业论文英文摘要首页用纸

THESIS: Optimal Margin Distribution Machine

SPECIALIZATION: Computer Science and Technology

POSTGRADUATE: ZHANG Teng

MENTOR: Professor ZHOU Zhi-Hua

Abstract

The classical large margin based methods in statistical learning try to maximize the *minimum margin*, however, recent theoretical studies on Boosting disclosed that maximizing the minimum margin does not necessarily lead to better generalization performances, and instead, the *margin distribution* is more crucial, so how to efficiently optimize the margin distribution turns to be a new challenge in machine learning. For four commonly encountered learning tasks, this paper proposes four methods respectively which can explicitly optimize the margin distribution, so as to completely set up this new statistical learning paradigm, including the following aspects,

1. **Binary optimal margin distribution machine, ODM.** For the binary classification problem, this paper tries to optimize the margin distribution by maximizing the margin mean and minimizing the margin variance simultaneously, and proposes a dual coordinate descent method to solve the final optimization problem. The empirical studies show that ODM is better and comparable at worst case than the minimum margin based binary classification methods.
2. **Multi-classification optimal margin distribution machine, mcODM.** For the multi-classification problem, this paper optimizes the margin distribution by defining the multi-class margin as the minimum of the binary margin between each class and all the other classes, and proposes a dual block coordinate descent method to solve the final optimization problem. The empirical studies show that mcODM is better and comparable at worst case than the minimum margin based multi-classification methods.
3. **Optimal margin distribution clustering, ODMC.** For the clustering problem, this paper tries to find a hyperplane, such that when labels are assigned to different

clusters according to this hyperplane it can also achieve optimal margin distribution, and proposes a stochastic mirror descent method to solve the final optimization problem. The empirical studies show that ODMC is better and comparable at worst case than the minimum margin based clustering methods.

4. **Semi-supervised optimal margin distribution machine, ssODM.** For the semi-supervised learning problem, this paper tries to find a hyperplane, such that when labels are assigned to each unlabeled instance according to this hyperplane it can also achieve optimal margin distribution, and proposes a stochastic mirror prox method to solve the final optimization problem. The empirical studies show that ssODM is better and comparable at worst case than the minimum margin based semi-supervised learning methods.

keywords: machine learning, data mining, supervised learning, unsupervised learning, semi-supervised learning, optimal margin distribution learning, binary classification, multi-class classification, clustering, margin, margin distribution

主要符号表

x	标量
$\boldsymbol{x}$	向量
$\boldsymbol{e}$	所有分量均为 1 的向量
$\boldsymbol{e}_i$	第 i 个分量为 1 其余分量为零的向量
$\mathbf{X}$	矩阵
$\mathbf{I}$	单位阵
$\mathbf{K}$	核矩阵
$\mathcal{X}$	特征空间
$\mathcal{Y}$	类别标记集合
$\mathcal{D}$	概率分布
D	数据集
$\mathcal{H}$	假设空间
$\mathfrak{L}$	学习算法
$[a]_+$	$= \max\{0, a\}$
$[k]$	集合 $\{1, \dots, k\}$, 其中 k 为正整数
$[\cdot, \cdot, \cdot]$	行向量
$[\cdot; \cdot; \cdot]$	列向量
$(\cdot)^\top$	向量或矩阵转置
$\{\dots\}$	集合
$ \{\dots\} $	集合 $\{\dots\}$ 中元素个数
$\ \cdot\ _p$	L_p 范数, p 缺省时为 L_2 范数
$\mathbb{P}(\cdot), \mathbb{P}(\cdot \cdot)$	概率函数, 条件概率函数
$\mathbb{E}_{\sim \mathcal{D}}[f(\cdot)]$	函数 $f(\cdot)$ 对 $\cdot$ 在分布 $\mathcal{D}$ 下的期望, 意义明确时简写为 $\mathbb{E}[f(\cdot)]$
$1_\cdot$	指示函数, 在 $\cdot$ 为真和假时分别取值为 1、0
$\text{sign}(\cdot)$	符号函数, 在 $\cdot < 0$ 、 $= 0$ 、 > 0 时分别取值为 -1、0、1

目 录

目 录	vii
1 绪论	1
1.1 引言	1
1.2 研究背景	3
1.3 有待研究的问题	17
1.4 本文工作	18
2 二分类最优间隔分布学习机	21
2.1 引言	21
2.2 问题形式化	23
2.3 优化算法	30
2.4 实验验证	36
2.5 小结	42
3 多分类最优间隔分布学习机	45
3.1 引言	45
3.2 问题形式化	48
3.3 优化算法	52
3.4 实验验证	59
3.5 小结	63
4 聚类最优间隔分布学习机	65
4.1 引言	65
4.2 问题形式化	68
4.3 优化算法	71
4.4 实验验证	77
4.5 小结	81

5	半监督最优间隔分布学习机	83
5.1	引言	83
5.2	问题形式化	86
5.3	优化算法	89
5.4	实验验证	94
5.5	小结	96
6	结束语	99
	参考文献	101
	致 谢	117
A	攻读博士学位期间的学术成果和获奖情况	119

第一章 绪论

1.1 引言

机器学习 (machine learning) 是支撑人工智能 (artificial intelligence) [160] 的核心技术, 一个广泛接受的定义是: “机器学习是研究如何通过计算的手段, 利用过往经验来改善系统自身性能的学科”[80,158]。在计算机系统中, “经验” 通常以 “数据” 的形式存在, 因此机器学习所研究的主要内容是从数据中产生 “模型” (model) 的学习算法。有了数据, 就能根据学习算法得到模型, 在面对未知情况时, 可以通过模型进行预测。

聚焦过去的数十年可以发现, 随着各行各业的数字化, 数据的生成途径越来越多; 随着互联网和计算机硬件的飞速发展, 获取数据、存储数据变得越来越便利。大量的数据汇集到一起, 超过了人类的处理能力, 机器学习顺理成章地变为计算机科学家研究和关注的焦点, 这也促进了人工智能的飞速发展。例如语音处理方面, 微软研究院的科学家在普通对话上取得了和人类媲美的语音识别能力, 错误率仅为 5.9% [128], IBM 的科学家则通过组合多个模型进一步将错误率降至 5.1% [95], 后来微软研究院的科学家在单个语音识别模型上也取得了同样的性能 [129]; 图像识别方面, AlexNet 在 ImageNet 大规模视觉识别挑战中将图像分类的 top-5 错误率降低到 15.3% [62], VGGNet 又将这个分类错误率进一步降至 7.3% [107], 后来微软研究院和谷歌的科学家又分别独立取得了 3.5% 的错误率 [41,49], 已经远超人类的平均水平。人机对弈方面, DeepMind 开发的人工智能围棋程序 AlphaGo 以 4:1 的大比分战胜世界冠军李世石 [105], 第二年 AlphaGo 又以 Master 的名字卷土重来, 完胜当时世界排名第一的中国棋手柯洁 [106]。自动驾驶方面, 从互联网公司、芯片制造商到传统汽车企业, 都纷纷开始布局, 谷歌、百度、英特尔先后宣布了自己的战略规划 [40], 并在一定范围内实现了路测; 医疗诊断方面, 机器学习模型在皮肤癌的检测上达到了专业医师的水平 [28], 对糖尿病眼盲症的自动诊断已经被引入临床。去年 7 月 8 日, 国务院印发了《新一代人工智能发展规划》, 将人工智能研究提升到国家战略高度, 要求有前瞻性地布局高级机器学习。毋庸置疑, 人工智能的时代来了, 作

为其重要支撑的机器学习技术将会取得更为广泛的应用。

机器学习的历史最早可以追溯到上世纪五十年代关于图灵测试的文章，之后经过几十年的发展，不同研究背景的科学家陆续加入进来，形成了许多流派。例如五十年代中后期出现的基于神经网络的“连接主义”（connectionism）学习，该类方法的最大局限是缺乏严格的理论指导，全靠手工“调参”；还有六七十年代出现的基于逻辑表示的“符号主义”（symbolism）学习，该类方法因模型的表示能力太强致使假设空间过大，问题规模稍大就难以进行有效地学习^[156]。进入九十年代中期后，针对这两类方法的研究相继退潮，而同一时间“统计学习”（statistical learning）开始声名鹊起，其代表性方法就是支持向量机（Support Vector Machine，简称 SVM）^[18]以及更一般性的核方法（kernel method）^[22,98]。由于统计学习技术直接以统计学习理论^[120-122]作为支撑，因此不存在连接主义学习那样的缺陷；此外，统计学习最终形式化出的问题是个凸二次规划（Quadratic Programming，简称 QP），这在优化领域早就有成熟的方法进行求解，所以也没有符号主义学习那样的尴尬。加上 SVM 在文本分类中表现出的优越性能，统计学习很快一统江山，占据了机器学习的主流舞台。

统计学习理论表明泛化风险（generalization risk）的上界，简称泛化界（generalization bound），由两部分组成，一是分类器在数据集上的经验风险（empirical risk），二是学习算法采用的假设空间（hypothesis space）的大小。经验风险最小化（empirical risk minimization）原则指出，我们应该不惜一切代价最小化经验风险，这在数据集很大而假设空间不大时，没有问题，因为此时第二部分的值很小，经验风险就是对泛化风险很好的近似；但在数据集不大而假设空间很大时，经验风险最小化就没有意义了，因为此时泛化风险上界中起主导作用的是第二部分。因此，统计学习技术采用结构风险最小化（structural risk minimization）原则，即直接最小化这个上界，同时考虑经验风险和假设空间的大小，期望在两者之间取得一个平衡，从而使得泛化风险最小。

假设空间的大小可以通过 VC 维来刻画，这个量能够准确体现出假设空间对数据的拟合能力，因此根据结构风险最小化原则，只需设计一个同时控制经验风险和 VC 维的算法就行了。但不幸的是，对于大多数假设空间而言，VC 维都无法直接计算，但好在可以引入有一个叫间隔（margin）的参数，它数据相关（data dependent），很好计算，且间隔越大，VC 维越小。因此可以考虑最小化经验风险同时最大化间隔，这就是所谓的“最大间隔准则”（large margin principle）。若选定假设空间为线性判别式模型构成的集合，间隔为划

分超平面到样本集的最近距离，即所有间隔中的最小者，则可导出经典的大间隔方法。

另一方面，在关于集成学习^[3,23,146]的代表性方法 AdaBoost 的理论研究中，间隔也扮演着非常重要的角色。近期有研究表明，以最小间隔为优化目标并不能保证良好的泛化性能，更为重要的是间隔分布。因此如何在常用框架下高效地优化间隔分布成为机器学习面临的一个新挑战。本文针对四种常见的机器学习任务，分别提出相应的显式优化间隔分布的方法，从而完整地建立起了这一新型统计学习范型。

本章后续内容中首先简要介绍研究背景，然后给出一些有待研究的问题，最后介绍论文的组织。

1.2 研究背景

本节先介绍常用的符号约定和基本术语，然后分别对 PAC 学习框架、VC 维理论、最大间隔准则、AdaBoost 的间隔理论做简要回顾。

记 $\mathcal{X}$ 为特征空间（feature space）， $\mathcal{Y}$ 为类别标记集合（label set）， $\mathcal{D}$ 是定义在 $\mathcal{X} \times \mathcal{Y}$ 上的未知分布，训练数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\} \in (\mathcal{X} \times \mathcal{Y})^m$ 独立同分布（i.i.d.）地采样于分布 $\mathcal{D}$ ， $\mathcal{H} = \{f : \mathcal{X} \mapsto \mathcal{Y}\}$ 是候选分类器构成的假设空间。机器学习的目标就是从 $\mathcal{H}$ 中寻找一个分类器 h ，使得泛化风险

$$R(h) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}}[1_{h(\mathbf{x}) \neq y}] \quad (1.1)$$

尽可能的小，其中 $1_{\cdot}$ 是指示函数（indicator function），当下标中的表达式成立时取值 1，否则取值 0。

1.2.1 PAC 学习框架

由于学习算法无法得到真实分布 $\mathcal{D}$ ，因此泛化风险根本无从计算，事实上如果有了真实分布也就不需要学习了。能够计算的仅仅是经验风险，即分类器 h 在训练数据集 D 上的误差：

$$R_D(h) = \frac{1}{m} \sum_{i=1}^m 1_{h(\mathbf{x}_i) \neq y_i} \quad (1.2)$$

对于学习算法来说，训练数据集是真实分布的一个缩影，因此通过最小化经验风险来寻找一个对真实分布的刻画也是合情合理的，这就是经验风险最小化原则。

尽管经验风险最小化看起来顺理成章，但它并不能保证在任何时候学习算法都能输出一个有意义的结果。事实上，如果我们对假设空间不做任何限制，那么根据经验风险最小化原则可能会得到一个强行“记住”每个训练样本类别标记的分类器，显然它在训练数据集上经验风险为零，比任何一个分类器都要好，但是它对未知样本的预测可能非常糟糕，因为它把全部注意力都集中在训练数据集上了，忽略了对真实世界的认知，这种现象称为“过拟合”（overfitting）。

过拟合显然是学习失败了，失败的根源在于没有对假设空间做限制。那么接下来一个重要的问题就是：我们应该选择什么样的受限假设空间？或者说选择什么样的假设空间可以保证学习过程的成功呢？在此之前需要先引入概率近似正确（Probably Approximately Correct，简称 PAC）的概念。

定义 1.1 (PAC 可学习^[118]) 对任意 $\epsilon, \delta \in (0, 1)$ 和未知分布 $\mathcal{D}$ ，设 m 是从 $\mathcal{D}$ 中独立同分布地采样出的训练样本数。若存在学习算法 $\mathcal{L}$ 和多项式函数 $\text{poly}(\cdot, \cdot)$ ，只要 $m \geq \text{poly}(1/\epsilon, 1/\delta)$ ， $\mathcal{L}$ 就能从假设空间 $\mathcal{H}$ 中输出的分类器 $h \in \mathcal{H}$ 使得

$$R(h) \leq \min_{h' \in \mathcal{H}} R(h') + \epsilon \quad (1.3)$$

至少以 $1 - \delta$ 的概率成立，则称假设空间 $\mathcal{H}$ 是 PAC 可学习的（learnable），后文在不引起混淆的情况下简称为可学习。满足所需的 $m \geq \text{poly}(1/\epsilon, 1/\delta)$ 中最小的 m 称为样本复杂度（sample complexity）。

简言之，假设空间中有一个泛化风险最小的分类器 h' ，如果学习算法能够以较大概率（ $1 - \delta$ 的置信度）输出一个近似正确（与最优分类器 h' 的泛化风险之差不超过 ϵ ）的分类器，就算学习成功了。

那么回到前面受限假设空间选择的问题，要想不出现过拟合，就要保证经验风险确实是泛化风险一个很好的近似。此外学习算法最终输出假设空间中的哪个分类器还依赖于具体的训练数据集。两相结合，这要求假设空间中任一候选分类器的经验风险和泛化风险之差都不能太大，这称为一致收敛性（uniform convergence）。

假设对任意 $h \in \mathcal{H}$ ，其在训练数据集 D 上的经验风险与泛化风险之差不超

过 $\epsilon/2$, 即 $|R_D(h) - R(h)| \leq \epsilon/2$, 记 $h_D = \arg \min_{h \in \mathcal{H}} R_D(h)$ 为经验风险最小化输出的分类器, 则

$$R(h_D) \leq R_D(h_D) + \frac{\epsilon}{2} \leq R_D(h) + \frac{\epsilon}{2} \leq R(h) + \frac{\epsilon}{2} + \frac{\epsilon}{2} = R(h) + \epsilon \quad (1.4)$$

对任意 h 成立, 其中第一个、第三个不等号是根据一致收敛性的定义, 第二个不等号是因为 h_D 是使得经验风险最小化的分类器。特别地取 $h = \arg \min_{h' \in \mathcal{H}} R(h')$ 可知式 (1.3) 成立, 即一致收敛的假设空间是可学习的。

那什么样的假设空间是一致收敛的呢? 借助 Hoeffding 不等式^[43] 可以证明:

定理 1.1 当 $|\mathcal{H}| < \infty$, 即假设空间为有限集合时, 对任意 $\delta \in (0, 1)$, $h \in \mathcal{H}$, 以及独立同分布地采样于未知分布 $\mathcal{D}$ 的 m 个训练样本组成的数据集 D ,

$$R(h) \leq R_D(h) + \sqrt{\frac{\ln |\mathcal{H}| + \ln(2/\delta)}{2m}} \quad (1.5)$$

至少以 $1 - \delta$ 的概率成立。

定理 1.1 表明当假设空间 $\mathcal{H}$ 有限时, 可以保证一致收敛性, 从而假设空间是可学习的。

至此我们知道了不做任何限制的假设空间是不可学习的, 而有限的假设空间是可学习的。那么我们不禁要问: 可学习的界限在哪里? 它与假设空间自身的什么性质有关? VC 维理论正是为回答这个问题而提出的。

1.2.2 VC 维理论

定理 1.1 表明假设空间 $\mathcal{H}$ 有限是可学习的充分条件, 注意泛化界中右边第二项有 $\ln |\mathcal{H}|$, 很容易让人猜测这也是个必要条件, 因为当假设空间无限时, 泛化风险无上界, 从而不可学习。但通过一个简单的反例就可以知道这个猜想是不对的, 存在无限假设空间是可学习的。

例 1.1 (可学习的无限假设空间^[100]) 考虑特征空间 $X = \mathbb{R}$ 上的二分类问题, $\mathcal{Y} = \{0, 1\}$, 令假设空间 $\mathcal{H} = \{h_a : a \in \mathbb{R}\}$ 为 $\mathbb{R}$ 上所有阈值函数构成的集合, 其中 $h_a(x) = 1_{x < a}$, 那么 $\mathcal{H}$ 是可学习的, 此时样本复杂度为 $m(\epsilon, \delta) = \ln(2/\delta)/\epsilon$ 。

例 1.1 说明假设空间的大小并不是对假设空间可学习性的本质刻画，为了得到能准确描述假设空间可学习性的度量，我们先来看下“没有免费的午餐”（No Free Lunch，简称 NFL）定理，这个定理陈述的是：如果对假设空间不做任何限制，则对于任何一个学习算法，都存在一个任务使其失败，但同时也有另一个学习算法在该任务上表现很好。

定理 1.2 (NFL 定理^[100]) 考虑特征空间 X 上的二分类问题， $\mathcal{Y} = \{0, 1\}$ ，设 $\mathcal{Q}$ 为任意学习算法，数据集大小为 m 且 $m < |X|/2$ ，则在 $X \times \{0, 1\}$ 上存在一个分布 $\mathcal{D}$ 使得：

1. 存在一个完美的分类器 $f: X \mapsto \{0, 1\}$ 满足 $R_{\mathcal{D}}(f) = 0$ ，即泛化风险为零；
2. 设 D_m 是独立同分布地采样于 $\mathcal{D}$ 的数据集，则 $R_{\mathcal{D}}(A(D_m)) \geq 1/8$ 至少以 $1/7$ 的概率成立。

该定理的证明并不复杂，对任一大小为 $2m$ 的数据集 $D_{2m} \subseteq X$ ，假设存在 2^{2m} 个 $D_{2m} \mapsto \{0, 1\}$ 的分类器 $f_1, \dots, f_{2^{2m}}$ ，其中任两个分类器都至少在一个样本的预测上不一致。

考虑定义在 $D_{2m} \times \{0, 1\}$ 上的 2^{2m} 个离散分布：

$$\mathcal{D}_i = (\{\mathbf{x}, y\}) = \begin{cases} 1/2m & y = f(\mathbf{x}) \\ 0 & \text{其它} \end{cases} \quad (1.6)$$

则对于每个 f_i 都有 $R_{\mathcal{D}_i}(f_i) = 0$ ，即每个分布上都有个分类器泛化风险为零，于是定理 1.2 中的第 1 点成立。

现在任取一个分布 $\mathcal{D}_i$ ，并从中独立同分布地采样出 m 个样本作为训练数据集 S_m ，则 $f_1, \dots, f_{2^{2m}}$ 中有 2^m 个在 S_m 上经验风险为零，且对剩余的 m 个样本的预测各不相同，其中泛化风险最小的为零，即 f_i ；泛化风险最大的为 $1/2$ ，即全部预测错。由于学习算法无法甄别它们，所以只能从中随机挑一个分类器作为最终输出，因此期望泛化风险为 $1/4$ ，根据马尔可夫不等式可知定理 1.2 中的第 2 点成立。

从 NFL 定理的证明可以看出，我们根本用不到假设空间的大小 $|\mathcal{H}|$ ，真正起作用的是假设空间对数据集能赋予的类别标记的可能结果数。当假设空间可以对任意 $2m$ 个样本实现全部 2^{2m} 种不同的类别标记指派时就会出现这个问题，这就引出了如下定义：

定义 1.2 (对分和打散^[158]) 设假设空间 $\mathcal{H} = \{h : X \mapsto \{0, 1\}\}$, 数据集 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subseteq X$, 定义集合

$$H_D = \{(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m)) \mid h \in \mathcal{H}\} \quad (1.7)$$

其中 H_D 中每个元素都是对 D 赋予类别标记的一个可能结果, 称之为“对分”(dichotomy)。

进一步若 $|H_D| = 2^m$, 即 H_D 包含了全部可能的对分结果, 则称假设空间 $\mathcal{H}$ 可以“打散”(shatter) 数据集 D 。

于是 NFL 定理陈述了这样一个事实: 如果假设空间 $\mathcal{H}$ 打散了大小为 $2m$ 的数据集, 则我们无法通过 m 个样本来进行有效学习。换言之, 如果一个数据集 D 被 $\mathcal{H}$ 打散, 而我们只能得到 D 中一半样本构成的集合, 那么这些样本的类别标记对于我们预测 D 中剩下的一半样本毫无帮助, 因为这些样本每一种可能的类别标记组合, 在 $\mathcal{H}$ 中都有一个经验风险为零的分类器与之对应。

基于上述事实, 我们可以定义 VC 维:

定义 1.3 (VC 维^[121]) 假设空间 $\mathcal{H}$ 的 VC 维是能被 $\mathcal{H}$ 打散的最大数据集的大小, 即

$$\text{VC}(\mathcal{H}) = \max\{m \mid \exists D : |H_D| = 2^m\} \quad (1.8)$$

若 $\mathcal{H}$ 可以打散任意大的集合, 则称 $\mathcal{H}$ 的 VC 维无穷。

根据定义, 若存在大小为 d 的数据集能被 $\mathcal{H}$ 打散, 但不存在任何大小为 $d+1$ 的数据集能被 $\mathcal{H}$ 打散, 则称假设空间 $\mathcal{H}$ 的 VC 维是 d 。但一般来说, 假设空间的 VC 维很难通过这种方式计算, 只有某些特殊的假设空间才可以, 如例 1.2 所示。

例 1.2 (二维实平面上直线集合的 VC 维^[158]) 设特征空间 $X = \mathbb{R}^2$, 假设空间为二维平面上直线构成的集合, 如图 1.1 所示, 存在 3 个样本构成的集合, 在 $2^3 = 8$ 种可能的类别标记赋值下均是线性可分的, 但对于任意 4 个样本构成的集合, 总有一种类别标记赋值线性不可分, 因此二维实平面上直线集合的 VC 维是 3。事实上有更一般的结论, n 维欧氏空间 $\mathbb{R}^n$ 中超平面集合的 VC 维是 $n+1$ 。




图 1.1: 二维实平面上, 存在 3 个样本构成的集合, 在 8 种可能的类别标记赋值下均是线性可分的, 但对于任意 4 个样本构成的集合, 总有一种类别标记赋值线性不可分, 因此二维实平面上直线集合的 VC 维是 3

若 $\mathcal{H}$ 有无穷的 VC 维, 则对于任意大小为 m 的训练数据集, 总存在一个大小为 $2m$ 且被 $\mathcal{H}$ 打散的集合, 因此由 NFL 定理可知此时 $\mathcal{H}$ 不是可学习的。反过来, 若 $\mathcal{H}$ 的 VC 维有限, 则 $\mathcal{H}$ 是可学习的, 事实上, VC 维有限的假设空间是一致收敛的, 这可从如下的泛化界^[121] 得到:

定理 1.3 若假设空间 $|\mathcal{H}|$ 的 VC 维为 d , 则对任意 $\delta \in (0, 1)$, $m > d$, $h \in \mathcal{H}$, 以及独立同分布地采样于未知分布 $\mathcal{D}$ 的 m 个训练样本组成的数据集 D ,

$$R(h) \leq R_D(h) + \sqrt{\frac{8d \ln(2em/d) + 8 \ln(4/\delta)}{m}} \quad (1.9)$$

至少以 $1 - \delta$ 的概率成立。

式 (1.9) 右端第二项称为置信区间 (confidence interval), 易知它是关于 m/d 的单调减函数, 且当 $m/d \rightarrow \infty$ 时趋于零, 因此当 m/d 很大时, 置信区间的值不大, 此时第一项经验风险起主导作用, 这也是经验风险最小化原则在大数据集上表现不错的原因。但反过来, 当 m/d 较小时, 则必须考虑置信区间的影响, 因为此时最小化经验风险并不能保证泛化风险也小。

经验风险和置信区间的关系如图 1.2 所示, 它们是有冲突的, 当采用 VC 维大的假设空间时, 经验风险会比较小, 但是置信区间会很大; 反过来, 如果采用 VC 维较小的假设空间, 则经验风险会变大, 但是置信区间会相应地变小。因此为了使得泛化界较紧, 我们应该在两者之间取得一个平衡, 这就是结构风险最小化原则:

给定训练数据集 D , 构造长为 N 的嵌套假设空间序列:

$$\mathcal{H}_1 \subseteq \cdots \subseteq \mathcal{H}_t \subseteq \cdots \subseteq \mathcal{H}_N \quad (1.10)$$




图 1.2: 经验风险和置信区间是有冲突的, 随着 VC 维的增大, 经验风险单调减小, 置信区间单调增加, 两相结合, 泛化界先减后增, 在某个适当的假设空间 $\mathcal{H}^*$ 处达到最紧^[121]

对于每个 t , 在 $\mathcal{H}_t$ 中求解一个使得经验风险最小的分类器 h_t , 于是有序列

$$R_D(h_1) \geq \cdots \geq R_D(h_t) \geq \cdots \geq R_D(h_N) \quad (1.11)$$

同时有 VC 维序列

$$\text{VC}(\mathcal{H}_1) \leq \cdots \leq \text{VC}(\mathcal{H}_t) \leq \cdots \leq \text{VC}(\mathcal{H}_N) \quad (1.12)$$

代入式 (1.9) 中可以算得相应的置信区间的值, 最终取使得经验风险与置信区间的和最小的 t , 并以 h_t 作为学习算法最终输出的分类器。

1.2.3 最大间隔准则

要想将结构风险最小化原则转变成一个切实可行的学习算法, 首先要有一个方便的计算假设空间 VC 维的方式, 然而对于一般的假设空间, VC 维都没有显式的表达式。此外, 如果特征空间是无穷维空间, 假设空间采用超平面构成的集合, 根据定理 1.3 和例 1.2 的结论知训练集样本数也要无穷才行, 这是不可能的, 那么此时该如何进行学习呢?

注意 VC 维导出的泛化界是分布无关、数据独立的, 对任何分布都成立, 换言之它考虑的是最坏情况, 因此不可避免地有点“松”, 一个缓解此问题的办法是引入数据相关的量加强泛化界, 从而即便在无穷维空间也可以学习。

定义 1.4 (间隔和宽打散维^[22]) 设 $\mathcal{F} = \{f : \mathcal{X} \mapsto \mathbb{R}\}$ 是定义在特征空间 $\mathcal{X}$ 上阈值为零的实值函数集合, 考虑用其来分类, 对于任意 $f \in \mathcal{F}$, 其关于样本 $(\mathbf{x}_i, y_i)$ 的间隔定义为

$$\gamma_i = y_i f(\mathbf{x}_i) \quad (1.13)$$

对于二分类数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\} \in (\mathcal{X} \times \{+1, -1\})^m$, 若存在 $f \in \mathcal{F}$ 和 $\gamma > 0$ 使得

$$f(\mathbf{x}_i) \begin{cases} \geq \gamma & \text{如果 } y_i = 1 \\ \leq -\gamma & \text{如果 } y_i = -1 \end{cases} \quad (1.14)$$

则称数据集 D 被 $\mathcal{F}$ 以 γ 打散, $\mathcal{F}$ 的尺度为 γ 的宽打散维 $\text{fat}_{\mathcal{F}}(\gamma)$ (fat-shattering dimension) 是能被 $\mathcal{F}$ 以 γ 打散的最大集合的大小。

宽打散维又叫做尺度敏感 VC 维 (scale-sensitive VC dimension), 某种意义上它可以看做对 VC 维的加强, 事实上, 可以证明与式 (1.9) 形式相似但只依赖于宽打散维的泛化界, 对于前文所说的 VC 维为无穷的情形也可以进行有效学习, 此时宽打散维是有限的。

以 γ 打散意味着存在实值函数使得所有样本间隔不小于 γ , 显然 γ 越大, 对函数集合的限制越严格, $\mathcal{F}$ 能以 γ 打散的数据集规模越小, 因此可以通过间隔来控制假设空间的大小, 这就得到了所谓的“最大间隔准则”, 即最小化经验风险同时最大化间隔。

特别地, 若取 $\mathcal{F}$ 为线性实值函数 $f(\mathbf{x}_i) = \mathbf{w}^\top \mathbf{x}_i$ 构成的集合, 划分超平面

$$\mathbf{w}^\top \mathbf{x} = 0, \quad \|\mathbf{w}\| = 1 \quad (1.15)$$

对任意 $(\mathbf{x}_i, y_i) \in D$ 有

$$\mathbf{w}^\top \mathbf{x}_i \begin{cases} \geq \gamma & \text{如果 } y_i = 1 \\ \leq -\gamma & \text{如果 } y_i = -1 \end{cases} \quad (1.16)$$

则称其为 γ -间隔划分超平面。

γ -间隔划分超平面意味着 γ 是所有样本间隔中的最小值, 亦称最小间隔, 下面这个定理^[22] 给出了 γ -间隔划分超平面的宽打散维与最小间隔之间的关系:

定理 1.4 若数据集 $D \subseteq \mathcal{X}$ 属于一个半径为 R 的球，则 γ -间隔划分超平面构成的假设空间 $\mathcal{H} = \{x \mapsto \mathbf{w}^\top x \mid \|\mathbf{w}\| = 1, x \in \mathcal{X}\}$ 的宽打散维有如下上界：

$$\text{fat}_{\mathcal{H}}(\gamma) \leq \frac{R^2}{\gamma^2} \quad (1.17)$$

定理 1.4 表明当我们采用 γ -间隔划分超平面构成的集合作为假设空间时，结构风险最小化原则对应于最小化经验风险同时最大化最小间隔，由此导出的学习算法就是 SVM：

$$\max_{\mathbf{w}} \quad \gamma \quad (1.18)$$

$$\text{s.t.} \quad y_i \mathbf{w}^\top \mathbf{x}_i \geq \gamma, \forall i \in [m] \quad (1.19)$$

$$\|\mathbf{w}\| = 1 \quad (1.20)$$

由于式 (1.16) 要求两类样本在特征空间中是线性可分 (linear separable) 的，因此经验风险为零，所以此时目标函数只剩一项：最大化最小间隔。注意 γ 的取值对优化问题没有影响且最大化 $1/\|\mathbf{w}\|$ 等价于最小化 $\|\mathbf{w}\|^2$ ，因此上述形式化可以等价地写成如下常见的形式：

$$\min_{\mathbf{w}} \quad \frac{1}{2} \|\mathbf{w}\|^2 \quad (1.21)$$

$$\text{s.t.} \quad y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1, \forall i \in [m] \quad (1.22)$$

现实世界中的问题往往很复杂，不是靠简单的线性超平面就可以解决的，例如 $\mathbb{R}^2$ 上的“异或”问题就不是线性可分的，此时需要有比线性模型表示能力更强的非线性模型。一个常用的解决途径是核方法 (kernel method)，即引入某个正定核 (positive definite kernel) 函数 $\kappa(\cdot, \cdot)$ 及其诱导的特征映射 (feature mapping) $\phi(\cdot) : \mathcal{X} \mapsto \mathbb{H}$ ，其中 $\mathbb{H}$ 为希尔伯特再生核空间 (Reproducing Kernel Hilbert Space, 简称 RKHS) 且 $\kappa(\mathbf{x}_1, \mathbf{x}_2) = \phi(\mathbf{x}_1)^\top \phi(\mathbf{x}_2)$ 。有了特征映射后，先将样本从原特征空间映射到一个新的特征空间，然后在新的特征空间里按最大间隔准则寻找一个超平面将映射后的两类样本分开，再将超平面映射回原特征空间，就得到了一个将两类样本正确分类的非线性模型。有理论保证，如果原特征空间是有限维的，即特征个数有限，那么一定存在一个正定核函数，在其对应的高维特征空间里，映射后的样本是线性可分的。

遗憾的是，至此问题还没有得到完全解决，因为核函数的选择本身就是一

个很难的问题。给定一个数据集，我们无法事先知道什么样的核函数能满足我们的要求，换言之，不存在一个通用的核函数适用于任何数据集。即便找到某个核函数使大部分数据集在高维特征空间都线性可分，也很难断定这是否是因核的表示能力太强而带来的过拟合。既然无法确保高维特征空间中的两类样本一定线性可分，只好退而求其次，要求约束 $y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1$ 对大部分样本成立：

$$\min_{\mathbf{w}} \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m 1_{y_i \mathbf{w}^\top \phi(\mathbf{x}_i) - 1} \quad (1.23)$$

其中第二项为不满足约束的样本个数，参数 λ 用来权衡两项的重要性。

由于指示函数非凸、非连续，导致优化问题 (1.23) 不太好求解。此时通常用一些数学性质较好的函数来替代指示函数，称为“替代损失”（surrogate loss），一般为凸连续函数且为指示函数的上界。特别地，如果取

- hinge 损失函数 $[1 - z]_+$ ，就得到了“软间隔”（soft-margin）SVM，相对应的，前面要求两类样本线性可分的叫“硬间隔”（hard-margin）SVM；
- 对率损失（logistic loss）函数 $\ln(1 + \exp(-z))$ ，就得到了对数几率回归（logistic regression）^[45,79]；
- 平方损失（square loss）函数 $(y - z)^2$ ，就得到了岭回归（ridge regression）^[44,75]；
- ϵ -不敏感损失（ ϵ -insensitive loss）函数 $[|z| - \epsilon]_+$ ，就得到了支持向量回归（support vector regression）^[26,109]。

注意目标函数中的第一项 $\|\mathbf{w}\|^2/2$ 是根据最大间隔准则得到的，某种程度上它体现了我们对假设空间的先验知识，所以从这个角度来说，可以考虑更一般的“正则化”（regularization）问题：

$$\min_f \quad \Omega(f) + \frac{\lambda}{m} \sum_{i=1}^m l(f(\mathbf{x}_i), y_i) \quad (1.24)$$

其中 $\Omega(f)$ 为正则化项。最常用的正则化项就是 l_p -范数，如果固定替代损失为平方损失，将前面的 l_2 -范数替换成

- l_1 -范数，就得到了 LASSO^[36,114]；
- l_1 -范数、 l_2 -范数的线性组合，就得到了弹性网（elastic net）^[155]；
- l_1 -范数、 l_∞ -范数的线性组合，就得到了 OSCAR^[9]。
- $l_{2,1}$ -范数，就得到了 Group LASSO^[50,78]；
- $l_{1,2}$ -范数，就得到了 Exclusive LASSO^[61,145]；

其中 l_2 -范数倾向于使得 $\mathbf{w}$ 的非零分量个数较多，而 l_1 -范数则会使得 $\mathbf{w}$ 变稀疏， l_∞ -范数会促使多个分量取值相同，所以 OSCAR 会使得非零分量尽量少且相等。此外还有 $l_{2,1}$ -范数和 $l_{1,2}$ -范数，它们考虑的是分组特征，前者倾向于在多组特征中选择一组，后者则是在每个分组中挑选少许特征，它们常用于多任务学习（multi-task learning）中。

至此，通过最大间隔准则导出了一系列统计学习算法，它们都可以很方便地引入核方法，从而既能保持原本模型内在的线性性，又能在不显著增加参数的情况下加强假设空间的表达能力，最后还使得模型能够处理结构化的输入特征，如字符序列、语法树、图等^[103]。事实上，随着统计学习的流行，核方法已经成为机器学习的通用技术，被推广到其它各种学习模型上，如主成分分析（principal component analysis）^[127]、线性判别分析（linear discriminant analysis）^[31]、高斯过程（Gaussian process）^[92] 等。此外，得益于 Mercer 核条件，这些算法最终形式化出的问题是个凸的 QP 问题，一般来说有高效的优化算法可以快速得到全局最优解，这是决策树、神经网络等其他学习模型所不具备的，反过来统计学习的火热也促进了对优化算法的研究，除了传统的求解 QP 的通用算法，如有效集法、内点法^[83] 等，基于序贯最小化（Sequential Minimal Optimization，简称 SMO）的算法^[15,29,74,89]、基于割平面（cutting-plane）的算法^[54,55,116]、基于随机梯度下降（Stochastic Gradient Descent，简称 SGD）的算法^[101,138]、基于对偶坐标下降（dual coordinate descent）的算法^[47]，也纷纷被提了出来。时至今日，依然有许多研究者在想方设法改进这些统计学习算法^[19,25,57,64,67,84,87,110–113,141]。

1.2.4 间隔理论

除了最大间隔准则导出的算法外，Boosting 是另一类源自理论研究^[96] 并发展成为实用技术的统计学习算法。它主要考虑两个问题，一是偏差-复杂度权衡（bias-complexity tradeoff）。易知最小化经验风险的分类器 h_D 的泛化风险可分解为两部分：

$$R(h_D) = \underbrace{\min_{h \in \mathcal{H}} R(h)}_{\text{逼近误差}} + \underbrace{R(h_D) - \min_{h \in \mathcal{H}} R(h)}_{\text{估计误差}} \quad (1.25)$$

其中第一项称为逼近误差（approximation error），即假设空间中最优分类器的泛化风险，它的产生是因为我们事先选定了—个受限的假设空间。第二项称为

估计误差（estimation error），它的产生是因为学习算法只能得到训练数据集，而不是真实分布，即这是用经验风险近似真实的泛化风险所带来的误差。

不难看出这两项是冲突的，如果选取较大的假设空间，则容易出现过拟合，此时逼近误差会较小，但估计误差会很大。反过来，如果选择较小的假设空间，则容易出现欠拟合，此时逼近误差较大，而估计误差较小。因此任何一个学习算法都需要在这两者间做权衡，在保持合理的估计误差的情况下，使得假设空间尽可能的大。Boosting 算法提供了一个平滑地控制两者的方式：起初先从一个很小的假设空间开始，此时逼近误差会很大，然后随着算法的运行，逐步增大假设空间，使得逼近误差慢慢减小，直到两者之间达到一个平衡。

Boosting 算法考虑的第二个问题就是学习算法的计算复杂度。对于一些复杂的假设空间，在其中通过经验风险最小化得到一个好的分类器可能在计算上是行不通的，但如果就此放弃转而采用简单好求解的假设空间，则意味着牺牲了泛化性能。Boosting 算法可以克服这个问题，因为它将一个复杂假设空间中难以学习的分类器，分解成一系列在简单假设空间中易求解的基分类器（base learner），大大降低了计算上的难度，最后将这些基分类器组合起来就可以还原出要学习的目标分类器。

Boosting 族算法中最具代表性的就是 AdaBoost^[32,33,35]，它采用的假设空间为：

$$\mathcal{H} = \left\{ f \mid f(\cdot) = \sum_i \alpha_i h_i(\cdot), \sum_i \alpha_i = 1, \alpha_i \geq 0 \right\} \quad (1.26)$$

其中 $h_i : \mathcal{X} \mapsto \{1, -1\}$ 就是基分类器， α_i 是 h_i 的权重，最终的预测值是基分类器的凸组合。AdaBoost 有个令人费解的特征就是不容易出现过拟合：当训练数据集上的经验风险达到零后，继续训练，即继续加入新的基分类器，泛化性能还会继续改善，这与简单就好的“奥卡姆剃刀”（Occam's razor）原则相悖。直觉上来说基分类器越多，模型就越复杂，越容易过拟合，泛化性能理应下降才对。为了从理论上给这个怪现象一个解释，Schapire 等人^[97] 引入了间隔的概念：固定 $f = \sum_i \alpha_i h_i(\cdot)$ ，样本 $(\mathbf{x}, y)$ 的间隔定义为

$$yf(\mathbf{x}) = y \sum_i \alpha_i h_i(\cdot) = \sum_{i: y=h_i(\mathbf{x})} \alpha_i - \sum_{i: y \neq h_i(\mathbf{x})} \alpha_i \quad (1.27)$$

即分类正确的基分类器权重之和与分类错误的基分类器权重之和的差。基于此，Schapire 等人得到了第一个关于 AdaBoost 的泛化界：

定理 1.5 对任意 $\delta > 0$, $\theta > 0$, $f \in \mathcal{H}$, 以及独立同分布地采样于未知分布 $\mathcal{D}$ 的 m 个训练样本组成的数据集 D ,

$$R(f) \leq \mathbb{P}(yf(\mathbf{x}) \leq \theta) + O\left(\sqrt{\frac{\ln m \ln |\mathcal{H}|}{m\theta^2}} + \frac{1}{m} \ln \frac{1}{\delta}\right) \quad (1.28)$$

至少以 $1 - \delta$ 的概率成立。

该定理表明 AdaBoost 的泛化风险与训练数据集上的间隔 $\mathbb{P}(yf(\mathbf{x}) \leq \theta)$ 、训练数据集的大小 m 以及假设空间的大小 $|\mathcal{H}|$ 有关。固定后两者可以看出, 当最小间隔越大时, $\mathbb{P}(yf(\mathbf{x}) \leq \theta)$ 越小, 从而界越紧。因此某种程度上, 该定理揭示了最小间隔的重要性。受此启发, Breiman^[14] 直接考虑最小间隔 $\theta_0 = \min_i y_i f(\mathbf{x}_i)$ 并证明了:

定理 1.6 对任意 $\delta > 0$, $\theta_0 > 4\sqrt{2/|\mathcal{H}|}$, $B \leq 2m$, $f \in \mathcal{H}$, 以及独立同分布地采样于未知分布 $\mathcal{D}$ 的 m 个训练样本组成的数据集 D ,

$$R(f) \leq B\left(\ln(2m) + \ln \frac{1}{B} + 1\right) + \frac{1}{m} \ln \frac{|\mathcal{H}|}{\delta} \quad (1.29)$$

至少以 $1 - \delta$ 的概率成立, 其中 $B = 32 \ln 2 |\mathcal{H}| / m\theta_0^2$ 。

不难看出这个界是 $O(\ln m/m)$ 的, 比定理 1.5 中的 $O(\sqrt{\ln m/m})$ 的界要紧, 因此这个定理更加明确地显示了最小间隔的重要性。鉴于此, Breiman 紧接着提出了一个直接优化最小间隔的 AdaBoost 的变体算法: Arc-gv。但事与愿违的是, 在真实数据集上, Arc-gv 表现出的泛化性能并没有 AdaBoost 好, 尽管它确实得到了更大的最小间隔, 于是 Breiman 宣称用间隔来解释 AdaBoost 的鲁棒性是行不通的。

后来, Reyzin 和 Schapire^[94] 研究发现 Breiman 的实验中存在漏洞: 比较两个模型给出的间隔的前提是它们必须有相同的复杂度, 而他并没有保证这一点。事实上, Breiman 用的基分类器是分类回归树 (Classification And Regression Tree, 简称 CART), 他认为代表树型分类器复杂度的度量是叶子结点的个数, 因此他只固定了每个 CART 上叶子结点的个数, 但是树型分类器的复杂度与它的深度也是相关的。因此, Reyzin 和 Schapire 重做了 Breiman 的实验, 只不过这次选用的基分类器是只有一层深度、两个叶子结点的决策树桩 (decision stumps), 最终实验结果表明 Arc-gv 虽然给出的最小间隔要大于

AdaBoost, 但它的整体间隔分布没有 AdaBoost 好, 于是他们猜测优化最小间隔也许并无必要, 间隔分布才是更重要的。

至此, 问题转变成如何得到更紧的基于间隔分布的泛化界。后来, Wang 等人^[125] 提出 E-间隔 (Emargin) 的概念并证明了:

定理 1.7 对任意 $\delta > 0$, $8 < |\mathcal{H}| < \infty$, $f \in \mathcal{H}$, 以及独立同分布地采样于未知分布 $\mathcal{D}$ 的 m 个训练样本组成的数据集 D ,

$$R(f) \leq \frac{\ln |\mathcal{H}|}{m} + \inf_{q \in \{q_0, q_0 + \frac{1}{m}, \dots, 1\}} \text{KL}^{-1}(q; u[\hat{\theta}(q)]) \quad (1.30)$$

至少以 $1 - \delta$ 的概率成立, 其中

$$q_0 = \mathbb{P}_D(yf(\mathbf{x}) \leq \sqrt{8/|\mathcal{H}|}) < 1 \quad (1.31)$$

$$u[\hat{\theta}(q)] = \frac{1}{m} \left(\frac{8 \ln |\mathcal{H}|}{\hat{\theta}^2(q)} \ln \frac{2m^2}{\ln |\mathcal{H}|} + \ln |\mathcal{H}| + \ln \frac{m}{\delta} \right) \quad (1.32)$$

$$\hat{\theta}(q) = \sup_{\theta} \left\{ \theta \in \left(\sqrt{8/|\mathcal{H}|}, 1 \right] \mid \mathbb{P}_D(yf(\mathbf{x}) \leq \theta) \leq q \right\} \quad (1.33)$$

$$\text{KL}^{-1}(q; u) = \inf_w \{w \mid w \geq q, \text{KL}(q||w) \geq u\} \quad (1.34)$$

定理中使得右边第二项最小的 q 就是 E-间隔, 虽然文中称这是基于间隔分布的更紧的泛化界, 但由于定理所利用的信息已经不同于定理 1.5, 因此无法直接比较这两个界。此外 E-间隔的表达式缺乏直觉意义, 也很难对算法的设计有任何的指导作用。

几年后, Gao 和 Zhou^[37] 研究表明无论是最小间隔还是 E-间隔, 事实上都是 k -间隔的特例, 即都是在考虑某个单个间隔。此外, 在利用与定理 1.5 相同信息的条件下, Gao 和 Zhou 利用改进的 Bernstein 不等式^[76] 证明了更紧的基于间隔分布的泛化界:

定理 1.8 对任意 $\delta > 0$, $m \geq 5$, $f \in \mathcal{H}$, 以及独立同分布地采样于未知分布 $\mathcal{D}$ 的 m 个训练样本组成的数据集 D ,

$$R(f) \leq \frac{2}{m} + \inf_{\theta \in (0, 1]} \left\{ \mathbb{P}_D(yf(\mathbf{x}) < \theta) + \frac{7\mu + 3\sqrt{3\mu}}{3m} + \sqrt{\frac{3\mu}{m} \mathbb{P}_D(yf(\mathbf{x}) < \theta)} \right\} \quad (1.35)$$

$$\leq \frac{7\mu_0}{3m} + \frac{\sqrt{3\mu_0}}{m} \quad (1.36)$$

至少以 $1 - \delta$ 的概率成立，其中

$$\mu = \frac{8}{\theta^2} \ln m \ln(2|\mathcal{H}|) + \ln \frac{2|\mathcal{H}|}{\delta} \quad (1.37)$$

$$\mu_0 = \frac{8}{\theta_0^2} \ln m \ln(2|\mathcal{H}|) + \ln \frac{2|\mathcal{H}|}{\delta} \quad (1.38)$$

不难看出这个界是 $O(\ln m/m)$ 的，因此比定理 1.5 中的 $O(\sqrt{\ln m/m})$ 的界要紧。此外，当以下条件：

$$\theta_0 > 4 \sqrt{2/|\mathcal{H}|} \quad (1.39)$$

$$B = \frac{32 \ln 2|\mathcal{H}|}{m\theta_0^2} \leq 2m \quad (1.40)$$

$$m \geq \max \left\{ 4, \exp \left(\frac{\theta_0^2}{4 \ln(2|\mathcal{H}|)} \ln \frac{|\mathcal{H}|}{8} \right) \right\} \quad (1.41)$$

成立时，可以证明这个界使用的信息与定理 1.6 完全相同，但比定理 1.6 中的界也要紧，因此以最小间隔的界更紧但是实验效果差来说明间隔理论不能用来解释 AdaBoost 鲁棒性的说法就不攻自破了，至此关于 AdaBoost 的间隔理论完美地画上了句号。

1.3 有待研究的问题

统计学习中经典的大间隔方法以 VC 维理论为基础，考虑优化分类器的最小间隔，然而关于 AdaBoost 的一系列理论研究表明，优化最小间隔并不能保证良好的泛化性能，更为重要的概念是间隔分布。因此，以优化间隔分布为准则，不妨称为最优间隔分布准则，设计学习算法是个值得探索的问题，这很可能会给现有的学习算法带来性能的提升。

那么该如何优化间隔分布呢？Reyzin 和 Schapire^[94] 曾经猜想应该通过最大化间隔均值或者间隔加权和来优化间隔分布，但并没有给出理论保证。后来 Gao 和 Zhou^[37] 给出的另一个形式的间隔定理表明，只用间隔均值来刻画间隔分布是远远不够的，还要把二阶统计量间隔方差也考虑进来，应该通过最大化间隔均值同时最小化间隔方差来优化间隔分布。

至此我们得到一系列值得研究的问题：

1. 对于监督学习中最常见的二分类问题，如何将最大化间隔均值同时最小

化间隔方差形式化成一个优化问题？是否存在高效的优化算法？理论上能否推出基于间隔分布的泛化界？实验上能否验证最优间隔分布准则的优越性？

2. 对于监督学习中的多分类问题，如何优化间隔分布？将其分解成一系列二分类问题还是直接将二分类下的形式化推广到多分类？是否存在高效的优化算法？理论上能否推出基于间隔分布的泛化界？实验上能否验证最优间隔分布准则的优越性？
3. 对于无监督学习中最常见的聚类问题，是否可以引入最优间隔分布准则？此时对簇赋予簇标记是个带有整型变量的优化问题，此时是否存在高效的优化算法？实验上能否验证基于最优间隔分布准则的聚类算法的优越性？
4. 对于半监督学习问题？是否可以引入最优间隔分布准则？此时对未标记样本赋予类别标记涉及混合整数规划，是否存在高效的优化算法？实验上能否验证基于最优间隔分布准则的半监督学习算法的优越性？

1.4 本文工作

针对上一节所说的四种常见的机器学习任务，本文提出四种相应的显式优化间隔分布的方法，分别对应于本文的第 2 章至第 5 章。

第 2 章提出二分类最优间隔分布学习机 ODM。通过将任务形式化为最大化间隔均值同时最小化间隔方差来优化间隔分布，并提出一种基于对偶坐标下降的方法进行求解。对于大规模数据集，本文提出基于 SVRG 的快速求解算法。最终实验表明 ODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的传统大间隔方法。

第 3 章提出多分类最优间隔分布学习机 mcODM。通过将多类间隔定义为每类与“其他类”的二类间隔的最小值来优化间隔分布。由于最终形式化出的问题不再是一个凸优化，很难直接求解。本文先将其放松成一系列较易处理的 QP 问题，并通过基于块坐标下降的方法来求解其对偶问题；每个块坐标下降子问题是一个含有特殊结构的 QP 问题，本文提出一种基于排序的快速求解算法，比传统的求解 QP 的通用算法要高效。最终实验表明 mcODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的多分类方法。

第 4 章提出聚类最优间隔分布学习机 ODMC。对于聚类问题，一个好的结果是在将簇标记指派给每个簇之后，可以寻找一个划分超平面在这个“有监督”

数据集上产生最优间隔分布。因此 ODMC 同时优化簇标记和间隔分布，最终形式化出的问题是一个混合整数规划，难以直接求解，本文采用极大极小技巧先将其放松成一个鞍点问题，然后提出一种基于随机镜像下降的方法进行求解。最终实验表明 ODMC 的聚类性能显著优于、且在最坏情况下不差于优化最小间隔的聚类方法。

第 5 章提出半监督最优间隔分布学习机 ssODM。根据半监督学习的流形假设，在将类别标记指派给每个未标记样本之后，可以寻找一个划分超平面在这个“有监督”数据集上产生最优间隔分布。因此 ssODM 同时优化未标记样本的类别标记和间隔分布，最终形式化出的问题是一个混合整数规划，难以直接求解，本文采用极大极小技巧先将其放松成一个鞍点问题，然后提出一种基于随机镜像近端下降的方法进行求解。最终实验表明 ssODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的半监督学习方法。

第二章 二分类最优间隔 分布学习机

2.1 引言

经典的大间隔方法以最小间隔为优化目标，这种忽略了大部分样本的信息而只关注少数样本的做法是有潜在风险的。如图2.1所示：虚线椭圆分别代表两类样本的潜在分布，圆形和正方形分别代表采样出的两类样本，实心圆形和实心正方形是样本均值（未必是数据集中的真实样本）。大间隔方法只考虑离超平面近的那些点，最终学到的分界面是 $h_{\min}$ ，注意它与右边的椭圆已经相交了，这意味着它有将正方形样本误分类的风险。相反，如果考虑整个间隔分布，最终学到的分界面是 h_{dist} ，显然它要比 $h_{\min}$ 鲁棒得多。




图 2.1: 虚线椭圆分别代表两类样本的潜在分布，圆形和正方形分别代表采样出的两类样本，实心圆形和实心正方形是样本均值（未必是数据集中的真实样本），大间隔方法只考虑离超平面近的那些点，最终学到的分界面是 $h_{\min}$ ，与右边的椭圆相交意味着它有将正方形样本误分类的风险；如果考虑整个间隔分布，最终学到的分界面应该是 h_{dist} ，显然比 $h_{\min}$ 鲁棒得多^[147]

之前已经有一些工作在考虑间隔分布对线性判别式模型的影响，Garg 和 Roth^[38,39] 提出了间隔分布优化（Margin Distribution Optimization, MDO）算法，

该算法启发式地定义了一个关于间隔的指数损失函数

$$W(\mathbf{x}_i) = \begin{cases} \exp(-\alpha\gamma_f^2(\mathbf{x}_i, y_i)) & \gamma_f(\mathbf{x}_i, y_i) \geq 0 \\ \exp(-\beta\gamma_f(\mathbf{x}_i, y_i)) & \gamma_f(\mathbf{x}_i, y_i) < 0 \end{cases} \quad (2.1)$$

其中 α, β 是可调节的参数，可以看出当间隔 $\gamma_f(\mathbf{x}_i, y_i)$ 很大时，损失 $W(\mathbf{x}_i)$ 很小；间隔 $\gamma_f(\mathbf{x}_i, y_i)$ 很小时，损失 $W(\mathbf{x}_i)$ 很大，最终目标就是最小化损失的和。因此某种程度上，该算法可以看作是在优化间隔的加权和。注意该方法将间隔放在了指数函数内部，因此无法引入非线性核，这使得最终模型的表达能力很受限制。此外，该方法的目标函数既不凸也不平滑，很难优化，只能以较慢的速率求得一个局部最优解。

Pelckmans 等人^[88] 提出了最大平均间隔分类器（Maximal Average Margin for Classifiers, MAMC），即直接最大化间隔分布的一阶统计量

$$\max_{\mathbf{w}} \quad \frac{1}{m} \sum_{i=1}^m \frac{y_i \mathbf{w}^\top \phi(\mathbf{x}_i)}{\|\mathbf{w}\|} \quad (2.2)$$

在类别不平衡时，该方法容易输出一个平凡解，即划分超平面落在无穷远处。

Aioli2008A 等人^[1] 从博弈论的角度提出了一个优化间隔分布的算法（KM-OMD），最终形式化为

$$\min_{\boldsymbol{\alpha}} \quad (1 - \lambda) \boldsymbol{\alpha}^\top [(\mathbf{y}\mathbf{y}^\top) \circ \mathbf{K}] \boldsymbol{\alpha} + \lambda \|\boldsymbol{\alpha}\|^2 \quad (2.3)$$

$$\text{s.t.} \quad \boldsymbol{\alpha}^+ \in \Delta_{m_+}, \boldsymbol{\alpha}^- \in \Delta_{m_-} \quad (2.4)$$

其中 $\boldsymbol{\alpha}^+$ 和 $\boldsymbol{\alpha}^-$ 分别表示 $\boldsymbol{\alpha}$ 的正数部分和负数部分， m_+ 和 m_- 分别表示正类样本和负类样本的个数， Δ_m 表示 m 维单纯形， $\mathbf{K}$ 是核矩阵（kernel matrix），即 $[\mathbf{K}]_{ij} = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$ 。可以看出该方法就是在硬间隔 SVM 的对偶问题的目标函数上加了一项 $\|\boldsymbol{\alpha}\|^2$ ，即在矩阵 $(\mathbf{y}\mathbf{y}^\top) \circ \mathbf{K}$ 的每个对角线元素上加了 λ ，这相当于设计了一个特殊的特征映射^[34]：在每个样本的特征向量后接上 $\sqrt{\lambda} \mathbf{e}_i \in \mathbb{R}^m$ ，其中 $\mathbf{e}_i$ 是第 i 维为 1 其余维为零的向量。因此，这就是一个带有固定核函数的硬间隔 SVM。此外，该方法由于含有等式约束，只能使用类似 SMO 的方法进行优化，难以处理大数据集。

不难看出，这些工作虽然都声称考虑了间隔分布，但其实都只是在优化间隔均值或是间隔加权和，而 Gao 和 Zhou^[37] 的研究表明只用间隔均值来刻画间

隔分布是不够的，还要把二阶统计量间隔方差也考虑进来，因此这些方法的性能注定不会特别好。

2.2 问题形式化

本节提出最大化间隔均值同时最小化间隔方差的二分类最优间隔分布学习机（Optimal margin Distribution Machine，简称 ODM）。最直接的办法就是考虑两者的线性组合，该部分结果已发表于 KDD'14 的文章^[139]中，当时我们称其为 LDM（Large margin Distribution Machine），但以“Large”来形容分布“好”未必妥帖，所以我们改用“Optimal”，并记其为 ODM^L ，由于 ODM^L 最终形式化出的优化问题涉及计算开销较大的矩阵求逆操作，我们又提出另一种更简单有效的形式化，记为 $\text{ODM}^{[140]}$ 。

2.2.1 ODM^L

记 $\mathbf{X} = [\phi(\mathbf{x}_1), \dots, \phi(\mathbf{x}_m)]$ ，其中 $\phi(\cdot)$ 是某个正定核函数 $\kappa(\cdot, \cdot)$ 诱导的特征映射， $\mathbf{y} = [y_1; \dots; y_m]$ 是 m 维列向量， $\mathbf{Y}$ 是以 $y_1, \dots, y_m$ 为对角线的 m 阶方阵，即 $\mathbf{y} = \mathbf{Y}\mathbf{e}$ ，其中 $\mathbf{e}$ 是全 1 向量，于是间隔均值和间隔方差可分别写为：

$$\gamma_m = \frac{1}{m} \sum_{i=1}^m y_i \mathbf{w}^\top \phi(\mathbf{x}_i) = \frac{1}{m} (\mathbf{X}\mathbf{y})^\top \mathbf{w} \quad (2.5)$$

$$\gamma_v = \frac{1}{m} \sum_{i=1}^m (y_i \mathbf{w}^\top \phi(\mathbf{x}_i) - \bar{\gamma})^2 = \mathbf{w}^\top \mathbf{X} \frac{m\mathbf{I} - \mathbf{y}\mathbf{y}^\top}{m^2} \mathbf{X}^\top \mathbf{w} \quad (2.6)$$

最直接的方式就是考虑其线性组合，结合 l_2 -范数正则项和 hinge 损失函数，于是得到如下形式化：

$$\begin{aligned} \min_{\mathbf{w}, \xi_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + \mu_1 \gamma_v - \mu_2 \gamma_m + \frac{\lambda}{m} \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \xi_i \\ & \xi_i \geq 0, \forall i \in [m] \end{aligned} \quad (2.7)$$

其中参数 μ_1 和 μ_2 用来权衡两项的重要性。将式 (2.5) 和式 (2.6) 代入到问题

(2.7) 中并改写成矩阵的形式可得如下优化问题:

$$\begin{aligned} \min_{\mathbf{w}, \boldsymbol{\xi}} \quad & \frac{1}{2} \mathbf{w}^\top \mathbf{w} + \mathbf{w}^\top \mathbf{X} \frac{\mu_1(m\mathbf{I} - \mathbf{y}\mathbf{y}^\top)}{m^2} \mathbf{X}^\top \mathbf{w} - \frac{\mu_2}{m} (\mathbf{X}\mathbf{y})^\top \mathbf{w} + \frac{\lambda}{m} \mathbf{e}^\top \boldsymbol{\xi} \\ \text{s.t.} \quad & \mathbf{Y}\mathbf{X}^\top \mathbf{w} \geq \mathbf{e} - \boldsymbol{\xi} \\ & \boldsymbol{\xi} \geq \mathbf{0} \end{aligned} \quad (2.8)$$

这就是 ODM^L 的原始问题。注意由于核的存在, 优化变量可能是无穷维的, 但约束个数是有限的, 因此我们求其对偶问题。

为两个约束分别引入拉格朗日乘子 (Lagrange multipliers) $\alpha \geq 0$ 、 $\beta \geq 0$, 于是得到拉格朗日函数^[12]:

$$\begin{aligned} L(\mathbf{w}, \boldsymbol{\xi}, \alpha, \beta) &= \frac{1}{2} \mathbf{w}^\top \mathbf{w} + \mathbf{w}^\top \mathbf{X} \frac{\mu_1(m\mathbf{I} - \mathbf{y}\mathbf{y}^\top)}{m^2} \mathbf{X}^\top \mathbf{w} - \frac{\mu_2}{m} (\mathbf{X}\mathbf{y})^\top \mathbf{w} \\ &\quad + \frac{\lambda}{m} \mathbf{e}^\top \boldsymbol{\xi} - \alpha^\top (\mathbf{Y}\mathbf{X}^\top \mathbf{w} - \mathbf{e} + \boldsymbol{\xi}) - \beta^\top \boldsymbol{\xi} \\ &= \frac{1}{2} \mathbf{w}^\top \mathbf{Q} \mathbf{w} - \mathbf{w}^\top \mathbf{X} \mathbf{Y} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right) + \alpha^\top \mathbf{e} + \boldsymbol{\xi}^\top \left(\frac{\lambda}{m} \mathbf{e} - \alpha - \beta \right) \end{aligned} \quad (2.9)$$

其中 $\mathbf{Q} = \mathbf{I} + \mathbf{X} 2\mu_1(m\mathbf{I} - \mathbf{y}\mathbf{y}^\top) \mathbf{X}^\top / m^2$ 。为了求得对偶函数, 需令拉格朗日函数关于原始优化变量 $\mathbf{w}$ 、 $\boldsymbol{\xi}$ 取极小, 故分别求导并令导数为零可得:

$$\begin{aligned} \frac{\partial L}{\partial \mathbf{w}} &= \mathbf{Q} \mathbf{w} - \mathbf{X} \mathbf{Y} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right) = \mathbf{0} \longrightarrow \mathbf{w} = \mathbf{Q}^{-1} \mathbf{X} \mathbf{Y} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right) \\ \frac{\partial L}{\partial \boldsymbol{\xi}} &= \frac{\lambda}{m} \mathbf{e} - \alpha - \beta = \mathbf{0} \end{aligned} \quad (2.10)$$

回代入式 (2.9) 可得对偶函数:

$$g(\alpha, \beta) = \inf_{\mathbf{w}, \boldsymbol{\xi}} L(\mathbf{w}, \boldsymbol{\xi}, \alpha, \beta) \quad (2.11)$$

$$= -\frac{1}{2} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right)^\top \mathbf{Y} \mathbf{X}^\top \mathbf{Q}^{-1} \mathbf{X} \mathbf{Y} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right) + \alpha^\top \mathbf{e} \quad (2.12)$$

令对偶函数关于拉格朗日乘子 α 、 β 取极大可得 ODM^L 的对偶问题:

$$\max_{\alpha, \beta} \quad -\frac{1}{2} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right)^\top \mathbf{Y} \mathbf{X}^\top \mathbf{Q}^{-1} \mathbf{X} \mathbf{Y} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right) + \alpha^\top \mathbf{e} \quad (2.13)$$

$$\text{s.t.} \quad \frac{\lambda}{m} \mathbf{e} - \alpha - \beta = \mathbf{0} \quad (2.14)$$

$$\alpha \geq \mathbf{0}, \beta \geq \mathbf{0} \quad (2.15)$$

注意 $\mathbf{Q}$ 的维度与特征映射 $\phi(\cdot)$ 对应的高维特征空间的维度相当，当核函数取如高斯核（Gaussian kernel）、拉普拉斯核（Laplace kernel）时根本无法计算，但好在 $\mathbf{X}^\top \mathbf{Q}^{-1} \mathbf{X}$ 是 m 阶方阵，是可以计算的。

引理 2.1 (Sherman-Morrison-Woodbury 公式) 对任意矩阵 $\mathbf{X}$ 和方阵 $\mathbf{A}$ 有

$$(\mathbf{I} + \mathbf{XAX}^\top)^{-1} = \mathbf{I} - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \quad (2.16)$$

成立。

证明: 直接验证即可

$$\begin{aligned} & (\mathbf{I} - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top)(\mathbf{I} + \mathbf{XAX}^\top) \\ &= \mathbf{I} - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top + \mathbf{XAX}^\top - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{XAX}^\top \\ &= \mathbf{I} - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top + \mathbf{XAX}^\top - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} (\mathbf{X}^\top \mathbf{X} + \mathbf{A}^{-1} - \mathbf{A}^{-1}) \mathbf{AX}^\top \\ &= \mathbf{I} - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top + \mathbf{XAX}^\top - \mathbf{XAX}^\top + \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \\ &= \mathbf{I} \end{aligned}$$

□

取 $\mathbf{A} = 2\mu_1(m\mathbf{I} - \mathbf{y}\mathbf{y}^\top)/m^2$ ，则 $\mathbf{Q} = \mathbf{I} + \mathbf{XAX}^\top$ ，根据 Sherman-Morrison-Woodbury 公式可知

$$\begin{aligned} \mathbf{Q}^{-1} \mathbf{X} &= (\mathbf{I} - \mathbf{X}(\mathbf{A}^{-1} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top) \mathbf{X} \\ &= \mathbf{X}(\mathbf{I} - (\mathbf{A}^{-1} + \mathbf{K})^{-1} \mathbf{K}) \\ &= \mathbf{X}(\mathbf{I} - (\mathbf{A}^{-1} + \mathbf{K})^{-1} (\mathbf{A}^{-1} + \mathbf{K} - \mathbf{A}^{-1})) \\ &= \mathbf{X}(\mathbf{I} - \mathbf{I} + (\mathbf{A}^{-1} + \mathbf{K})^{-1} \mathbf{A}^{-1}) \\ &= \mathbf{X}(\mathbf{I} + \mathbf{AK})^{-1} \end{aligned} \quad (2.17)$$

其中 $\mathbf{K} = \mathbf{X}^\top \mathbf{X}$ 是核矩阵，于是 $\mathbf{X}^\top \mathbf{Q}^{-1} \mathbf{X} = \mathbf{K}(\mathbf{I} + \mathbf{AK})^{-1}$ 。记 $\mathbf{H} = \mathbf{YK}(\mathbf{I} + \mathbf{AK})^{-1} \mathbf{Y}$ ，则对偶问题的目标函数可以写为

$$g(\alpha, \beta) = -\frac{1}{2} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right)^\top \mathbf{H} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right) + \mathbf{e}^\top \alpha \quad (2.18)$$

$$= -\frac{1}{2} \alpha^\top \mathbf{H} \alpha - \left(\frac{\mu_2}{m} \mathbf{H} \mathbf{e} - \mathbf{e} \right)^\top \alpha + \text{const} \quad (2.19)$$

忽略常数项，取负号将最大化问题转化成易处理的最小化问题，并注意 β 的非负性可得如下的等价问题：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^\top \mathbf{H} \alpha + \left(\frac{\mu_2}{m} \mathbf{H} \mathbf{e} - \mathbf{e} \right)^\top \alpha \\ \text{s.t.} \quad & \mathbf{0} \leq \alpha \leq \frac{\lambda}{m} \mathbf{e} \end{aligned} \quad (2.20)$$

设对偶问题最优解为 α^* ，根据式 (2.10) 和式 (2.17) 可得原始问题最优解

$$\mathbf{w}^* = \mathbf{Q}^{-1} \mathbf{X} \mathbf{Y} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha \right) = \mathbf{X} (\mathbf{I} + \mathbf{A} \mathbf{K})^{-1} \mathbf{Y} \left(\frac{\mu_2}{m} \mathbf{e} + \alpha^* \right) = \mathbf{X} \boldsymbol{\nu}, \quad (2.21)$$

其中 $\boldsymbol{\nu} = (\mathbf{I} + \mathbf{A} \mathbf{K})^{-1} \mathbf{Y} (\mu_2 \mathbf{e} / m + \alpha^*)$ ，故对于任意未知样本 $\mathbf{z}$ ，其类别标记 $\hat{y}$ 可通过下式计算得到：

$$\hat{y} = \text{sign } \mathbf{w}^\top \phi(\mathbf{z}) = \text{sign } \boldsymbol{\nu}^\top \mathbf{X}^\top \phi(\mathbf{z}) = \text{sign } \sum_{i=1}^m \nu_i \kappa(\mathbf{x}_i, \mathbf{z}) \quad (2.22)$$

2.2.2 ODM

ODM^L 的想法非常直接，就是间隔均值和间隔方差的线性组合，但最终的形式化却有点复杂，其中还涉及 $(\mathbf{I} + \mathbf{A} \mathbf{K})^{-1}$ 这样的矩阵求逆操作，当 $\mathbf{I} + \mathbf{A} \mathbf{K}$ 的条件数（condition number）很大时，矩阵接近不可逆，这会给优化过程带来不稳定性。本节提出一个更简单的形式化，可以克服 ODM^L 的缺陷。

记训练数据集上的归一化间隔均值为 $\hat{\gamma}_m$ ，则样本 $(\mathbf{x}_i, y_i)$ 的归一化间隔偏离均值的量为 $|\hat{\gamma}(\mathbf{x}_i, y_i) - \hat{\gamma}_m|$ ，于是最大化间隔均值同时最小间隔方差可以形式化为

$$\max_{\mathbf{w}, \hat{\xi}_i, \hat{\epsilon}_i} \quad \rho \hat{\gamma}_m^2 - \frac{1}{m} \sum_{i=1}^m (\hat{\xi}_i^2 + \hat{\epsilon}_i^2) \quad (2.23)$$

$$\text{s.t.} \quad \hat{\gamma}(\mathbf{x}_i, y_i) \geq \hat{\gamma}_m - \hat{\xi}_i \quad (2.24)$$

$$\hat{\gamma}(\mathbf{x}_i, y_i) \leq \hat{\gamma}_m + \hat{\epsilon}_i, \quad \forall i \in [m] \quad (2.25)$$

其中参数 ρ 用来权衡两项的重要性。注意间隔 $\hat{\gamma}(\mathbf{x}_i, y_i)$ 大于均值与小于均值两种情况不可能同时成立，故 $\hat{\xi}_i$ 、 $\hat{\epsilon}_i$ 中必然一个非负一个为零（为负是不可能的，否则将其设成零不破坏任何约束却可以使目标函数值下降），所以目标函

数第二项就是间隔方差。记 $\xi_i = \|\mathbf{w}\|\hat{\xi}_i$ 、 $\epsilon_i = \|\mathbf{w}\|\hat{\epsilon}_i$ ，则上述问题可重写为

$$\max_{\mathbf{w}, \xi_i, \epsilon_i} \rho \frac{\gamma_m^2}{\|\mathbf{w}\|^2} - \frac{1}{m} \sum_{i=1}^m \frac{\xi_i^2 + \epsilon_i^2}{\|\mathbf{w}\|^2} \quad (2.26)$$

$$\text{s.t. } y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq \gamma_m - \xi_i \quad (2.27)$$

$$y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq \gamma_m + \epsilon_i, \forall i \in [m] \quad (2.28)$$

注意 γ_m 的取值不影响优化，因为对其缩放， $\mathbf{w}$ 、 ξ_i 、 ϵ_i 只需做同比例的缩放即可使得约束依然满足，且目标函数值保持不变，故我们可以简单地将其设为 1，于是问题进一步转化成

$$\max_{\mathbf{w}, \xi_i, \epsilon_i} \frac{1}{\|\mathbf{w}\|^2} \left(1 - \frac{1}{m} \sum_{i=1}^m (\xi_i^2 + \epsilon_i^2) \right) \quad (2.29)$$

$$\text{s.t. } y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \xi_i \quad (2.30)$$

$$y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \epsilon_i, \forall i \in [m] \quad (2.31)$$

目标函数是两项乘积的形式，注意最大化这两项分别等价于最小化 $\|\mathbf{w}\|^2$ 和 $\sum_{i=1}^m (\xi_i^2 + \epsilon_i^2)$ ，因此不难看出存在常数 λ 使得下述优化问题与上述优化问题有相同的解

$$\min_{\mathbf{w}, \xi_i, \epsilon_i} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m (\xi_i^2 + \epsilon_i^2) \quad (2.32)$$

$$\text{s.t. } y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \xi_i \quad (2.33)$$

$$y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \epsilon_i, \forall i \in [m] \quad (2.34)$$

注意两个约束分别对应了样本间隔对间隔均值 1 的两种不同方向的偏离，它们是不能一视同仁的，因为向更大方向的偏离也同时在远离划分超平面，这不会对分类错误率有什么影响；而向变小方向的偏离则是在接近划分超平面，这同时也增加了样本被误分类的可能性。因此我们需区别对待，考虑引入参数 $\mu \in (0, 1)$ 来权衡两种不同的偏离损失，即将目标函数第二项中的 $\sum_{i=1}^m (\xi_i^2 + \epsilon_i^2)$ 修改成 $\sum_{i=1}^m (\xi_i^2 + \mu \epsilon_i^2)$ 。

根据表示定理^[98]可知最终的划分超平面由损失不为零 $\square\square$ 样本线性表出，而对于 ODM，只要间隔不等于 1 就有损失，故几乎所有的样本都是支持向量，都对最终的划分超平面有影响，这同时增大了计算开销和存储开销，并无必

要。为此需要让模型保留一定程度可控的稀疏性，仿照支持向量回归的思想，我们引入 θ -不敏感损失，即样本间隔对均值 1 的偏离程度不超过 θ 的话，就认为没有损失，超过的部分才会计算损失。

综合上述两方面，就得到了 ODM 的最终形式化：

$$\min_{\mathbf{w}, \xi_i, \epsilon_i} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1-\theta)^2} \quad (2.35)$$

$$\text{s.t. } y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i \quad (2.36)$$

$$y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \forall i \in [m] \quad (2.37)$$

其中参数 λ 、 μ 、 θ 如前所述，第二项分母上的 $(1-\theta)^2$ 是为了使得第二项成为 0-1 损失的上界。

同样由于核的存在，优化变量可能是无穷维的，但约束个数是有限的，因此我们求其对偶问题，为了方便推导，先将原始问题写成矩阵的形式：

$$\min_{\mathbf{w}, \xi, \epsilon} \frac{1}{2} \mathbf{w}^\top \mathbf{w} + \frac{\lambda}{m(1-\theta)^2} \xi^\top \xi + \frac{\lambda\mu}{m(1-\theta)^2} \epsilon^\top \epsilon \quad (2.38)$$

$$\text{s.t. } \mathbf{YX}^\top \mathbf{w} \geq (1-\theta)\mathbf{e} - \xi \quad (2.39)$$

$$\mathbf{YX}^\top \mathbf{w} \leq (1+\theta)\mathbf{e} + \epsilon \quad (2.40)$$

为两个约束分别引入拉格朗日乘子 $\zeta \geq 0$ 、 $\beta \geq 0$ ，于是得到拉格朗日函数：

$$\begin{aligned} L(\mathbf{w}, \xi, \epsilon, \zeta, \beta) = & \frac{1}{2} \mathbf{w}^\top \mathbf{w} + \frac{\lambda}{m(1-\theta)^2} \xi^\top \xi + \frac{\lambda\mu}{m(1-\theta)^2} \epsilon^\top \epsilon \\ & - \zeta^\top (\mathbf{YX}^\top \mathbf{w} - (1-\theta)\mathbf{e} + \xi) + \beta^\top (\mathbf{YX}^\top \mathbf{w} - (1+\theta)\mathbf{e} - \epsilon) \end{aligned} \quad (2.41)$$

为了求得对偶函数，需令拉格朗日函数关于原始优化变量 $\mathbf{w}$ 、 ξ 、 ϵ 取极小，故分别求导并令导数为零可得：

$$\begin{aligned} \frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \mathbf{XY}\zeta + \mathbf{XY}\beta = 0 & \longrightarrow \mathbf{w} = \mathbf{XY}(\zeta - \beta) \\ \frac{\partial L}{\partial \xi} = \frac{2\lambda}{m(1-\theta)^2} \xi - \zeta = 0 & \longrightarrow \xi = \frac{m(1-\theta)^2}{2\lambda} \zeta \\ \frac{\partial L}{\partial \epsilon} = \frac{2\lambda\mu}{m(1-\theta)^2} \epsilon - \beta = 0 & \longrightarrow \epsilon = \frac{m(1-\theta)^2}{2\lambda\mu} \beta \end{aligned} \quad (2.42)$$

回代入式 (2.41) 可得对偶函数:

$$g(\zeta, \beta) = -\frac{1}{2}(\zeta - \beta)^\top \mathbf{Y} \mathbf{X}^\top \mathbf{X} \mathbf{Y} (\zeta - \beta) + \frac{m(1-\theta)^2}{4\lambda} \zeta^\top \zeta + \frac{m(1-\theta)^2}{4\lambda\mu} \beta^\top \beta \\ - \frac{m(1-\theta)^2}{2\lambda} \zeta^\top \zeta - \frac{m(1-\theta)^2}{2\lambda\mu} \beta^\top \beta + (1-\theta) \zeta^\top \mathbf{e} - (1+\theta) \beta^\top \mathbf{e} \quad (2.43)$$

$$= -\frac{1}{2}(\zeta - \beta)^\top \mathbf{Q} (\zeta - \beta) - \frac{m(1-\theta)^2}{4\lambda} \zeta^\top \zeta - \frac{m(1-\theta)^2}{4\lambda\mu} \beta^\top \beta \\ + (1-\theta) \zeta^\top \mathbf{e} - (1+\theta) \beta^\top \mathbf{e} \quad (2.44)$$

其中 $\mathbf{Q} = \mathbf{Y} \mathbf{X}^\top \mathbf{X} \mathbf{Y}$ 。记 $\alpha = [\zeta; \beta]$, 则有

$$\zeta = [\mathbf{I}, 0] \alpha, \quad \beta = [0, \mathbf{I}] \alpha, \quad \zeta - \beta = [\mathbf{I}, -\mathbf{I}] \alpha \quad (2.45)$$

于是对偶函数可进一步写成

$$g(\alpha) = -\frac{1}{2} \alpha^\top [\mathbf{I}, -\mathbf{I}]^\top \mathbf{Q} [\mathbf{I}, -\mathbf{I}] \alpha - \frac{m(1-\theta)^2}{4\lambda} \alpha^\top [\mathbf{I}, 0]^\top [\mathbf{I}, 0] \alpha \\ - \frac{m(1-\theta)^2}{4\lambda\mu} \alpha^\top [0, \mathbf{I}]^\top [0, \mathbf{I}] \alpha + (1-\theta) \mathbf{e}^\top [\mathbf{I}, 0] \alpha - (1+\theta) \mathbf{e}^\top [0, \mathbf{I}] \alpha \quad (2.46)$$

$$= -\frac{1}{2} \alpha^\top \begin{bmatrix} \mathbf{Q} & -\mathbf{Q} \\ -\mathbf{Q} & \mathbf{Q} \end{bmatrix} \alpha - \frac{1}{2} \alpha^\top \begin{bmatrix} \frac{m(1-\theta)^2}{2\lambda} \mathbf{I} & 0 \\ 0 & \frac{m(1-\theta)^2}{2\lambda\mu} \mathbf{I} \end{bmatrix} \alpha + \begin{bmatrix} (1-\theta) \mathbf{e} \\ -(1+\theta) \mathbf{e} \end{bmatrix}^\top \alpha \quad (2.47)$$

令对偶函数关于拉格朗日乘子 α 取极大可得 ODM 的对偶问题:

$$\min_{\alpha} \quad \frac{1}{2} \alpha^\top \begin{bmatrix} \mathbf{Q} + \frac{m(1-\theta)^2}{2\lambda} \mathbf{I} & -\mathbf{Q} \\ -\mathbf{Q} & \mathbf{Q} + \frac{m(1-\theta)^2}{2\lambda\mu} \mathbf{I} \end{bmatrix} \alpha + \begin{bmatrix} (\theta-1) \mathbf{e} \\ (\theta+1) \mathbf{e} \end{bmatrix}^\top \alpha \\ \text{s.t.} \quad \alpha \geq 0 \quad (2.48)$$

设对偶问题最优解为 α^* , 根据式 (2.42) 可得原始问题最优解

$$\mathbf{w} = \mathbf{X} \mathbf{Y} (\zeta - \beta) = \mathbf{X} \mathbf{Y} [\mathbf{I}, -\mathbf{I}] \alpha^* = \mathbf{X} \nu, \quad (2.49)$$

其中 $\nu = \mathbf{Y} [\mathbf{I}, -\mathbf{I}] \alpha^*$, 故对于任意未知样本 z , 其类别标记 $\hat{y}$ 可通过下式计算得到:

$$\hat{y} = \text{sign } \mathbf{w}^\top \phi(z) = \text{sign } \sum_{i=1}^m \nu_i \kappa(x_i, z) \quad (2.50)$$

2.3 优化算法

本节我们为 ODM 提出一种基于对偶坐标下降的优化算法 ODM_{dcd} ，然后针对采用线性核的 ODM 提出一种基于 SVRG 的加速算法 ODM_{svrg} ，最后对 ODM 的泛化性能做简要分析。

2.3.1 ODM_{dcd}

注意无论是问题 (2.20) 还是问题 (2.48)，目标函数都是凸二次函数，约束都是解耦合的箱型约束（decoupled box constraint），因此它们可以统一写成如下形式：

$$\min_{\alpha} f(\alpha) = \frac{1}{2} \alpha^\top \mathbf{H} \alpha + \mathbf{q}^\top \alpha \quad (2.51)$$

$$\text{s.t. } \mathbf{0} \leq \alpha \leq \mathbf{u} \quad (2.52)$$

其中 $\mathbf{H}$ 是某个半正定矩阵，向量 $\mathbf{q} \in \mathbb{R}^m$ ，向量

$$\mathbf{u} = \begin{cases} \lambda \mathbf{e}/m & \text{对于 } \text{ODM}^L \\ \infty & \text{对于 } \text{ODM} \end{cases} \quad (2.53)$$

根据 Yuan 等人^[133] 的结论，这类问题可以通过对偶坐标下降法^[47] 快速求解：因为在算法的每一轮，选择其中一个坐标作为优化变量，其他变量控制不变，这个子问题是有闭式解（closed-form solution）的。不妨设当前轮选择的优化变量为 α_i ，其他变量 $\alpha_{j \neq i}$ 固定不变，子问题为：

$$\min_t f(\alpha + t \mathbf{e}_i) \quad (2.54)$$

$$\text{s.t. } 0 \leq \alpha_i + t \leq u_i \quad (2.55)$$

设 $[\mathbf{H}]_{ij} = h_{ij}$ ，则

$$f(\alpha + t \mathbf{e}_i) = \frac{1}{2} (\alpha + t \mathbf{e}_i)^\top \mathbf{H} (\alpha + t \mathbf{e}_i) + \mathbf{q}^\top (\alpha + t \mathbf{e}_i) \quad (2.56)$$

$$= \frac{1}{2} \alpha^\top \mathbf{H} \alpha + \mathbf{q}^\top \alpha + \frac{1}{2} h_{ii} t^2 + t \mathbf{e}_i^\top \mathbf{H} \alpha + t \mathbf{e}_i^\top \mathbf{q} \quad (2.57)$$

$$= f(\alpha) + \frac{1}{2} h_{ii} t^2 + \mathbf{e}_i^\top \nabla f(\alpha) t \quad (2.58)$$

其中 $\nabla f(\alpha) = \mathbf{H}\alpha + \mathbf{q}$ 是目标函数的梯度，忽略和优化变量 t 无关的 $f(\alpha)$ ，不难看出这就是个在闭区间上求二次函数极值的问题，易知其有如下闭式解：

$$\alpha_i^{new} = \min\left(\max\left(\alpha_i - \frac{[\nabla f(\alpha)]_i}{h_{ii}}, 0\right), u_i\right) \quad (2.59)$$

其中 $[\nabla f(\alpha)]_i$ 是梯度 $\nabla f(\alpha)$ 的第 i 个分量。

算法 2.1 描述了用对偶坐标下降法求解 ODM^L 和 ODM 的详细过程：

算法 2.1 ODM_{dcd}

```

1: 算法输入：数据集  $\mathbf{X}$ 
2: 算法过程：
3: 初始化  $\alpha = \mathbf{0}$ ，计算  $\mathbf{H}$  和  $\mathbf{q}$ 
4: while  $\alpha$  没有收敛 do
5:   for  $i = 1, \dots, m$  do
6:      $[\nabla f(\alpha)]_i \leftarrow [\mathbf{H}\alpha + \mathbf{q}]_i$ 
7:      $\alpha_i \leftarrow \min(\max(\alpha_i - [\nabla f(\alpha)]_i/h_{ii}, 0), u_i)$ 
8:   end for
9: end while
10: 算法输出： $\alpha$ 

```

2.3.2 ODM_{svrg}

ODM_{dcd} 由于要计算核矩阵，时间开销至少是 $O(m^2)$ ，当面对大规模数据集时，会显得力不从心，因此我们为使用线性核的 ODM^L 和 ODM 专门设计了基于 $\text{SGD}^{[10,90,93,102,143]}$ 的加速算法。

线性核 ODM^L 可形式化成无约束优化问题：

$$\begin{aligned} \min_w \quad f_L(w) = & \frac{1}{2} w^\top w + \frac{\mu_1}{m} w^\top \mathbf{X} \mathbf{X}^\top w - \frac{\mu_1}{m^2} w^\top \mathbf{X} \mathbf{y} \mathbf{y}^\top \mathbf{X}^\top w \\ & - \frac{\mu_2}{m} (\mathbf{X} \mathbf{y})^\top w + \frac{\lambda}{m} \sum_{i=1}^m [1 - y_i w^\top \mathbf{x}_i]_+ \end{aligned} \quad (2.60)$$

线性核 ODM 可形式化成无约束优化问题：

$$\begin{aligned} \min_w \quad f_O(w) = & \frac{1}{2} w^\top w + \frac{\lambda}{m(1-\theta)^2} \sum_{i=1}^m [1 - \theta - y_i w^\top \mathbf{x}_i]_+^2 \\ & + \frac{\lambda\mu}{m(1-\theta)^2} \sum_{i=1}^m [y_i w^\top \mathbf{x}_i - 1 - \theta]_+^2 \end{aligned} \quad (2.61)$$

如果使用基于梯度的一阶优化算法进行求解, 不可避免地要涉及 m 项求和, 当面对大规模数据集时, 计算开销很高。一个常用的解决办法是使用 SGD, 其基本思想是每轮用负梯度的无偏估计作为下降方向, 从而避免了对精确梯度的求解。可以证明, 当目标函数是凸函数, 即问题是凸优化时, SGD 可以按期望收敛到全局最优解^[11,63], 于是剩下的问题就是如何求 $\nabla f_O(\mathbf{w})$ 和 $\nabla f_L(\mathbf{w})$ 的无偏估计。

定理 2.2 设 $(\mathbf{x}_i, y_i)$ 和 $(\mathbf{x}_j, y_j)$ 是从训练数据集中随机采样出的两个样本, 则

$$\nabla f_L(\mathbf{w}, \mathbf{x}_i, \mathbf{x}_j) = \mathbf{w} + 2\mu_1 \mathbf{x}_i \mathbf{x}_i^\top \mathbf{w} - 2\mu_1 y_i y_j \mathbf{x}_i \mathbf{x}_j^\top \mathbf{w} - \mu_2 y_i \mathbf{x}_i - \lambda y_i \mathbf{x}_i 1_{i \in I_1} \quad (2.62)$$

$$\nabla f_O(\mathbf{w}, \mathbf{x}_i) = \mathbf{w} + \frac{2\lambda y_i \mathbf{x}_i [(y_i \mathbf{w}^\top \mathbf{x}_i + \theta - 1) 1_{i \in I_2} + \mu (y_i \mathbf{w}^\top \mathbf{x}_i - \theta - 1) 1_{i \in I_3}]}{(1 - \theta)^2} \quad (2.63)$$

分别是 $\nabla f_O(\mathbf{w})$ 和 $\nabla f_L(\mathbf{w})$ 的无偏估计, 其中集合 I_1 、 I_2 、 I_3 定义如下:

$$I_1 = \{i \mid y_i \mathbf{w}^\top \mathbf{x}_i < 1\} \quad (2.64)$$

$$I_2 = \{i \mid y_i \mathbf{w}^\top \mathbf{x}_i < 1 - \theta\} \quad (2.65)$$

$$I_3 = \{i \mid y_i \mathbf{w}^\top \mathbf{x}_i > 1 + \theta\} \quad (2.66)$$

证明: 易知 $f_L(\mathbf{w})$ 的梯度为

$$\nabla f_L(\mathbf{w}) = \mathbf{w} + \frac{2\mu_1}{m} \mathbf{X} \mathbf{X}^\top \mathbf{w} - \frac{2\mu_1}{m^2} \mathbf{X} \mathbf{y} \mathbf{y}^\top \mathbf{X}^\top \mathbf{w} - \frac{\mu_2}{m} \mathbf{X} \mathbf{y} - \frac{\lambda}{m} \sum_{i=1}^m y_i \mathbf{x}_i 1_{i \in I_1} \quad (2.67)$$

又

$$\mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top] = \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^\top = \frac{1}{m} \mathbf{X} \mathbf{X}^\top, \quad \mathbb{E}[y_i \mathbf{x}_i] = \frac{1}{m} \sum_{i=1}^m y_i \mathbf{x}_i = \frac{1}{m} \mathbf{X} \mathbf{y} \quad (2.68)$$

结合期望的线性性, $\mathbf{x}_i$ 、 $\mathbf{x}_j$ 之间的独立性, 以及式 (2.68) 可知

$$\mathbb{E}[\nabla f_L(\mathbf{w}, \mathbf{x}_i, \mathbf{x}_j)] \quad (2.69)$$

$$= \mathbf{w} + 2\mu_1 \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top] \mathbf{w} - 2\mu_1 \mathbb{E}[y_i \mathbf{x}_i] \mathbb{E}[y_j \mathbf{x}_j]^\top \mathbf{w} - \mu_2 \mathbb{E}[y_i \mathbf{x}_i] - \frac{\lambda}{m} \mathbb{E}[y_i \mathbf{x}_i 1_{i \in I_1}] \quad (2.70)$$

$$= \mathbf{w} + \frac{2\mu_1}{m} \mathbf{X} \mathbf{X}^\top \mathbf{w} - \frac{2\mu_1}{m^2} \mathbf{X} \mathbf{y} \mathbf{y}^\top \mathbf{X}^\top \mathbf{w} - \frac{\mu_2}{m} \mathbf{X} \mathbf{y} - \frac{\lambda}{m} \sum_{i=1}^m y_i \mathbf{x}_i 1_{i \in I_1} \quad (2.71)$$

$$= \nabla f_L(\mathbf{w}) \quad (2.72)$$

这就证明了 $\nabla f_L(\mathbf{w}, \mathbf{x}_i, \mathbf{x}_j)$ 是 $\nabla f_L(\mathbf{w})$ 的无偏估计。

同理易知 $f_O(\mathbf{w})$ 的梯度为

$$\nabla f_O(\mathbf{w}) = \mathbf{w} + \frac{2\lambda \sum_{i=1}^m [(y_i \mathbf{w}^\top \mathbf{x}_i + \theta - 1)y_i \mathbf{x}_i 1_{i \in I_2} + \mu(y_i \mathbf{w}^\top \mathbf{x}_i - \theta - 1)y_i \mathbf{x}_i 1_{i \in I_3}]}{m(1 - \theta)^2} \quad (2.73)$$

结合期望的线性性，以及式 (2.68) 可知

$$\begin{aligned} & \mathbb{E}[\nabla f_O(\mathbf{w}, \mathbf{x}_i)] \\ &= \mathbf{w} + \frac{2\lambda(\mathbb{E}[(y_i \mathbf{w}^\top \mathbf{x}_i + \theta - 1)y_i \mathbf{x}_i 1_{i \in I_2}] + \mu \mathbb{E}[(y_i \mathbf{w}^\top \mathbf{x}_i - \theta - 1)y_i \mathbf{x}_i 1_{i \in I_3}])}{(1 - \theta)^2} \\ &= \mathbf{w} + \frac{2\lambda[\sum_{i=1}^m (y_i \mathbf{w}^\top \mathbf{x}_i + \theta - 1)y_i \mathbf{x}_i 1_{i \in I_2} + \mu \sum_{i=1}^m (y_i \mathbf{w}^\top \mathbf{x}_i - \theta - 1)y_i \mathbf{x}_i 1_{i \in I_3}]}{m(1 - \theta)^2} \\ &= \nabla f_O(\mathbf{w}) \end{aligned}$$

这就证明了 $\nabla f_O(\mathbf{w}, \mathbf{x}_i)$ 是 $\nabla f_O(\mathbf{w})$ 的无偏估计。 $\square$

根据定理 2.2，算法第 t 轮的更新公式为

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta_t \mathbf{g}_t \quad (2.74)$$

其中 η_t 是算法第 t 轮采用的步长， $\mathbf{g}_t$ 视算法而定：

$$\mathbf{g}_t = \begin{cases} \nabla f_L(\mathbf{w}_t, \mathbf{x}_i, \mathbf{x}_j) & \text{对于 ODM}^L \\ \nabla f_O(\mathbf{w}_t, \mathbf{x}_i) & \text{对于 ODM} \end{cases} \quad (2.75)$$

通常的 SGD 由于到达最优解处，随机梯度也不为零，因此较难设置停止条件（stopping criteria），解决此问题的办法是采用其一个变体算法：SVRG（stochastic gradient descent with variance reduction）^[56,93]。该算法着眼于控制优化过程中随机梯度的方差，因此在最优解处，随机梯度也是为零的，这给设置停止条件带来了便利。此外，该算法拥有线性收敛率（linear convergence rate），因此较 SGD 也更快，其每轮除了像通常的 SGD 那样进行更新外，还需周期性地计算全梯度（full gradient）。

算法 2.2 描述了用基于 SVRG 的方法求解大规模线性核的 ODM^L 和 ODM 的详细过程：

算法 2.2 ODM_{svrg}

```

1: 算法输入: 数据集  $\mathbf{X}$ 
2: 算法过程:
3: 初始化  $\bar{\mathbf{w}}_0 = \mathbf{0}$ 
4: for  $s = 1, 2, \dots$  do
5:    $\bar{\mathbf{w}} \leftarrow \bar{\mathbf{w}}_{s-1}$ 
6:   计算全梯度  $\bar{\boldsymbol{\mu}}$ 
7:    $\mathbf{w}_0 \leftarrow \bar{\mathbf{w}}$ 
8:   for  $t = 1, 2, \dots, m$  do
9:     随机采样训练样本  $(\mathbf{x}_i, y_i)$ 
10:    根据定理 2.2 计算随机梯度  $\mathbf{g}_t$ 
11:     $\mathbf{w}_t \leftarrow \mathbf{w}_{t-1} - \eta(\nabla f_O(\mathbf{w}_{t-1}, \mathbf{x}_i) - \nabla f_O(\bar{\mathbf{w}}, \mathbf{x}_i) + \bar{\boldsymbol{\mu}})$ 
12:   end for
13:   随机采样  $t \in [m]$ 
14:    $\bar{\mathbf{w}}_s \leftarrow \mathbf{w}_t$ 
15: end for
16: 算法输出:  $\bar{\mathbf{w}}$ 

```

2.3.3 理论分析

本节我们研究 ODM 的统计性质, 为了证明 ODM 的泛化界, 需要引入如下函数:

$$\Phi(z) = 1_{z \leq 0} + \frac{(z - 1 + \theta)^2}{(1 - \theta)^2} 1_{0 < z \leq 1 - \theta} \quad (2.76)$$

以及关于 Rademacher 复杂度的性质:

引理 2.3 (Talagrand 引理^[81]) 设 $\Phi: \mathbb{R} \mapsto \mathbb{R}$ 是 l -利普希茨连续 (Lipschitz continuous) 函数。则对于任意由实值函数构成的假设空间 $\mathcal{H}$ 有如下不等式成立:

$$\mathcal{R}_m(\Phi \circ \mathcal{H}) \leq l \mathcal{R}_m(\mathcal{H}) \quad (2.77)$$

其中 $\Phi \circ \mathcal{H}$ 表示 $\mathcal{H}$ 中所有函数经 Φ 复合后构成的集合。

下面我们证明 ODM 的泛化界:

定理 2.4 记 $\mathcal{H} = \{\mathbf{x} \in \mathcal{X} \mapsto \mathbf{w}^\top \phi(\mathbf{x}) \mid \|\mathbf{w}\|^2 \leq \Lambda^2\}$ 为 ODM 的假设空间, 其中 $\phi: \mathcal{X} \mapsto \mathbb{H}$ 是某个正定核函数 $\kappa(\cdot, \cdot)$ 诱导的特征映射, 设数据集 $D \subseteq \{\mathbf{x} :$

$\kappa(\mathbf{x}, \mathbf{x}) \leq r^2\}$, 则对于任意 $\delta > 0$, 以及任意 $h \in \mathcal{H}$,

$$R(h) \leq \frac{1}{m} \sum_{i=1}^m \Phi(y_i h(\mathbf{x}_i)) + \frac{4r\Lambda}{(1-\theta)\sqrt{m}} + \sqrt{\frac{\ln(1/\delta)}{2m}} \quad (2.78)$$

至少以 $1 - \delta$ 的概率成立。

证明: 根据 McDiarmid 不等式^[77] 可知对于任意 $\delta > 0$, 以及任意 $h \in \mathcal{H}$,

$$\mathbb{E}[\Phi(yh(\mathbf{x}))] \leq \frac{1}{m} \sum_{i=1}^m \Phi(y_i h(\mathbf{x}_i)) + 2\mathcal{R}_m(\Phi \circ (y\mathcal{H})) + \sqrt{\frac{\ln(1/\delta)}{2m}} \quad (2.79)$$

至少以 $1 - \delta$ 的概率成立。

由于 $1_{yh(\mathbf{x}) \leq 0} \leq \Phi(yh(\mathbf{x}))$, 于是 $R(h) = \mathbb{E}[1_{yh(\mathbf{x}) \leq 0}] \leq \mathbb{E}[\Phi(yh(\mathbf{x}))]$ 。又 $\Phi(z)$ 是 $\frac{2}{1-\theta}$ -利普希茨连续函数, 根据 Talagrand 引理有

$$R(h) \leq \frac{1}{m} \sum_{i=1}^m \Phi(y_i h(\mathbf{x}_i)) + \frac{4}{1-\theta} \mathcal{R}_m(y\mathcal{H}) + \sqrt{\frac{\ln(1/\delta)}{2m}} \quad (2.80)$$

由 Rademacher 复杂度的定义知

$$\mathcal{R}_m(y\mathcal{H}) = \mathbb{E}_{\sigma} \left[\sup_{w \in H} \frac{1}{m} \sum_{i=1}^m \sigma_i y_i w^{\top} \mathbf{x}_i \right] = \frac{1}{m} \mathbb{E}_{\sigma} \left[\sup_{w \in H} w^{\top} \sum_{i=1}^m \sigma_i \mathbf{x}_i \right] \quad (2.81)$$

$$\leq \frac{1}{m} \mathbb{E}_{\sigma} \left[\sup_{w \in H} \|w\| \left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\| \right] \leq \frac{\Lambda}{m} \mathbb{E}_{\sigma} \left[\left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\| \right] \quad (2.82)$$

$$\leq \frac{\Lambda}{m} \sqrt{\mathbb{E}_{\sigma} \left[\left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|^2 \right]} = \frac{\Lambda}{m} \sqrt{\mathbb{E}_{\sigma} \left[\sum_{i=1}^m \sum_{j=1}^m \sigma_i \sigma_j \mathbf{x}_i^{\top} \mathbf{x}_j \right]} \quad (2.83)$$

$$\leq \frac{\Lambda}{m} \sqrt{r^2 \sum_{i=1}^m \sum_{j=1}^m \mathbb{E}_{\sigma} [\sigma_i \sigma_j]} = \frac{\Lambda}{m} \sqrt{r^2 m} = \frac{r\Lambda}{\sqrt{m}} \quad (2.84)$$

其中第二个等号成立是因为 σ_i 与 $y_i \sigma_i$ 同分布, 第三个不等号是根据柯西-施瓦茨不等式 (Cauchy-Schwarz inequality), 回代入式 (2.80) 可得式 (2.78) 成立。

□

根据定理 2.4 的结果, ODM 的泛化界由三项组成。其中第一项是 ODM 在训练数据集的经验损失, 最后一项是集中度不等式必带的副产品, 因此我们主要关注第二项。不难看出 $r\Lambda$ 越小、 $1 - \theta$ 越大, 泛化界越紧。注意

$\gamma \leq \|\mathbf{w}^\top \phi(\mathbf{x})\| \leq \|\mathbf{w}\| \|\phi(\mathbf{x})\| \leq r\Lambda$, 因此为了得到更紧的泛化界, 间隔的上界不能太大。另一方面, $1 - \theta$ 是无损失的间隔带的下界, 它类似于 SVM 的软间隔, 是某个第 p 小的间隔, 因此为了得到更紧的泛化界, 第 p 小的间隔也要尽可能的大。两相结合表明, 在固定间隔均值为 1 的情况下, 间隔方差越小泛化界越紧, 这与^[37]中的结论也是一致的。

2.4 实验验证

本节我们通过实验验证 ODM 的性能。首先 2.4.1 节介绍实验设置。然后 2.4.2 节分别展示了 ODM^L 和 ODM 在 38 个常规数据集和 12 个大数据集上的泛化性能, 对比方法包括二分类支持向量机 (SVM)、支持向量回归 (SVR)、最小二乘支持向量机 (LSSVM) 以及 2.1 节中介绍的三个方法: MDO、MAMC、KMOMD, 其中 SVR 就是以类别标记作为回归的目标值。此外, 2.4.3 节图示了 SVM、 ODM^L 、ODM 最终输出的间隔分布, 最后 2.4.4 节对比了 SVM、 ODM^L 、ODM 在大规模数据集上时间开销。

2.4.1 实验设置

实验中用到的二分类数据集包括 38 个常规数据集和 12 个大规模数据集, 表 2.1 列出了这些数据集的所有信息。可以看出, 这 50 个数据集, 样本数最小的仅有 44 个, 最大的达到 2,396,130, 特征数的跨度也很大, 小至 2, 大到 3,231,961, 因此可以说覆盖了很大的范围。对于每个数据集, 所有的特征都归一化到 $[0, 1]$ 之间, 然后随机抽取 80% 的样本用作训练数据集剩余的作为测试数据集。每个常规数据集上, 既比较线性核, 也比较高斯核, 所有随机划分重复 30 次, 记录均值和标准差, ODM^L 和 ODM 通过 ODM_{dcd} 进行求解。每个大规模数据集上, 比较线性核, 所有随机划分重复 10 次, 记录均值和标准差, ODM^L 和 ODM 通过 ODM_{svrg} 进行求解。

对于所有方法, 参数 C 和 λ 通过 5-折交叉验证 (cross validation) 从集合 $[2^0, 2^2, \dots, 2^{20}]$ 中选取, 高斯核的“带宽”参数 σ 通过 5-折交叉验证从集合 $[2^{-4}\delta, 2^{-2}\delta, 2^0\delta, 2^2\delta, 2^4\delta]$ 中选取, 其中 δ 是特征数的倒数。对于 MDO, 参数 α 、 β 按照其文中^[38]推荐的方法设置。对于 ODM^L , 参数 μ_1 和 μ_2 通过 5-折交叉验证从集合 $[2^{-4}, 2^{-2}, 2^0, 2^2, 2^4]$ 中选取。对于 ODM, 参数 μ 和 θ 通过 5-折交叉验证从集合 $[0.2, 0.4, 0.6, 0.8]$ 中选取。算法 ODM_{svrg} 的步长参数 η 按照文^[56]中推

表 2.1: 二分类数据集的信息, 38 个常规数据集, 12 个大规模数据集

规模	数据集	样本数	特征数	数据集	样本数	特征数
常规	<i>duke</i>	44	7,129	<i>heart-c</i>	296	13
	<i>colon-cancer</i>	62	2,000	<i>haberman</i>	306	14
	<i>echocardiog.</i>	62	8	<i>vertebral-col.</i>	310	6
	<i>dbworld</i>	64	4,702	<i>liverDisorders</i>	345	6
	<i>leu</i>	72	7,129	<i>house-votes</i>	435	16
	<i>balloons</i>	76	4	<i>vehicle</i>	435	16
	<i>hepatitis</i>	80	19	<i>wdbc</i>	569	14
	<i>promoters</i>	106	57	<i>isolet</i>	600	51
	<i>colic</i>	188	13	<i>credit-a</i>	653	15
	<i>parkinsons</i>	195	22	<i>breastw</i>	683	9
	<i>colic.ORIG</i>	205	17	<i>austra</i>	690	15
	<i>sonar</i>	208	60	<i>australian</i>	690	42
	<i>house</i>	232	16	<i>diabetes</i>	768	8
	<i>vote</i>	232	16	<i>fourclass</i>	862	2
	<i>heart-h</i>	261	10	<i>tic-tac-toe</i>	958	9
	<i>heart</i>	270	9	<i>credit-g</i>	1,000	20
	<i>heart-statlog</i>	270	13	<i>german</i>	1,000	59
	<i>breast</i>	277	9	<i>optdigits</i>	1,143	42
	<i>cylinder-bands</i>	277	39	<i>svmguide3</i>	1,284	22
大	<i>farm-ads</i>	4,143	54,877	<i>w8a</i>	49,749	300
	<i>gisette</i>	7,000	5,000	<i>cod-rna</i>	59,535	8
	<i>svmguide1</i>	7,089	4	<i>real-sim</i>	72,309	20,958
	<i>magic04</i>	19,020	10	<i>mini-boo-ne</i>	130,064	50
	<i>news20</i>	19,996	1,355,191	<i>rcv1</i>	697,641	47,236
	<i>adult-a</i>	32,561	123	<i>url</i>	2,396,130	3,231,961

荐的方法设置。所有参数的选取只依赖于训练数据集。

2.4.2 实验结果

表 2.2 展示了在使用线性核的情况下, 所有算法在 38 个常规数据集上的性能 (均值 $\pm$ 标准差)。每个数据集上的最好结果加粗显示。●/○ 表示在 95% 置信度的成对 t -检验下, ODM 的泛化性能显著好于/差于对比方法。平均精

表 2.2: 常规数据集上的性能 (均值 $\pm$ 标准差); 所有方法均采用线性核; 每个数据集上的最好结果加粗显示; $\bullet/\circ$ 表示在 95% 置信度的成对 t -检验下, ODM 的泛化性能显著好于/差于对比方法

数据集	SVM	SVR	LSSVM	MDO	MAMC	KMOMD	ODM ^L	ODM
<i>duke</i>	84.2 $\pm$ 8.8	84.2 $\pm$ 8.8	85.0 $\pm$ 8.2	80.6 $\pm$ 8.7 $\bullet$	46.2 $\pm$ 9.1 $\bullet$	84.1 $\pm$ 8.8	85.0 $\pm$ 8.0	85.5$\pm$7.9
<i>colon-canc</i>	81.3 $\pm$ 7.7	82.3 $\pm$ 6.3	81.8 $\pm$ 5.9 $\bullet$	80.3 $\pm$ 7.0 $\bullet$	63.3 $\pm$ 6.3 $\bullet$	81.0 $\pm$ 7.0 $\bullet$	82.2 $\pm$ 5.7	82.3$\pm$5.5
<i>echocardio</i>	68.5 $\pm$ 6.5 $\bullet$	71.7 $\pm$ 7.1	70.2 $\pm$ 6.4 $\bullet$	70.1 $\pm$ 6.8 $\bullet$	71.0 $\pm$ 5.7	72.0 $\pm$ 6.6	67.3 $\pm$ 7.7 $\bullet$	73.0$\pm$6.7
<i>dbworld</i>	86.5 $\pm$ 5.2 $\bullet$	86.5 $\pm$ 5.2 $\bullet$	86.5 $\pm$ 5.2 $\bullet$	82.6 $\pm$ 14.3 $\bullet$	78.0 $\pm$ 19.4 $\bullet$	86.5 $\pm$ 5.2 $\bullet$	88.2 $\pm$ 3.6	88.5$\pm$3.9
<i>leu</i>	93.9 $\pm$ 6.1 $\bullet$	93.3 $\pm$ 6.3 $\bullet$	93.1 $\pm$ 6.4 $\bullet$	93.5 $\pm$ 6.4 $\bullet$	65.9 $\pm$ 6.1 $\bullet$	93.9 $\pm$ 6.1 $\bullet$	93.9 $\pm$ 6.1 $\bullet$	94.8$\pm$6.0
<i>balloons</i>	68.1 $\pm$ 5.9 $\bullet$	68.1 $\pm$ 7.9 $\bullet$	71.8 $\pm$ 5.7 $\bullet$	70.9 $\pm$ 6.6 $\bullet$	60.9 $\pm$ 8.3 $\bullet$	72.5 $\pm$ 5.6 $\bullet$	72.4 $\pm$ 6.7 $\bullet$	73.9$\pm$5.6
<i>hepatitis</i>	82.6 $\pm$ 3.1 $\bullet$	82.6 $\pm$ 3.1 $\bullet$	82.6 $\pm$ 3.1 $\bullet$	83.5 $\pm$ 3.8	82.6 $\pm$ 3.1 $\bullet$	82.6 $\pm$ 3.9 $\bullet$	83.9 $\pm$ 3.8 $\bullet$	84.8$\pm$4.6
<i>promoters</i>	71.3 $\pm$ 6.7 $\bullet$	71.4 $\pm$ 6.4 $\bullet$	71.3 $\pm$ 6.9 $\bullet$	69.6 $\pm$ 7.5 $\bullet$	52.0 $\pm$ 9.6 $\bullet$	71.9 $\pm$ 6.6	73.8$\pm$6.5	73.7 $\pm$ 6.4
<i>colic</i>	83.5 $\pm$ 2.6	79.6 $\pm$ 9.1 $\bullet$	82.4 $\pm$ 5.6 $\bullet$	82.5 $\pm$ 2.9	66.1 $\pm$ 6.2 $\bullet$	80.7 $\pm$ 3.2 $\bullet$	83.8$\pm$2.8	83.7 $\pm$ 3.5
<i>parkinsons</i>	85.5 $\pm$ 2.9 $\bullet$	76.4 $\pm$ 3.5 $\bullet$	84.2 $\pm$ 4.8 $\bullet$	86.0 $\pm$ 2.7	76.4 $\pm$ 3.5 $\bullet$	81.3 $\pm$ 2.3 $\bullet$	87.0$\pm$2.6$\circ$	86.7 $\pm$ 2.7
<i>colic.ORIG</i>	61.6 $\pm$ 3.1 $\bullet$	60.6 $\pm$ 3.7 $\bullet$	62.6 $\pm$ 3.5	61.8 $\pm$ 4.1 $\bullet$	62.3 $\pm$ 2.7	63.5 $\pm$ 4.6	63.0 $\pm$ 4.6 $\bullet$	63.8$\pm$3.9
<i>sonar</i>	76.1 $\pm$ 3.0	50.8 $\pm$ 4.4 $\bullet$	72.0 $\pm$ 3.9 $\bullet$	74.3 $\pm$ 3.6	53.3 $\pm$ 4.5 $\bullet$	76.3$\pm$2.9$\circ$	75.0 $\pm$ 3.6	75.4 $\pm$ 3.8
<i>house</i>	93.1 $\pm$ 2.7 $\bullet$	96.8$\pm$1.1	96.4 $\pm$ 1.3 $\bullet$	93.4 $\pm$ 2.7 $\bullet$	88.3 $\pm$ 2.9 $\bullet$	94.7 $\pm$ 1.4 $\bullet$	96.8 $\pm$ 1.1	96.8 $\pm$ 1.1
<i>vote</i>	93.0 $\pm$ 2.2 $\bullet$	97.0$\pm$1.3	97.0 $\pm$ 1.3	93.4 $\pm$ 2.4 $\bullet$	88.4 $\pm$ 2.3 $\bullet$	94.9 $\pm$ 2.0 $\bullet$	97.0 $\pm$ 1.3	97.0 $\pm$ 1.3
<i>heart-h</i>	79.6 $\pm$ 2.9 $\bullet$	79.7 $\pm$ 3.0 $\bullet$	79.7 $\pm$ 3.2 $\bullet$	80.1 $\pm$ 3.0 $\bullet$	63.5 $\pm$ 4.1 $\bullet$	81.1 $\pm$ 2.6	80.9 $\pm$ 2.8	81.3$\pm$2.4
<i>heart</i>	82.6 $\pm$ 2.7 $\bullet$	82.6 $\pm$ 3.5	78.2 $\pm$ 5.6 $\bullet$	83.1 $\pm$ 2.8	53.7 $\pm$ 5.7 $\bullet$	82.8 $\pm$ 2.3 $\bullet$	83.4 $\pm$ 2.3	83.7$\pm$2.3
<i>heart-stat</i>	83.2 $\pm$ 2.4	82.7 $\pm$ 2.6 $\bullet$	83.3 $\pm$ 2.3	83.3 $\pm$ 2.6	61.3 $\pm$ 13.2 $\bullet$	81.7 $\pm$ 2.9 $\bullet$	84.0$\pm$2.5	83.8 $\pm$ 2.7
<i>breast</i>	71.3 $\pm$ 2.8 $\bullet$	70.6 $\pm$ 2.7 $\bullet$	72.6 $\pm$ 2.8	71.7 $\pm$ 3.0 $\bullet$	70.6 $\pm$ 2.7 $\bullet$	69.6 $\pm$ 3.1 $\bullet$	72.8 $\pm$ 2.5 $\bullet$	73.1$\pm$3.2
<i>cylinder-b</i>	64.4 $\pm$ 2.9 $\bullet$	65.8 $\pm$ 3.8 $\bullet$	67.9 $\pm$ 3.6 $\bullet$	70.2 $\pm$ 3.2	64.4 $\pm$ 2.9 $\bullet$	69.5 $\pm$ 3.7 $\bullet$	70.7 $\pm$ 3.3 $\bullet$	70.8$\pm$3.3
<i>heart-c</i>	79.7 $\pm$ 2.3 $\bullet$	78.4 $\pm$ 4.0 $\bullet$	79.8 $\pm$ 2.5 $\bullet$	79.9 $\pm$ 2.7 $\bullet$	65.9 $\pm$ 11.7 $\bullet$	80.3 $\pm$ 2.7	80.3 $\pm$ 2.5	80.5$\pm$2.4
<i>haberman</i>	74.2 $\pm$ 2.1	74.2 $\pm$ 2.1	73.4 $\pm$ 2.8	71.0 $\pm$ 3.8 $\bullet$	73.8 $\pm$ 2.0 $\bullet$	67.0 $\pm$ 4.0 $\bullet$	73.3 $\pm$ 3.1 $\bullet$	74.3$\pm$2.2
<i>vertebral-</i>	85.6 $\pm$ 1.8	67.9 $\pm$ 2.4 $\bullet$	77.2 $\pm$ 3.4 $\bullet$	71.5 $\pm$ 5.6 $\bullet$	67.9 $\pm$ 2.4 $\bullet$	84.0 $\pm$ 2.4 $\bullet$	85.5 $\pm$ 1.9	85.7$\pm$1.9
<i>liverDisor</i>	67.3 $\pm$ 2.8	62.2 $\pm$ 4.7 $\bullet$	65.9 $\pm$ 3.3 $\bullet$	57.0 $\pm$ 6.1 $\bullet$	58.4 $\pm$ 2.8 $\bullet$	63.6 $\pm$ 3.4 $\bullet$	67.8$\pm$3.0$\circ$	67.7 $\pm$ 3.9
<i>house-vote</i>	94.0 $\pm$ 1.2 $\bullet$	94.7 $\pm$ 1.0	91.8 $\pm$ 1.6 $\bullet$	93.3 $\pm$ 1.7 $\bullet$	78.9 $\pm$ 6.0 $\bullet$	94.3 $\pm$ 1.0 $\bullet$	94.5 $\pm$ 0.8 $\bullet$	94.7$\pm$0.9
<i>vehicle</i>	95.5 $\pm$ 1.2 $\bullet$	94.0 $\pm$ 1.3 $\bullet$	95.9 $\pm$ 1.1 $\bullet$	94.9 $\pm$ 2.0 $\bullet$	56.6 $\pm$ 16.0 $\bullet$	95.7 $\pm$ 1.1 $\bullet$	96.0 $\pm$ 1.0 $\bullet$	96.2$\pm$1.1
<i>wdbc</i>	95.9 $\pm$ 1.5 $\bullet$	92.7 $\pm$ 1.9 $\bullet$	94.7 $\pm$ 1.6 $\bullet$	94.5 $\pm$ 1.5 $\bullet$	62.3 $\pm$ 2.0 $\bullet$	96.8 $\pm$ 0.9	96.8 $\pm$ 1.0 $\bullet$	96.9$\pm$1.0
<i>isolet</i>	99.4 $\pm$ 0.4 $\bullet$	97.8 $\pm$ 1.3 $\bullet$	99.3 $\pm$ 0.4 $\bullet$	99.7 $\pm$ 0.3 $\bullet$	62.1 $\pm$ 20.7 $\bullet$	99.5 $\pm$ 0.3 $\bullet$	99.7 $\pm$ 0.3 $\bullet$	99.8$\pm$0.3
<i>credit-a</i>	86.4 $\pm$ 1.2 $\bullet$	86.4 $\pm$ 1.2 $\bullet$	86.4 $\pm$ 1.2 $\bullet$	86.2 $\pm$ 1.3 $\bullet$	59.6 $\pm$ 6.3 $\bullet$	86.2 $\pm$ 1.2 $\bullet$	86.4 $\pm$ 1.2 $\bullet$	86.5$\pm$1.2
<i>breastw</i>	96.7 $\pm$ 0.7	95.4 $\pm$ 0.8 $\bullet$	95.3 $\pm$ 0.9 $\bullet$	90.6 $\pm$ 2.9 $\bullet$	35.0 $\pm$ 2.1 $\bullet$	96.6 $\pm$ 0.8	96.9$\pm$0.8$\circ$	96.8 $\pm$ 0.7
<i>austra</i>	85.6 $\pm$ 1.4 $\bullet$	85.6 $\pm$ 1.3 $\bullet$	85.7 $\pm$ 1.4 $\bullet$	85.5 $\pm$ 1.4 $\bullet$	56.7 $\pm$ 4.4 $\bullet$	85.8 $\pm$ 1.3 $\bullet$	86.0 $\pm$ 1.4 $\bullet$	86.4$\pm$1.5
<i>australian</i>	85.8 $\pm$ 1.5 $\bullet$	86.1 $\pm$ 1.7 $\bullet$	86.6 $\pm$ 1.5 $\bullet$	84.8 $\pm$ 1.4 $\bullet$	57.6 $\pm$ 4.9 $\bullet$	86.2 $\pm$ 1.6 $\bullet$	86.0 $\pm$ 1.4 $\bullet$	86.7$\pm$1.5
<i>diabetes</i>	65.6 $\pm$ 1.9 $\bullet$	65.6 $\pm$ 1.9 $\bullet$	77.2 $\pm$ 1.4	76.7 $\pm$ 1.6 $\bullet$	65.6 $\pm$ 1.9 $\bullet$	76.1 $\pm$ 1.7 $\bullet$	77.4 $\pm$ 1.6 $\bullet$	77.4$\pm$1.7
<i>fourclass</i>	76.7 $\pm$ 1.9 $\bullet$	71.5 $\pm$ 5.7 $\bullet$	76.6 $\pm$ 1.2 $\bullet$	76.6 $\pm$ 1.3 $\bullet$	64.1 $\pm$ 2.0 $\bullet$	73.6 $\pm$ 1.4 $\bullet$	77.9$\pm$1.0$\circ$	77.7 $\pm$ 1.1
<i>tic-tac-to</i>	64.9 $\pm$ 1.2 $\bullet$	64.9 $\pm$ 1.2 $\bullet$	64.9 $\pm$ 1.2 $\bullet$	63.9 $\pm$ 5.5 $\bullet$	64.9 $\pm$ 1.2 $\bullet$	57.9 $\pm$ 2.1 $\bullet$	65.0 $\pm$ 1.8 $\bullet$	66.4$\pm$1.6
<i>credit-g</i>	75.1 $\pm$ 1.6	70.8 $\pm$ 1.9 $\bullet$	74.8 $\pm$ 1.6 $\bullet$	74.9 $\pm$ 1.5	70.0 $\pm$ 1.2 $\bullet$	73.3 $\pm$ 1.8 $\bullet$	74.9 $\pm$ 1.6 $\bullet$	75.2$\pm$1.6
<i>german</i>	73.7 $\pm$ 1.4 $\bullet$	70.8 $\pm$ 2.2 $\bullet$	73.9 $\pm$ 1.4 $\bullet$	74.1 $\pm$ 1.5	69.7 $\pm$ 1.7 $\bullet$	72.9 $\pm$ 1.7 $\bullet$	74.3 $\pm$ 1.4	74.4$\pm$1.2
<i>optdigits</i>	99.7 $\pm$ 0.2 $\bullet$	99.6 $\pm$ 0.2 $\bullet$	99.7 $\pm$ 0.2 $\bullet$	99.7 $\pm$ 0.2 $\bullet$	74.3 $\pm$ 20.4 $\bullet$	99.7 $\pm$ 0.2 $\bullet$	99.8 $\pm$ 0.2 $\bullet$	99.9$\pm$0.2
<i>svmguide3</i>	73.7 $\pm$ 1.3 $\bullet$	78.5 $\pm$ 1.8 $\bullet$	73.9 $\pm$ 1.4 $\bullet$	79.0 $\pm$ 2.0 $\bullet$	73.7 $\pm$ 1.3 $\bullet$	78.8 $\pm$ 1.6 $\bullet$	82.0$\pm$1.5$\circ$	81.6 $\pm$ 1.3
平均精度	81.2	79.5	81.4	80.6	65.4	81.3	82.7	83.1
平均排名	4.61	5.42	4.55	5.24	7.55	4.68	2.55	1.39
最好次数	0	2	0	0	0	1	8	27
ODM: 胜/平/负	28/10/0	30/8/0	31/7/0	29/9/0	36/2/0	29/8/1	19/14/5	

表 2.3: 常规数据集上的性能 (均值 $\pm$ 标准差); 所有方法均采用高斯核; 每个数据集上的最好结果加粗显示; $\bullet/\circ$ 表示在 95% 置信度的成对 t -检验下, ODM 的泛化性能显著好于/差于对比方法; MDO 因是专门为线性核设计, 不参与本次实验

数据集	SVM	SVR	LSSVM	MAMC	KMOMD	ODM ^L	ODM
<i>duke</i>	84.2 $\pm$ 8.2 $\bullet$	84.2 $\pm$ 8.2 $\bullet$	81.7 $\pm$ 9.7 $\bullet$	71.8 $\pm$ 11.1 $\bullet$	74.4 $\pm$ 14.7 $\bullet$	85.3 $\pm$ 7.9	85.6$\pm$8.2
<i>colon-canc</i>	80.9 $\pm$ 10.9	78.4 $\pm$ 7.7 $\bullet$	78.5 $\pm$ 8.1 $\bullet$	63.7 $\pm$ 7.2 $\bullet$	77.0 $\pm$ 8.5 $\bullet$	83.3$\pm$5.3	82.7 $\pm$ 6.3
<i>echocardio</i>	61.1 $\pm$ 7.3 $\bullet$	70.8 $\pm$ 6.3 $\bullet$	73.2 $\pm$ 6.5	71.0 $\pm$ 5.7 $\bullet$	67.4 $\pm$ 6.1 $\bullet$	74.0 $\pm$ 6.0	74.4$\pm$6.7
<i>dbworld</i>	86.4 $\pm$ 5.2 $\bullet$	86.4 $\pm$ 5.2 $\bullet$	85.7 $\pm$ 5.5 $\bullet$	58.6 $\pm$ 12.1 $\bullet$	57.2 $\pm$ 14.3 $\bullet$	87.2 $\pm$ 5.9	87.6$\pm$4.3
<i>leu</i>	93.9 $\pm$ 6.1	93.3 $\pm$ 6.3 $\bullet$	92.9 $\pm$ 6.4 $\bullet$	68.0 $\pm$ 8.6 $\bullet$	86.6 $\pm$ 10.0 $\bullet$	95.0$\pm$5.5	94.6 $\pm$ 5.6
<i>balloons</i>	70.0 $\pm$ 6.1 $\bullet$	66.6 $\pm$ 7.1 $\bullet$	71.6 $\pm$ 5.3 $\bullet$	72.1 $\pm$ 5.6 $\bullet$	67.0 $\pm$ 7.5 $\bullet$	73.2 $\pm$ 4.9 $\bullet$	75.1$\pm$4.5
<i>hepatitis</i>	82.6 $\pm$ 3.1 $\bullet$	83.0 $\pm$ 3.5	83.0 $\pm$ 3.3	82.6 $\pm$ 3.1 $\bullet$	84.2$\pm$4.3	84.0 $\pm$ 4.0	84.2 $\pm$ 3.9
<i>promoters</i>	71.5 $\pm$ 6.7 $\bullet$	72.1 $\pm$ 6.5 $\bullet$	71.3 $\pm$ 6.4 $\bullet$	66.6 $\pm$ 11.1 $\bullet$	70.6 $\pm$ 6.4 $\bullet$	73.8 $\pm$ 6.5	74.7$\pm$5.4
<i>colic</i>	81.1 $\pm$ 3.9 $\bullet$	84.1$\pm$2.4	82.6 $\pm$ 3.0 $\bullet$	82.6 $\pm$ 2.6 $\bullet$	82.6 $\pm$ 3.6 $\bullet$	83.8 $\pm$ 2.8	84.1 $\pm$ 2.4
<i>parkinsons</i>	88.7 $\pm$ 2.7 $\bullet$	90.0 $\pm$ 3.1 $\bullet$	89.7 $\pm$ 3.4 $\bullet$	92.5 $\pm$ 2.8 $\bullet$	84.7 $\pm$ 2.6 $\bullet$	89.2 $\pm$ 2.4 $\bullet$	93.5$\pm$2.8
<i>colic.ORIG</i>	64.1 $\pm$ 4.1	61.4 $\pm$ 4.3 $\bullet$	63.5 $\pm$ 3.5 $\bullet$	62.5 $\pm$ 4.0 $\bullet$	62.6 $\pm$ 4.0 $\bullet$	64.2 $\pm$ 4.1	65.2$\pm$3.8
<i>sonar</i>	78.3 $\pm$ 3.0 $\bullet$	55.2 $\pm$ 7.4 $\bullet$	73.8 $\pm$ 3.6 $\bullet$	50.7 $\pm$ 4.3 $\bullet$	71.4 $\pm$ 4.2 $\bullet$	85.7 $\pm$ 3.6	85.8$\pm$3.6
<i>house</i>	95.9 $\pm$ 1.7 $\bullet$	96.8$\pm$1.1	96.8 $\pm$ 1.1	56.1 $\pm$ 13.9 $\bullet$	93.4 $\pm$ 2.7 $\bullet$	96.8 $\pm$ 1.1	96.8 $\pm$ 1.1
<i>vote</i>	95.7 $\pm$ 1.6 $\bullet$	97.0$\pm$1.3	97.0 $\pm$ 1.3	54.7 $\pm$ 12.3 $\bullet$	93.7 $\pm$ 3.0 $\bullet$	97.0 $\pm$ 1.3	97.0 $\pm$ 1.3
<i>heart-h</i>	80.4 $\pm$ 2.8 $\bullet$	79.4 $\pm$ 2.6 $\bullet$	80.7 $\pm$ 2.6 $\bullet$	79.7 $\pm$ 2.9 $\bullet$	80.4 $\pm$ 3.2 $\bullet$	80.9 $\pm$ 2.8	81.3$\pm$2.3
<i>heart</i>	82.6 $\pm$ 2.7 $\bullet$	82.1 $\pm$ 3.1 $\bullet$	83.7 $\pm$ 2.3	79.9 $\pm$ 5.1 $\bullet$	82.9 $\pm$ 2.9 $\bullet$	83.4 $\pm$ 2.3	83.9$\pm$2.3
<i>heart-stat</i>	82.8 $\pm$ 2.9 $\bullet$	81.5 $\pm$ 3.4 $\bullet$	83.0 $\pm$ 2.7 $\bullet$	82.6 $\pm$ 2.7 $\bullet$	80.8 $\pm$ 3.5 $\bullet$	84.0$\pm$2.5	83.8 $\pm$ 2.5
<i>breast</i>	72.9 $\pm$ 2.9 $\bullet$	73.3 $\pm$ 2.4 $\bullet$	75.0 $\pm$ 2.9 $\bullet$	74.3 $\pm$ 2.3 $\bullet$	70.6 $\pm$ 2.6 $\bullet$	73.0 $\pm$ 2.8 $\bullet$	75.5$\pm$2.7
<i>cylinder-b</i>	73.8 $\pm$ 3.6 $\bullet$	74.1 $\pm$ 3.8 $\bullet$	73.9 $\pm$ 3.8 $\bullet$	69.8 $\pm$ 3.3 $\bullet$	71.9 $\pm$ 4.1 $\bullet$	74.4 $\pm$ 3.6 $\bullet$	75.4$\pm$3.0
<i>heart-c</i>	79.6 $\pm$ 2.9 $\bullet$	79.7 $\pm$ 2.6 $\bullet$	80.2 $\pm$ 2.9 $\bullet$	78.7 $\pm$ 2.2 $\bullet$	79.2 $\pm$ 2.5 $\bullet$	80.3 $\pm$ 2.5	80.9$\pm$2.7
<i>haberman</i>	74.2 $\pm$ 2.1	73.7 $\pm$ 2.0 $\bullet$	72.0 $\pm$ 3.1 $\bullet$	74.2 $\pm$ 2.1	73.6 $\pm$ 2.2	74.2 $\pm$ 2.2	74.2$\pm$2.2
<i>vertebral-</i>	78.6 $\pm$ 3.0 $\bullet$	78.2 $\pm$ 2.8 $\bullet$	78.9 $\pm$ 2.5 $\bullet$	77.3 $\pm$ 3.0 $\bullet$	76.9 $\pm$ 3.1 $\bullet$	85.6$\pm$1.9	85.5 $\pm$ 2.1
<i>liverDisor</i>	71.8 $\pm$ 3.2	69.2 $\pm$ 3.5 $\bullet$	71.4 $\pm$ 3.3 $\bullet$	61.3 $\pm$ 3.9 $\bullet$	70.0 $\pm$ 4.6 $\bullet$	72.1 $\pm$ 3.2	72.3$\pm$3.1
<i>house-vote</i>	94.7 $\pm$ 1.2 $\bullet$	93.6 $\pm$ 1.1 $\bullet$	93.9 $\pm$ 1.0 $\bullet$	60.6 $\pm$ 2.3 $\bullet$	91.4 $\pm$ 2.4 $\bullet$	94.8 $\pm$ 1.2 $\bullet$	95.1$\pm$1.2
<i>vehicle</i>	98.8 $\pm$ 0.8 $\bullet$	98.8 $\pm$ 0.7 $\bullet$	99.1 $\pm$ 0.7 $\bullet$	49.6 $\pm$ 8.0 $\bullet$	98.8 $\pm$ 0.8 $\bullet$	99.0 $\pm$ 0.8 $\bullet$	99.4$\pm$0.6
<i>wdbc</i>	97.1 $\pm$ 1.1	95.3 $\pm$ 1.1 $\bullet$	96.4 $\pm$ 1.2 $\bullet$	92.9 $\pm$ 1.5 $\bullet$	94.5 $\pm$ 2.4 $\bullet$	97.2 $\pm$ 1.0	97.4$\pm$1.0
<i>isolet</i>	99.6 $\pm$ 0.3 $\bullet$	99.8 $\pm$ 0.3	99.6 $\pm$ 0.5 $\bullet$	99.3 $\pm$ 0.5 $\bullet$	99.6 $\pm$ 0.3 $\bullet$	99.8 $\pm$ 0.2	99.9$\pm$0.2
<i>credit-a</i>	86.4 $\pm$ 1.2 $\bullet$	86.4 $\pm$ 1.2 $\bullet$	86.4 $\pm$ 1.2	86.1 $\pm$ 1.5	83.9 $\pm$ 2.8 $\bullet$	86.4 $\pm$ 1.2 $\bullet$	86.5$\pm$1.4
<i>breastw</i>	96.7 $\pm$ 0.9 $\bullet$	96.6 $\pm$ 0.7 $\bullet$	96.8 $\pm$ 0.7 $\bullet$	96.1 $\pm$ 0.7 $\bullet$	97.3$\pm$0.6$\circ$	96.9 $\pm$ 1.1	97.0 $\pm$ 0.7
<i>austra</i>	85.7 $\pm$ 1.3 $\bullet$	84.9 $\pm$ 1.9 $\bullet$	85.2 $\pm$ 2.0 $\bullet$	83.4 $\pm$ 1.7 $\bullet$	85.1 $\pm$ 1.8 $\bullet$	86.3$\pm$1.4	86.2 $\pm$ 1.4
<i>australian</i>	85.8 $\pm$ 1.5 $\bullet$	85.8 $\pm$ 1.5 $\bullet$	86.3 $\pm$ 1.7	85.1 $\pm$ 1.5 $\bullet$	86.0 $\pm$ 1.6 $\bullet$	86.0 $\pm$ 1.4 $\bullet$	86.8$\pm$1.3
<i>diabetes</i>	77.4 $\pm$ 1.4 $\bullet$	76.6 $\pm$ 1.8 $\bullet$	77.0 $\pm$ 1.6 $\bullet$	73.1 $\pm$ 1.6 $\bullet$	73.8 $\pm$ 3.4 $\bullet$	77.4 $\pm$ 1.3 $\bullet$	77.8$\pm$1.7
<i>fourclass</i>	99.8 $\pm$ 0.3 $\bullet$	99.8 $\pm$ 0.3 $\bullet$	99.9 $\pm$ 0.1 $\bullet$	99.9 $\pm$ 0.1 $\bullet$	99.7 $\pm$ 0.3 $\bullet$	99.9 $\pm$ 0.1 $\bullet$	100.0$\pm$0.0
<i>tic-tac-to</i>	98.2 $\pm$ 0.4	98.2 $\pm$ 0.4	98.2 $\pm$ 0.4	82.4 $\pm$ 1.2 $\bullet$	78.6 $\pm$ 2.4 $\bullet$	98.2 $\pm$ 0.4	98.4$\pm$0.6
<i>credit-g</i>	75.3 $\pm$ 1.8 $\bullet$	74.4 $\pm$ 1.5 $\bullet$	75.5 $\pm$ 1.5 $\bullet$	72.7 $\pm$ 1.5 $\bullet$	74.8 $\pm$ 2.0 $\bullet$	75.3 $\pm$ 1.7 $\bullet$	75.8$\pm$1.4
<i>german</i>	74.2 $\pm$ 1.5 $\bullet$	74.6 $\pm$ 1.4 $\bullet$	75.0 $\pm$ 1.2	72.0 $\pm$ 1.6 $\bullet$	74.6 $\pm$ 1.7 $\bullet$	74.3 $\pm$ 1.3 $\bullet$	75.1$\pm$1.2
<i>optdigits</i>	99.9 $\pm$ 0.2 $\bullet$	99.9 $\pm$ 0.1 $\bullet$	99.9 $\pm$ 0.1	49.1 $\pm$ 0.8 $\bullet$	99.8 $\pm$ 0.2 $\bullet$	99.9 $\pm$ 0.2 $\bullet$	99.9$\pm$0.1
<i>svmguide3</i>	82.5 $\pm$ 1.5 $\bullet$	81.0 $\pm$ 1.7 $\bullet$	82.5 $\pm$ 1.5 $\bullet$	78.2 $\pm$ 1.2 $\bullet$	78.3 $\pm$ 1.4 $\bullet$	82.7 $\pm$ 1.4	83.1$\pm$0.9
平均精度	83.8	83.1	84.0	74.0	80.9	85.1	85.6
平均排名	4.26	4.53	3.58	6.11	5.58	2.58	1.37
最好次数	0	3	0	0	2	5	28
ODM: 胜/平/负	31/7/0	32/6/0	28/10/0	36/2/0	35/2/1	13/25/0	

表 2.4: 大规模数据集上的性能 (均值 $\pm$ 标准差); 所有方法均采用线性核; 每个数据集上的最好结果加粗显示; $\bullet/\circ$ 表示在 95% 置信度的成对 t -检验下, ODM 的泛化性能显著好于/差于对比方法; LSSVM 和 KMOMD 因缺乏专门为大规模数据集设计的软件包, 在部分数据集上无法在 48 小时内输出结果

数据集	SVM	SVR	LSSVM	MDO	MAMC	KMOMD	ODM ^L	ODM
<i>farm-ads</i>	88.6 $\pm$ 0.6 $\bullet$	88.6 $\pm$ 0.5 $\bullet$	89.0 $\pm$ 0.7	88.0 $\pm$ 0.7 $\bullet$	75.9 $\pm$ 3.9 $\bullet$	88.9 $\pm$ 0.8	89.4$\pm$0.8$\circ$	89.2 $\pm$ 0.6
<i>gisette</i>	97.0 $\pm$ 0.3 $\bullet$	97.0 $\pm$ 0.4 $\bullet$	97.5 $\pm$ 0.3	96.9 $\pm$ 0.3 $\bullet$	70.8 $\pm$ 6.5 $\bullet$	97.0 $\pm$ 0.3 $\bullet$	97.5 $\pm$ 0.2	97.5$\pm$0.3
<i>svmguide1</i>	89.8 $\pm$ 0.3 $\bullet$	82.8 $\pm$ 3.4 $\bullet$	90.5 $\pm$ 0.4 $\bullet$	95.1 $\pm$ 0.1 $\bullet$	56.2 $\pm$ 0.4 $\bullet$	95.6$\pm$0.2	95.4 $\pm$ 0.2	95.5 $\pm$ 0.2
<i>magic04</i>	79.2 $\pm$ 0.3	77.0 $\pm$ 0.8 $\bullet$	78.4 $\pm$ 0.3 $\bullet$	79.2$\pm$0.3	64.9 $\pm$ 0.3 $\bullet$	78.8 $\pm$ 0.4 $\bullet$	79.0 $\pm$ 0.3	79.2 $\pm$ 0.3
<i>news20</i>	95.4 $\pm$ 0.1 $\bullet$	95.4 $\pm$ 0.1 $\bullet$	95.6 $\pm$ 0.2	94.9 $\pm$ 0.3 $\bullet$	77.2 $\pm$ 1.7 $\bullet$	95.5 $\pm$ 0.2	95.5 $\pm$ 0.2 $\bullet$	95.6$\pm$0.2
<i>adult-a</i>	84.5 $\pm$ 0.2 $\bullet$	80.5 $\pm$ 0.5 $\bullet$	N/A	84.5 $\pm$ 0.2 $\bullet$	75.9 $\pm$ 0.2 $\bullet$	N/A	84.6 $\pm$ 0.2	84.6$\pm$0.2
<i>w8a</i>	97.1 $\pm$ 0.1 $\bullet$	89.0 $\pm$ 0.2 $\bullet$	N/A	98.6 $\pm$ 0.1	88.9 $\pm$ 0.2 $\bullet$	N/A	98.6 $\pm$ 0.1	98.6$\pm$0.0
<i>cod-rna</i>	89.9 $\pm$ 0.1 $\bullet$	88.6 $\pm$ 1.0 $\bullet$	N/A	93.8$\pm$0.1$\circ$	66.7 $\pm$ 0.1 $\bullet$	N/A	93.7 $\pm$ 0.1 $\bullet$	93.8 $\pm$ 0.1
<i>real-sim</i>	96.2 $\pm$ 0.1 $\bullet$	96.1 $\pm$ 0.1 $\bullet$	N/A	96.8 $\pm$ 0.1 $\bullet$	74.2 $\pm$ 0.4 $\bullet$	N/A	97.2 $\pm$ 0.1 $\bullet$	97.2$\pm$0.1
<i>mini-boo-ne</i>	86.1 $\pm$ 0.6 $\bullet$	81.7 $\pm$ 2.2 $\bullet$	N/A	84.6 $\pm$ 0.1 $\bullet$	72.0 $\pm$ 0.1 $\bullet$	N/A	85.3 $\pm$ 0.1 $\bullet$	90.6$\pm$0.1
<i>rcv1</i>	97.7 $\pm$ 0.0 $\bullet$	97.1 $\pm$ 0.0 $\bullet$	N/A	97.7 $\pm$ 0.0 $\bullet$	91.3 $\pm$ 0.0 $\bullet$	N/A	97.8 $\pm$ 0.0 $\bullet$	97.8$\pm$0.0
<i>url</i>	99.3 $\pm$ 0.0 $\bullet$	99.2 $\pm$ 0.0 $\bullet$	N/A	99.3 $\pm$ 0.0 $\bullet$	67.0 $\pm$ 0.0 $\bullet$	N/A	99.1 $\pm$ 0.0 $\bullet$	99.3$\pm$0.0
平均排名	4.08	5.42	3.80	3.75	6.83	3.60	2.67	1.42
最好次数	0	0	0	2	0	1	1	8
ODM: 胜/平/负	11/1/0	12/0/0	9/3/0	9/2/1	12/0/0	9/3/0	6/5/1	

度、平均排名、取得最好性能的次数以及成对 t -检验下 ODM 胜/平/负的次数在最后四行。不难看出, 很多时候 ODM 的泛化性能都显著好于对比方法, 至少也是相当的, 几乎不会出现退化的情况。具体来说, 在 38 个数据集上, ODM 显著好于 SVM/SVR/LSSVM/MDO/MAMC/KMOMD/ODM^L 的次数分别是 28/30/31/29/36/29/19 次, 并且在 27 个数据集上取得最好性能。

表 2.3 展示了在使用高斯核的情况下, 所有算法在 38 个常规数据集上的性能 (均值 $\pm$ 标准差), MDO 因为是专门为线性核设计的, 因此无法参与本实验。不难看出, ODM 的泛化性能依然显著好于对比方法。具体来说, 在 38 个数据集上, ODM 显著好于 SVM/SVR/LSSVM/MAMC/KMOMD/ODM^L 的次数分别是 31/32/28/36/35/13 次, 并且在 28 个数据集上取得最好性能。

表 2.4 展示了在使用线性核的情况下, 所有算法在 12 个大规模数据集上的性能 (均值 $\pm$ 标准差)。LSSVM 和 KMOMD 因为缺乏专门为大规模数据集设计的软件包, 因此在部分数据集上无法在 48 小时内输出结果。不难看出, ODM 依然取得了很好的泛化性能, 在 12 个数据集上, 依次显著好于 SVM/SVR/LSSVM/MDO/MAMC/KMOMD/ODM^L 的次数分别为 11/12/9/9/12/9/6, 并且在 8 个数据集上取得最好性能。

2.4.3 间隔分布

图 2.2 展示了在数据集 `german` 上, SVM、 ODM^L 和 ODM 最终输出的间隔分布的频度直方图。可以看出, 相比于 ODM^L 和 ODM, SVM 确实得到了更大的最小间隔, 这是它的优化目标所致。我们所提的两个方法, 得到的最小间隔虽然比 SVM 的要小, 但是整体来说, 间隔较小 (例如 < 0) 的样本总数要少于 SVM, 间隔较大 (例如 > 0.5) 的样本总数要多于 SVM, 因此我们的方法有更好的间隔分布, 也从而有更好的泛化性能和鲁棒性。在其他数据集上也有与图 2.2 类似的结果。




图 2.2: SVM、 ODM^L 和 ODM 在数据集 `german` 上最终输出的间隔分布的频度直方图, ODM^L 和 ODM 得到的最小间隔虽然比 SVM 要小, 但是间隔分布要显著好于 SVM

图 2.3 展示了在数据集 `austra`、`heart-statlog`、`german`、`australian` 上, SVM、 ODM^L 和 ODM 最终输出的间隔的累积频率曲线。可以看出, ODM^L 和 ODM 的曲线总体位于 SVM 的右侧, 如果固定一个值 $t \in [0, u]$, 其中 u 是三条曲线都达到 1 的横坐标, 即画一条竖直线 $x = t$ 与三条曲线相交, SVM 的交点总是在最上面, 这表明我们的方法总是可以使得更多的样本的间隔大于 t , 这也与图 2.2 相一致, 即我们的方法总是输出更好的间隔分布。在其他数据集上的结果或多或少都与图 2.3 类似, 因此不一一列举了。

2.4.4 时间开销

本节我们对比 SVM、 ODM^L 和 ODM 在 12 个大规模数据集上的时间开销。所有实验都是在同一台拥有 2.6G 赫兹主频 *8 核 CPU、32GB 主存的服




图 2.3: SVM、 ODM^L 和 ODM 在数据集 **austra**、**heart-statlog**、**german**、**australian** 上最终输出的间隔的累积频率曲线，任取一根竖直线 $x = t$ 与曲线相交，交点的纵坐标表明间隔小于 t 的样本占整个数据集的比例

务器上进行，求解的软件是 MATLAB (2012b)。每个数据集的平均时间开销（单位：秒）如图 2.4 所示。记 LIBLINEAR 软件包^[30]实现的 SVM 为 SVM_l ，记 SGD 软件包^①现的 SVM 为 SVM_s 。可以看出， SVM_s 和我们的方法都快于 SVM_l ，这要归功于 SGD 的速度。 ODM^L 和 ODM 仅仅在 2 个数据集上（**w8a** 和 **cod-rna**）上稍慢于 SVM_s ，其他数据集上都是相当的。注意 SVM_l 和 SVM_s 都是 SVM 非常成熟和高效的实现，因此可以说我们的方法在计算开销上还是可接受的。

2.5 小结

本文提出了面向二分类问题的最优间隔分布学习机 ODM，通过将任务形式化为最大化间隔均值同时最小化间隔方差来优化间隔分布，并提出一种基于对偶坐标下降的方法进行求解。对于大规模数据集，本文提出了基于 SVRG 的

^①<http://leon.bottou.org/projects/sgd>




图 2.4: SVM、ODM^L 和 ODM 在 12 个大规模数据集上的时间开销

加速算法。最终实验表明 ODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的传统大间隔方法。在以后的工作中，值得研究的问题包括在只利用相同信息的条件下，如何推出基于间隔分布的更紧的泛化界。

本章的主要工作已总结成文：

- T. Zhang and Z.-H. Zhou. Large margin distribution machine. In: **Proceedings of the 20th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD'14)**, New York, NY, 2014, pp.313-322. (CCF A 类会议)
- T. Zhang and Z.-H. Zhou. Optimal Margin Distribution Machine. **IEEE Transactions on Knowledge and Data Engineering (TKDE)**, in press. (CCF A 类期刊)

第三章 多分类最优间隔

分布学习机

3.1 引言

上一章讨论的是二分类问题，但现实世界中更常遇见的是多分类问题，此时专门为二分类问题设计的学习算法就用不了了。这时有两个策略可以选择：一是将多分类问题分解为一系列二分类问题，对每个二分类问题训练一个模型，然后将这些二分类模型以某种方式组合起来，从而得到一个解决多分类问题的分类模型；二是利用一些二分类算法的自身特性，直接将其推广到多分类。

不失一般性，记特征空间为 $\mathcal{X}$ ，类别标记集合 $\mathcal{Y} = \{1, \dots, k\}$ ，简记为 $\mathcal{Y} = [k]$ ，基于分解的策略大致有如下三种：

第一种是“一对其余”（One vs. Rest，简称 OvR）。每次将一个类别的样本作为正类，其他类别的样本作为负类，这样可依次训练得到 k 个二分类模型 $h_1, \dots, h_k$ 。在测试时，将未知样本同时提交给所有的二分类模型，若仅有一个预测为正类，则预测的类别标记就是该二分类模型的下标；若有多个同时预测为正类，通常考虑它们各自的预测置信度，选择置信度最大的下标作为分类结果，即 $f(\mathbf{x}) = \arg \max_l h_l(\mathbf{x})$ 。

第二种是“一对一”（One vs. One，简称 OvO）^[117]。将 k 个类别两两配对，例如为了区分第 i 类和第 j 类，就将第 i 类的样本作为正类，第 j 类的样本作为负类，训练一个对应的二分类模型 h_{ij} ，这样总共可以产生 $k(k-1)/2$ 个二分类问题。在测试时，将未知样本同时提交给所有的二分类模型，从而得到 $k(k-1)/2$ 个分类结果，最终结果通过投票产生，被预测次数最多的类别就是最终的分

第三种是“纠错输出码”（Error Correcting Output Code，简称 ECOC）^[24]。OvR 和 OvO 分别构造了 k 个和 $k(k-1)/2$ 个二分类问题。事实上，除此之外还可以构造很多二分类问题，例如将第 1 类和第 2 类样本当作正类，其余 $k-2$ 类

样本当作负类；或者把奇数类样本当作正类，把偶数类样本当作负类。这样就得到一种更一般的多对多分解策略 ECOC，每次选择若干个类别的样本作为正类，再选择若干个其他类别的样本作为负类，OvR 和 OvO 都可以看作该策略的特例。

以识别 0 到 9 这十个数字的十分类问题为例^[159]，按数字是否包含竖直线、是否包含水平线、是否包含斜线、是否包含闭合圈、是否左开口、是否右开口，可以得到 6 个二分类问题。如表 3.1 所示，一行对应一个问题，+1 表示在该问题上，当前类别的样本被当作正类，-1 则表示被当作负类。例如数字 1、4、5 含有竖直线，因此第一行在是否包含竖直线这个问题上，类别 1、4、5 的取值为 +1，其余为 -1，其他行同理。

表 3.1: 数字识别问题的纠错输出码

类别	0	1	2	3	4	5	6	7	8	9
竖直线	-1	+1	-1	-1	+1	+1	-1	-1	-1	-1
水平线	-1	-1	+1	-1	+1	+1	-1	+1	-1	-1
斜线	-1	-1	+1	-1	-1	-1	+1	+1	-1	+1
闭合圈	+1	-1	-1	-1	-1	-1	+1	-1	+1	+1
左开口	-1	-1	+1	+1	-1	+1	-1	+1	-1	+1
右开口	-1	-1	-1	-1	+1	-1	+1	-1	-1	-1

由于总共构造了 6 个二分类问题，因此每个类别对应一个长度为 6 的编码向量，例如对于类别 0，其编码向量为 $\mathbf{c}_0 = [-1, -1, -1, +1, -1, -1]$ ，即表 3.1 中的第一列，该编码向量可以看做类别的“高层特征”，或者说是“签名”。假设对这 6 个问题，依次训练好 6 个二分类模型 $h_1, \dots, h_6$ 。测试时只需将未知样本 $\mathbf{x}$ 同时提交给 6 个模型，就可以得到向量 $\mathbf{p}_x = [h_1(\mathbf{x}), \dots, h_6(\mathbf{x})]$ ，之后计算 $\mathbf{p}_x$ 与所有签名的汉明距离（Hamming distance），选择距离最小的类别作为最终分类结果即可。假设有一个 h_i 犯错误了，其他的 $h_{j \neq i}$ 都是正确的，那么 $\mathbf{p}_x$ 与真实类别的签名的汉明距离就是 2，但只要各个类别的签名间的汉明距离够大，依然可以进行正确分类，这也是算法名字的由来，即对分类器有一定的容错和修正能力。

表 3.1 属于二元 ECOC，除此之外还有三元 ECOC，除了 $\{+1, -1\}$ 外，还允许部分元素取零，即在某个构造的二分类问题上，有些类别既不作为正类，也不作为负类出现。

OvR 和 OvO 的最大缺陷是不能对整个特征空间作完整的划分，即存在一些区域，无法对它们进行分类。例如对于 OvR，可能存在一些样本，所有的 k 个二分类模型都将其分作负类；而对于 OvO，则可能存在多个类别被预测的次数一样多。ECOC 的性能非常依赖于编码的设计，理论上来说任两个类别之间的汉明距离越远，纠错能力越强，然而据此设计最优编码是个 NP 难的问题，编码长度稍大一些就难以有效地确定最优编码。另外，编码的理论性质好也不能保证最终分类性能就一定好，因为这还牵扯到一些其他因素，例如纠错性质好的编码可能导出的二分类问题较难，致使只能学得分类精度不高的二分类模型，这又反过来影响了纠错能力。

这三种基于分解的策略往往要训练大量的二分类模型，计算开销很大，超参数的调节也是个大麻烦。另一方面，也有些不依赖分解策略，直接推广二分类算法的方法，以统计学习为例^[20,21,65,85,126,130]，它们尝试同时学习 k 个打分函数 $\mathbf{w}_1^\top \phi(\mathbf{x}), \dots, \mathbf{w}_k^\top \phi(\mathbf{x})$ 。

对于第 i 类和第 j 类，显然介于两类间的垂直平分线 $\mathbf{w}_i^\top \phi(\mathbf{x}) - \mathbf{w}_j^\top \phi(\mathbf{x}) = 0$ 可以当做划分超平面。假设数据集线性可分，则对于第 i 类样本 $\bar{\mathbf{x}}$ ，存在如下的 γ -间隔划分超平面

$$\mathbf{w}_i^\top \phi(\bar{\mathbf{x}}) - \mathbf{w}_j^\top \phi(\bar{\mathbf{x}}) \geq \gamma, \quad \|\mathbf{w}_i - \mathbf{w}_j\| = 1, \quad j \neq i \quad (3.1)$$

将第 i 类样本与其它样本区别开，根据最大间隔准则有

$$\max_{\mathbf{w}_l} \sum_j \frac{1}{\|\mathbf{w}_i - \mathbf{w}_j\|} \quad (3.2)$$

$$\text{s.t.} \quad \mathbf{w}_i^\top \phi(\bar{\mathbf{x}}) - \mathbf{w}_l^\top \phi(\bar{\mathbf{x}}) \geq 1 - \delta_{i,l}, \quad \forall l \in [k] \quad (3.3)$$

其中 $\delta_{i,l}$ 在 $i = l$ 时等于 1，其余时候为零。遍历 i 即可得到如下的优化问题：

$$\max_{\mathbf{w}_l} \sum_{1 \leq i < j \leq k} \frac{1}{\|\mathbf{w}_i - \mathbf{w}_j\|} \quad (3.4)$$

$$\text{s.t.} \quad \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \delta_{y_i,l}, \quad \forall i \in [m], l \in [k] \quad (3.5)$$

注意最大化 $1/\|\mathbf{w}_i - \mathbf{w}_j\|$ 等价于最小化 $\|\mathbf{w}_i - \mathbf{w}_j\|^2$ ，故可将目标函数改写成

$$\min_{\mathbf{w}_l} \sum_{1 \leq i < j \leq k} \|\mathbf{w}_i - \mathbf{w}_j\|^2 \quad (3.6)$$

但即便如此，依然难以直接优化，不妨考虑其上界：

$$\sum_{1 \leq i < j \leq k} \|\mathbf{w}_i - \mathbf{w}_j\|^2 = \frac{1}{2} \sum_{i,j=1}^k \|\mathbf{w}_i - \mathbf{w}_j\|^2 \leq \frac{1}{2} \sum_{i,j=1}^k (\|\mathbf{w}_i\| + \|\mathbf{w}_j\|)^2 \quad (3.7)$$

$$\leq \sum_{i,j=1}^k (\|\mathbf{w}_i\|^2 + \|\mathbf{w}_j\|^2) = \sum_{i,j=1}^k \|\mathbf{w}_i\|^2 + \sum_{i,j=1}^k \|\mathbf{w}_j\|^2 \quad (3.8)$$

$$= 2k \sum_{i=1}^k \|\mathbf{w}_i\|^2 \quad (3.9)$$

则可得到如下的优化问题：

$$\min_{\mathbf{w}_l} \quad \frac{1}{2} \sum_{l=1}^k \|\mathbf{w}_l\|^2 \quad (3.10)$$

$$\text{s.t.} \quad \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \delta_{y_i, l}, \quad \forall i \in [m], l \in [k] \quad (3.11)$$

针对非线性可分的情况，可以引进松弛变量 ξ_i ：

$$\min_{\mathbf{w}_l, \xi_i} \quad \frac{1}{2} \sum_{l=1}^k \|\mathbf{w}_l\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \xi_i \quad (3.12)$$

$$\text{s.t.} \quad \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \delta_{y_i, l} - \xi_i, \quad \forall i \in [m], l \in [k]$$

由于所有的打分函数是同时学习的，因此它们对某个样本的打分可以直接比较。测试阶段只需将未知样本同时提交给所有打分函数，选择打分最高的下标作为分类结果，即 $f(\mathbf{x}) = \arg \max_l \mathbf{w}_l^\top \phi(\mathbf{x})$ 。注意打分最高的函数总是存在的，因此这样做不会出现分解策略中的未定区域的问题。但是它的形式化比单个二分类模型要复杂的多，变量个数、约束个数都大大增加，这需要利用问题的结构精心设计优化算法，一般求解 QP 的通用算法，恐怕难以胜任处理大规模数据集的任务。

3.2 问题形式化

由于基于分解策略的方法有先天缺陷：存在不可判别的区域，且当类别较大时计算开销很大，因此我们采用第二个办法，直接将二分类核 ODM 推广到多分类。

3.2.1 原问题

注意优化问题 (3.12) 的约束 $\mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \delta_{y_i, l} - \xi_i$ 可等价地写为

$$\mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \max_{l \neq y_i} \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (3.13)$$

因此这其实是要求在第 l 类的样本上, $\mathbf{w}_l^\top \phi(\mathbf{x})$ 的打分要尽可能地比其他类别的打分函数的分数都高, 故

$$\gamma(\mathbf{x}_i, y_i) = \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \max_{l \neq y_i} \mathbf{w}_l^\top \phi(\mathbf{x}_i) \quad (3.14)$$

反映了模型对样本 $(\mathbf{x}_i, y_i)$ 的分类置信度, 这个值越大, 置信度越高, 这个值为负, 则分类错误, 因此可将其看成多分类学习任务下间隔的定义。

又二分类核 ODM 的形式化为

$$\min_{\mathbf{w}, \xi_i, \epsilon_i} \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} \quad (3.15)$$

$$\text{s.t.} \quad y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i \quad (3.16)$$

$$y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \quad \forall i \in [m] \quad (3.17)$$

将约束中的二分类间隔 $y_i \mathbf{w}^\top \phi(\mathbf{x}_i)$ 换成多分类的版本, 则可得到多分类核 ODM 的形式化, 不妨记为 mcODM:

$$\begin{aligned} \min_{\mathbf{w}_l, \xi_i, \epsilon_i} \quad & \frac{1}{2} \sum_{l=1}^k \|\mathbf{w}_l\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} \\ \text{s.t.} \quad & \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \max_{l \neq y_i} \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i \\ & \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \max_{l \neq y_i} \mathbf{w}_l^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \quad \forall i \in [m] \end{aligned} \quad (3.18)$$

由于第二个约束中的 $\max$ 操作, 问题 (3.18) 是非凸非平滑优化问题, 很难直接求解, 因此我们先将其放松成一系列凸二次规划。

每一轮, 我们先将第一个约束等价地转换成 $k - 1$ 个线性不等式约束:

$$\mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i, \quad l \neq y_i \quad (3.19)$$

然后将第二个约束用下面这个约束取代：

$$\mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - M_i \leq 1 + \theta + \epsilon_i \quad (3.20)$$

其中 $M_i = \max_{l \neq y_i} \bar{\mathbf{w}}_l^\top \phi(\mathbf{x}_i)$, $\bar{\mathbf{w}}_l$ 是上一轮的解, 这样整个问题就变成一个平滑凸二次规划:

$$\begin{aligned} \min_{\mathbf{w}_l, \xi_i, \epsilon_i} \quad & \frac{1}{2} \sum_{l=1}^k \|\mathbf{w}_l\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} \\ \text{s.t.} \quad & \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \mathbf{w}_l^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i, \quad \forall l \neq y_i \\ & \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - M_i \leq 1 + \theta + \epsilon_i, \quad \forall i \in [m] \end{aligned} \quad (3.21)$$

之后我们重复地解这个问题直到收敛即可。

3.2.2 对偶问题

同样由于核的存在, 优化变量可能是无穷维的, 但约束个数是有限的, 因此我们求其对偶问题。为前 $k - 1$ 个约束引入拉格朗日乘子 $\zeta_i^l \geq 0$, $l \neq y_i$; 为最后一个约束引入拉格朗日乘子 $\beta_i \geq 0$, 于是得到拉格朗日函数:

$$\begin{aligned} L(\mathbf{w}_l, \xi_i, \epsilon_i, \zeta_i^l, \beta_i) \quad & (3.22) \\ = \frac{1}{2} \sum_{l=1}^k \|\mathbf{w}_l\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} - \sum_{i=1}^m \sum_{l \neq y_i} \zeta_i^l (\mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - \mathbf{w}_l^\top \phi(\mathbf{x}_i) - 1 + \theta + \xi_i) \\ + \sum_{i=1}^m \beta_i (\mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) - M_i - 1 - \theta - \epsilon_i) \quad & (3.23) \end{aligned}$$

为了求得对偶函数, 需令拉格朗日函数关于原始优化变量 $\mathbf{w}_l$ 、 ξ_i 、 ϵ_i 取极小, 在此之前需先处理 $\mathbf{w}_{y_i}$, 注意:

$$\sum_{i=1}^m \sum_{l \neq y_i} \zeta_i^l \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) = \sum_{l=1}^k \mathbf{w}_l^\top \left(\sum_{i=1}^m \delta_{y_i, l} \sum_{s \neq y_i} \zeta_i^s \phi(\mathbf{x}_i) \right) \quad (3.24)$$

$$\sum_{i=1}^m \sum_{l \neq y_i} \zeta_i^l \mathbf{w}_l^\top \phi(\mathbf{x}_i) = \sum_{l=1}^k \mathbf{w}_l^\top \left(\sum_{i=1}^m (1 - \delta_{y_i, l}) \zeta_i^l \phi(\mathbf{x}_i) \right) \quad (3.25)$$

$$\sum_{i=1}^m \beta_i \mathbf{w}_{y_i}^\top \phi(\mathbf{x}_i) = \sum_{l=1}^k \mathbf{w}_l^\top \left(\sum_{i=1}^m \delta_{y_i, l} \beta_i \phi(\mathbf{x}_i) \right) \quad (3.26)$$

因此拉格朗日函数可进一步写为:

$$L(\mathbf{w}_l, \xi_i, \epsilon_i, \zeta_i^l, \beta_i) \quad (3.27)$$

$$= \frac{1}{2} \sum_{l=1}^k \|\mathbf{w}_l\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1-\theta)^2} - \sum_{l=1}^k \mathbf{w}_l^\top \left(\sum_{i=1}^m \delta_{y_i, l} \sum_{s \neq y_i} \zeta_i^s \phi(\mathbf{x}_i) \right) \quad (3.28)$$

$$+ \sum_{l=1}^k \mathbf{w}_l^\top \left(\sum_{i=1}^m (1 - \delta_{y_i, l}) \zeta_i^l \phi(\mathbf{x}_i) \right) + \sum_{i=1}^m \sum_{l \neq y_i} \zeta_i^l (1 - \theta - \xi_i) \quad (3.29)$$

$$+ \sum_{l=1}^k \mathbf{w}_l^\top \left(\sum_{i=1}^m \delta_{y_i, l} \beta_i \phi(\mathbf{x}_i) \right) - \sum_{i=1}^m \beta_i (M_i + 1 + \theta + \epsilon_i) \quad (3.30)$$

对 $\mathbf{w}_l$ 、 ξ_i 、 ϵ_i 分别求导并令导数为零可得:

$$\mathbf{w}_l = \sum_{i=1}^m \left(\delta_{y_i, l} \sum_{s \neq y_i} \zeta_i^s - (1 - \delta_{y_i, l}) \zeta_i^l - \delta_{y_i, l} \beta_i \right) \phi(\mathbf{x}_i)$$

$$\xi_i = \frac{m(1-\theta)^2}{2\lambda} \sum_{l \neq y_i} \zeta_i^l \quad (3.31)$$

$$\epsilon_i = \frac{m(1-\theta)^2}{2\lambda\mu} \beta_i \quad (3.32)$$

进一步对 $\forall l \neq y_i$ 定义 $\alpha_i^l = -\zeta_i^l$, 以及 $\alpha_i^{y_i} = \sum_{s \neq y_i} \zeta_i^s$, $\mathbf{w}_l$ 的表达式可简化为

$$\mathbf{w}_l = \sum_{i=1}^m (\alpha_i^l - \delta_{y_i, l} \beta_i) \phi(\mathbf{x}_i) \quad (3.33)$$

将式 (3.31)、式 (3.32) 和式 (3.33) 回代入拉格朗日函数可得对偶函数:

$$g(\alpha_i^l, \alpha_i^{y_i}, \beta_i) = -\frac{1}{2} \sum_{l=1}^k \|\mathbf{w}_l\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2}{(1-\theta)^2} - \sum_{i=1}^m \sum_{l \neq y_i} \zeta_i^l \xi_i + \frac{\lambda\mu}{m} \sum_{i=1}^m \frac{\epsilon_i^2}{(1-\theta)^2}$$

$$- \sum_{i=1}^m \beta_i \epsilon_i + \sum_{i=1}^m \sum_{l \neq y_i} \zeta_i^l (1 - \theta) - \sum_{i=1}^m \beta_i (M_i + 1 + \theta) \quad (3.34)$$

$$= -\frac{1}{2} \sum_{l=1}^k \sum_{i,j=1}^m (\alpha_i^l - \delta_{y_i, l} \beta_i) (\alpha_j^l - \delta_{y_j, l} \beta_j) \kappa(\mathbf{x}_i, \mathbf{x}_j) - \frac{m(1-\theta)^2}{4\lambda} \sum_{i=1}^m (\alpha_i^{y_i})^2$$

$$- \frac{m(1-\theta)^2}{4\lambda\mu} \sum_{i=1}^m \beta_i^2 - (1-\theta) \sum_{i=1}^m \sum_{l \neq y_i} \alpha_i^l - (M_i + 1 + \theta) \sum_{i=1}^m \beta_i \quad (3.35)$$

令对偶函数关于 α_i^l 、 $\alpha_i^{y_i}$ 、 β_i 取极大可得 mcODM 的对偶问题：

$$\begin{aligned}
\min_{\alpha_i^l, \alpha_i^{y_i}, \beta_i} \quad & \frac{1}{2} \sum_{l=1}^k \sum_{i,j=1}^m (\alpha_i^l - \delta_{y_i,l} \beta_i) (\alpha_j^l - \delta_{y_j,l} \beta_j) \kappa(\mathbf{x}_i, \mathbf{x}_j) + \frac{m(1-\theta)^2}{4\lambda} \sum_{i=1}^m (\alpha_i^{y_i})^2 \\
& + \frac{m(1-\theta)^2}{4\lambda\mu} \sum_{i=1}^m \beta_i^2 + (1-\theta) \sum_{i=1}^m \sum_{l \neq y_i} \alpha_i^l + (M_i + 1 + \theta) \sum_{i=1}^m \beta_i \\
\text{s.t.} \quad & \sum_{l=1}^k \alpha_i^l = 0 \\
& \alpha_i^l \leq 0, \forall l \neq y_i \\
& \beta_i \geq 0, \forall i \in [m]
\end{aligned} \tag{3.36}$$

设对偶问题最优解为 α_i^{l*} 、 β_i^* ，根据式 (3.33) 可得原始问题最优解：

$$\mathbf{w}_l^* = \sum_{i=1}^m (\alpha_i^{l*} - \delta_{y_i,l} \beta_i^*) \phi(\mathbf{x}_i) = \mathbf{X} \boldsymbol{\nu}_l \tag{3.37}$$

其中 $\boldsymbol{\nu}_l = [\alpha_1^{l*} - \delta_{y_1,l} \beta_1^*; \dots; \alpha_m^{l*} - \delta_{y_m,l} \beta_m^*]$ ，故对于任意未知样本 $\mathbf{z}$ ，其类别标记 $\hat{y}$ 可通过下式计算得到：

$$\hat{y} = \arg \max_{l \in [k]} \mathbf{w}_l^{\top} \phi(\mathbf{z}) = \arg \max_{l \in [k]} \sum_{i=1}^m [\boldsymbol{\nu}_l]_i \kappa(\mathbf{x}_i, \mathbf{z}) \tag{3.38}$$

其中 $[\boldsymbol{\nu}_l]_i$ 是向量 $\boldsymbol{\nu}_l$ 的第 i 个分量。

3.3 优化算法

对偶问题 (3.36) 的目标函数总共有 $m(k+1)$ 个优化变量，这么多变量很难放在一起直接优化。但仔细观察约束条件不难发现可以将它们划分成相互独立的 m 个组，不同组间的优化变量是解耦合的，其中第 i 组的优化变量包括 $\alpha_i^1, \dots, \alpha_i^k, \beta_i$ ，它们只与样本 $\mathbf{x}_i$ 相关。因此可以仿效坐标下降的思想，将每个组看做一个“坐标”，每轮挑选一组的变量进行优化，剩下的 $m-1$ 组固定不变，这样每轮要优化的变量个数大大减小，只有 $k+1$ 个，要容易得多。之后像坐标下降一样，遍历所有组，不断循环，直到收敛为止，这就是块坐标下降^[7,115]。

算法 3.1 描述了用对偶块坐标下降法求解核 mcODM 的详细过程：

算法 3.1 核 mcODM

```

1: 算法输入: 数据集  $\mathbf{X}$ 
2: 算法过程:
3: 初始化  $\alpha = [\alpha_1^1; \dots; \alpha_1^k; \dots; \alpha_m^1; \dots; \alpha_m^k]$  和  $\beta = [\beta_1; \dots; \beta_m]$  为零向量
4: while  $\alpha$  和  $\beta$  没有收敛 do
5:   for  $i = 1, \dots, m$  do
6:      $M_i \leftarrow \max_{l \neq y_i} \sum_{j=1}^m (\alpha_j^l - \delta_{y_j, l} \beta_j) \kappa(\mathbf{x}_j, \mathbf{x}_i)$ 
7:   end for
8:   用块坐标下降法求解问题 (3.36)
9: end while
10: 算法输出:  $\alpha, \beta$ 

```

3.3.1 块坐标下降子问题

算法 3.1 中的第 7 步是一个只涉及 $k+1$ 个变量的凸二次规划，利用一般求解二次规划的黑盒算法如有效集法、内点法当然可以，但是借助该问题特有的结构：变量间的交叉项较少，或许可以设计一些专门的算法。本节提出一个基于排序的算法，要远远快于通用算法。

假设当前轮需要优化的是第 i 组变量，即 $\alpha_i^1, \dots, \alpha_i^k, \beta_i$ ，其他变量均已固定，则要求解的是如下的子问题：

$$\begin{aligned}
\min_{\alpha_i^l, \alpha_i^{y_i}, \beta_i} \quad & \sum_{l \neq y_i} \frac{A}{2} (\alpha_i^l)^2 + \sum_{l \neq y_i} B_l \alpha_i^l + \frac{D}{2} (\alpha_i^{y_i})^2 - A \alpha_i^{y_i} \beta_i + B_{y_i} \alpha_i^{y_i} + \frac{E}{2} \beta_i^2 + F \beta_i \\
\text{s.t.} \quad & \sum_{l=1}^k \alpha_i^l = 0 \\
& \alpha_i^l \leq 0, \forall l \neq y_i, \beta_i \geq 0
\end{aligned} \tag{3.39}$$

其中

$$A = \kappa(\mathbf{x}_i, \mathbf{x}_i) \tag{3.40}$$

$$B_l = \begin{cases} \sum_{j \neq i} \kappa(\mathbf{x}_i, \mathbf{x}_j) (\alpha_j^l - \delta_{y_j, l} \beta_j) + 1 - \theta & \forall l \neq y_i \\ \sum_{j \neq i} \kappa(\mathbf{x}_i, \mathbf{x}_j) (\alpha_j^{y_i} - \delta_{y_j, y_i} \beta_j) & l = y_i \end{cases} \tag{3.41}$$

$$D = A + \frac{m(1-\theta)^2}{2\lambda} \tag{3.42}$$

$$E = A + \frac{m(1-\theta)^2}{2\lambda\mu} \tag{3.43}$$

$$F = M_i + 1 + \theta - B_{y_i} \tag{3.44}$$

均是与优化变量无光的常数。

该子问题的 KKT 条件表明存在标量 ν 、 ρ_l 、 η 使得

$$\sum_{l=1}^k \alpha_i^l = 0 \quad (3.45)$$

$$\alpha_i^l \leq 0, \forall l \neq y_i \quad (3.46)$$

$$\beta_i \geq 0 \quad (3.47)$$

$$\rho_l \alpha_i^l = 0, \rho_l \geq 0, \forall l \neq y_i \quad (3.48)$$

$$A\alpha_i^l + B_l - \nu + \rho_l = 0, \forall l \neq y_i \quad (3.49)$$

$$\eta \beta_i = 0, \eta \geq 0 \quad (3.50)$$

$$-A\alpha_i^{y_i} + E\beta_i + F - \eta = 0 \quad (3.51)$$

$$D\alpha_i^{y_i} - A\beta_i + B_{y_i} - \nu = 0 \quad (3.52)$$

根据式 (3.46)，如果 $\alpha_i^l < 0$ ，则 $\rho_l = 0$ ，代入式 (3.49) 可得 $A\alpha_i^l + B_l - \nu = 0$ ；如果 $\alpha_i^l = 0$ ，代入式 (3.49) 可得 $B_l - \nu = -\rho_l \leq 0$ ，综上有

$$A\alpha_i^l + B_l - \nu = 0, \forall l \neq y_i \quad \text{如果 } \alpha_i^l < 0 \quad (3.53)$$

$$B_l - \nu \leq 0, \forall l \neq y_i \quad \text{如果 } \alpha_i^l = 0 \quad (3.54)$$

同理根据式 (3.50)，如果 $\beta_i > 0$ ，则 $\eta = 0$ ，代入式 (3.51) 可得 $-A\alpha_i^{y_i} + E\beta_i + F = 0$ ；如果 $\beta_i = 0$ ，代入式 (3.51) 可得 $-A\alpha_i^{y_i} + F = \eta \geq 0$ ，综上有

$$-A\alpha_i^{y_i} + E\beta_i + F = 0, \quad \text{如果 } \beta_i > 0 \quad (3.55)$$

$$-A\alpha_i^{y_i} + F \geq 0, \quad \text{如果 } \beta_i = 0 \quad (3.56)$$

于是 KKT 条件变成式 (3.45)-式 (3.47) 以及式 (3.52)-式 (3.56)。注意

$$\alpha_i^l = \min\left(0, \frac{\nu - B_l}{A}\right), \forall l \neq y_i \quad (3.57)$$

满足 KKT 条件中的式 (3.46)、式 (3.53)、式 (3.54)，以及

$$\beta_i = \max\left(0, \frac{A\alpha_i^{y_i} - F}{E}\right) \quad (3.58)$$

满足 KKT 条件中的式 (3.47)、式 (3.55)、式 (3.56)。将式 (3.58) 回代入式

(3.52) 可得

$$D\alpha_i^{y_i} + B_{y_i} - \nu = \max\left(0, \frac{A}{E}(A\alpha_i^{y_i} - F)\right) \quad (3.59)$$

下面分两种情况讨论：

1. 当 $A\alpha_i^{y_i} \leq F$ 时，根据式 (3.58)、式 (3.59) 可知 $\beta_i = 0$ 且 $\alpha_i^{y_i} = (\nu - B_{y_i})/D$ ，因此 $A(\nu - B_{y_i})/D \leq F$ ，这意味着 $\nu \leq B_{y_i} + DF/A$ 。
2. 当 $A\alpha_i^{y_i} > F$ 时，根据式 (3.58)、式 (3.59) 可知 $\beta_i = (A\alpha_i^{y_i} - F)/E > 0$ 且 $\alpha_i^{y_i} = (E\nu - AF - EB_{y_i})(DE - A^2)$ ，因此 $A(E\nu - AF - EB_{y_i})(DE - A^2) > F$ ，这意味着 $\nu > B_{y_i} + DF/A$ 。

剩下的问题就是如何找到使得式 (3.45) 成立的 ν ，根据式 (3.45) 和式 (3.57) 可知

$$\nu = \frac{AB_{y_i}/D + \sum_{l:\alpha_i^l < 0} B_l}{A/D + |\{l \mid \alpha_i^l < 0\}|}, \quad \text{如果 } A\alpha_i^{y_i} \leq F \quad (3.60)$$

$$\nu = \frac{(AEB_{y_i} + A^2F)/(DE - A^2) + \sum_{l:\alpha_i^l < 0} B_l}{AE/(DE - A^2) + |\{l \mid \alpha_i^l < 0\}|}, \quad \text{如果 } A\alpha_i^{y_i} > F \quad (3.61)$$

无论哪种情况，最优解 ν^* 都是

$$\frac{P + \sum_{l:\alpha_i^l < 0} B_l}{Q + |\{l \mid \alpha_i^l < 0\}|} \quad (3.62)$$

的形式，其中 P 、 Q 是某个常数。下面证明这可通过对 $\{B_l \mid l \neq y_i\}$ 降序排列，然后将其顺次逐个添加到空集 Φ 中，直至不等式

$$\nu^* = \frac{P + \sum_{l \in \Phi} B_l}{Q + |\Phi|} \geq \max_{l \notin \Phi} B_l \quad (3.63)$$

成立得到。对比式 (3.63) 和式 (3.62) 可知，这只需证明最终空集 Φ 变成了 $\{l \mid \alpha_i^l < 0\}$ 。结合式 (3.57)，这等价于证明：

$$\nu^* < B_l, \quad l \in \Phi \quad (3.64)$$

$$\nu^* \geq B_l, \quad l \notin \Phi. \quad (3.65)$$

其中式 (3.65) 由式 (3.63) 立即可得。最后只需证明式 (3.64)，假设 t 是最后一个被添加到 Φ 中的元素，因此它的前一个元素被添加后，式 (3.63) 依然还不成立。

立，因此

$$\frac{P + \sum_{l \in \Phi \setminus t} B_l}{Q + |\Phi| - 1} < B_t \quad (3.66)$$

注意 Φ 中元素是按降序添加的，所以有

$$P + \sum_{l \in \Phi} B_l = P + \sum_{l \in \Phi \setminus t} B_l + B_t \quad (3.67)$$

$$< (Q + |\Phi| - 1)B_t + B_t \quad (3.68)$$

$$= (Q + |\Phi|)B_t \quad (3.69)$$

$$\leq (Q + |\Phi|)B_l, \forall l \in \Phi \quad (3.70)$$

故式 (3.64) 成立。

由于子问题 (3.39) 的海森矩阵 (Hessian matrix) 是正定的，因此最优解存在且唯一，故式 (3.60) 和式 (3.61) 有且仅有成立。所以设计算法时，我们可以先根据式 (3.60) 来计算 ν^* ，然后检查关于 ν 的约束是否满足，如果不满足则再根据式 (3.61) 计算 ν^* 即可。算法 3.2 描述了用排序法求解子问题 (3.39) 的详细过程：

在 3.3.1 节中提出的方法可以高效地求解核 mcODM，然而算法 3.1 第 5 步中参数 M_i 的计算以及算法 3.2 中参数 B_l 的计算都涉及到了核矩阵，因此至少是 $O(m^2)$ 的计算时间开销，当面对大规模数据集时，会显得力不从心。

当使用线性核时，根据式 (3.33) 可知， $\mathbf{w}_1, \dots, \mathbf{w}_k$ 直接由训练样本张成，因此可以显式地存储它们，此时

$$M_i = \max_{l \neq y_i} \mathbf{w}_l^\top \mathbf{x}_i \quad (3.71)$$

的计算就容易得多了。注意

$$B_l = \sum_{j \neq i} \mathbf{x}_i^\top \mathbf{x}_j (\alpha_j^l - \delta_{y_j, l} \beta_j) \quad (3.72)$$

$$= \sum_{j=1}^m \mathbf{x}_i^\top \mathbf{x}_j (\bar{\alpha}_j^l - \delta_{y_j, l} \bar{\beta}_j) - \mathbf{x}_i^\top \mathbf{x}_i (\bar{\alpha}_i^l - \delta_{y_i, l} \bar{\beta}_i) \quad (3.73)$$

$$= \mathbf{w}_l^\top \mathbf{x}_i - A(\alpha_i^l - \delta_{y_i, l} \beta_i) \quad (3.74)$$

因此也可以高效地计算出来。

算法 3.2 块坐标下降子问题

```

1: 算法输入: 参数  $\mathfrak{L}$ ,  $B = \{B_1, \dots, B_k\}$ ,  $D$ ,  $E$ ,  $F$ 
2: 算法过程:
3: 初始化  $\hat{B} \leftarrow B$ , 交换  $\hat{B}_1$  与  $\hat{B}_{y_i}$ , 以降序排列  $\hat{B} \setminus \{\hat{B}_1\}$ 
4:  $i \leftarrow 2, v \leftarrow AB_{y_i}/D$ 
5: while  $i \leq k$  且  $v/(i-2+A/D) < \hat{B}_i$  do
6:    $v \leftarrow v + \hat{B}_i$ 
7:    $i \leftarrow i + 1$ 
8: end while
9: if  $v \leq B_{y_i} + DF/A$  then
10:   $\alpha_i^l \leftarrow \min(0, (v - B_l)/A)$ ,  $l \neq y_i$ 
11:   $\alpha_i^{y_i} \leftarrow (v - B_{y_i})/D$ 
12:   $\beta_i \leftarrow 0$ 
13: else
14:   $i \leftarrow 2, v \leftarrow (AE\hat{B}_1 + A^2F)/(DE - A^2)$ .
15:  while  $i \leq k$  且  $v/(i-2+AE/(DE - A^2)) < \hat{B}_i$  do
16:     $v \leftarrow v + \hat{B}_i$ 
17:     $i \leftarrow i + 1$ 
18:  end while
19:   $\alpha_i^l \leftarrow \min(0, (v - B_l)/A)$ ,  $l \neq y_i$ 
20:   $\alpha_i^{y_i} \leftarrow (Ev - AF - EB_{y_i})/(DE - A^2)$ 
21:   $\beta_i \leftarrow (A\alpha_i^{y_i} - F)/E$ 
22: end if
23: 算法输出:  $\alpha_i^1, \dots, \alpha_i^k, \beta_i$ 

```

3.3.2 理论分析

本节我们研究 mcODM 的统计性质, 为了证明 mcODM 泛化风险的界, 需要引入如下函数:

$$\Phi(z) = 1_{z \leq 0} + \frac{(z - 1 + \theta)^2}{(1 - \theta)^2} 1_{0 < z \leq 1 - \theta} \quad (3.75)$$

以及间隔 $\gamma(x, y)$ 的一个下界函数:

$$\gamma_\theta(x, y) = \mathbf{w}_y^\top \phi(x) - \max_{l \in \mathcal{Y}} \{\mathbf{w}_l^\top \phi(x) - (1 - \theta)1_{l=y}\} \quad (3.76)$$

不难看出 $\Phi(\gamma_\theta(x, y)) = \Phi(\gamma(x, y))$ 。

定理 3.1 设 $\mathcal{H} = \{(x, y) \in \mathcal{X} \times [k] \mapsto \mathbf{w}_y^\top \phi(x) \mid \sum_{l=1}^k \|\mathbf{w}_l\|^2 \leq \Lambda^2\}$ 为 mcODM 的假设空间, 其中 $\phi: \mathcal{X} \mapsto \mathbb{H}$ 是某个正定核函数 $\kappa(\cdot, \cdot)$ 诱导的特征映射, 设数据集

$D \subseteq \{\mathbf{x} : \kappa(\mathbf{x}, \mathbf{x}) \leq r^2\}$, 则对于任意 $\delta > 0$, 以及任意 $h \in \mathcal{H}$,

$$R(h) \leq \frac{1}{m} \sum_{i=1}^m \Phi(\gamma(\mathbf{x}_i, y_i)) + \frac{16r\Lambda}{1-\theta} \sqrt{\frac{2\pi k}{m}} + 3 \sqrt{\frac{\ln(2/\delta)}{2m}} \quad (3.77)$$

至少以 $1 - \delta$ 的概率成立。

证明: 对任意 $h \in \mathcal{H}$, 其对应一个实值函数 $(\mathbf{x}, y) \in \mathcal{X} \times [k] \mapsto \gamma_\theta(\mathbf{x}, y)$, 记全部这样的实值函数构成的假设空间为 $\tilde{\mathcal{H}}_\theta$, 根据 McDiarmid 不等式^[77] 可知对于任意 $\delta > 0$, 以及任意 $h \in \tilde{\mathcal{H}}_\theta$,

$$\mathbb{E}[\Phi(\gamma_\theta(\mathbf{x}, y))] \leq \frac{1}{m} \sum_{i=1}^m \Phi(\gamma_\theta(\mathbf{x}_i, y_i)) + 2\mathcal{R}_m(\Phi \circ \tilde{\mathcal{H}}_\theta) + 3 \sqrt{\frac{\ln(2/\delta)}{2m}} \quad (3.78)$$

至少以 $1 - \delta$ 的概率成立。

由于 $\Phi(\gamma_\theta(\mathbf{x}, y)) = \Phi(\gamma(\mathbf{x}, y))$, 于是

$$R(h) = \mathbb{E}[1_{\gamma(\mathbf{x}, y) \leq 0}] \leq \mathbb{E}[1_{\gamma_\theta(\mathbf{x}, y) \leq 0}] \leq \mathbb{E}[\Phi(\gamma_\theta(\mathbf{x}, y))] \quad (3.79)$$

又 $\Phi(z)$ is $\frac{2}{1-\theta}$ -利普希茨连续函数, 根据 Talagrand 引理^[81] 有

$$R(h) \leq \frac{1}{m} \sum_{i=1}^m \Phi(\gamma(\mathbf{x}_i, y_i)) + \frac{4\mathcal{R}_m(\tilde{\mathcal{H}}_\theta)}{1-\theta} + 3 \sqrt{\frac{\ln(2/\delta)}{2m}}. \quad (3.80)$$

其中不等号右边的第二项, 利用 Rademacher 复杂度与高斯复杂度^[66] 的关系 $\mathcal{R}_m(\mathcal{H}) \leq \sqrt{\pi/2} \mathcal{G}_m(\mathcal{H})$, 以及高斯复杂度的性质^[68] 可得

$$\mathcal{R}_m(\tilde{\mathcal{H}}_\theta) \leq 4r\Lambda \sqrt{\frac{2\pi k}{m}} \quad (3.81)$$

回代即可知式 (3.77) 成立。 $\square$

同样, 根据定理 3.1 的结果, mcODM 的泛化界由三部分组成。其中第一项是 mcODM 在训练数据集上的经验损失, 最后一项是集中度不等式必带的副产品, 因此我们主要关注第二项。不难看出 $r\Lambda$ 越小、 $1 - \theta$ 越大, 泛化界越紧, 这与二分类任务下的结果是一致的, 即间隔的上界要尽可能的小, 同时第 p 小的间隔也要尽可能的大, 两相结合就是在固定间隔均值为 1 的情况下, 间隔方差越小泛化界越紧, 这与^[37] 中的结论也是一致的。

3.4 实验验证

本节我们通过实验验证 mcODM 的性能。首先 3.4.1 节介绍实验设置。然后 3.4.2 节展示了 mcDOM 在 22 个数据集上的性能，对比方法包括 4 种多分类 SVM: ovrSVM、ovoSVM、ecocSVM 以及 mcSVM，其中前三种基于 3.1 节介绍的 3 种分解策略，最后一种基于 3.1 节介绍的直接推广的方法。3.4.3 节研究类别数目对泛化性能和间隔分布的影响。最后 3.4.4 节对比了时间开销。

表 3.2: 多分类数据集的信息

数据集	样本数	特征数	类别数	Dataset	样本数	特征数	类别数
<i>iris</i>	150	4	3	<i>sector</i>	9,619	55,197	105
<i>wine</i>	178	13	3	<i>pendigits</i>	10,992	16	10
<i>glass</i>	214	9	6	<i>news20</i>	19,928	62,061	20
<i>svmguide2</i>	391	20	3	<i>letter</i>	20,000	16	26
<i>svmguide4</i>	612	10	6	<i>protein</i>	24,387	357	3
<i>vehicle</i>	846	18	4	<i>shuttle</i>	58,000	9	7
<i>vowel</i>	990	10	11	<i>connect-4</i>	67,557	126	3
<i>segment</i>	2,310	19	7	<i>mnist</i>	70,000	780	10
<i>dna</i>	3,186	180	3	<i>aloi</i>	108,000	128	1,000
<i>satimage</i>	6,435	36	6	<i>rcv1</i>	534,135	47,236	53
<i>usps</i>	9,298	256	10	<i>covtype</i>	581,012	54	7

3.4.1 实验设置

实验中共用到 22 个多分类数据集，表 3.2 列出了这些数据集的所有信息。可以看出，这 22 个数据集，样本数的变化范围从 150 到 581,012，特征数从 4 到 62,061，类别数则是从 3 到 1,000，覆盖的范围很大。对于每个数据集，所有的特征都归一化到 $[0, 1]$ 之间，然后随机抽取 80% 的样本用作训练数据集，剩余的作为测试数据集。所有随机划分重复 10 次，记录均值和标准差。

对于所有方法，参数 C 和 λ 通过 5-折交叉验证从集合 $[2^0, 2^2, \dots, 2^{20}]$ 中选取。对于 mcODM，参数 μ 和 θ 通过 5-折交叉验证从集合 $[0.2, 0.4, 0.6, 0.8]$ 中选取。对于 ecocSVM，采用“无遗编码”（exhaustive coding），即为每个类别构造一个长为 $2^{k-1} - 1$ 的签名。所有参数的选取只依赖于训练数据集。

表 3.3: 22 个数据集上的性能 (均值 $\pm$ 标准差); 所有方法均采用线性核; 每个数据集上的最好结果加粗显示; $\bullet/\circ$ 表示在 95% 置信度的成对 t -检验下, mcODM 的泛化性能显著好于/差于对比方法; 平均排名、取得最好性能的次数以及成对 t -检验下 mcODM 胜/平/负的次数在最后三行。ovoSVM 和 ecocSVM 在部分数据集上因为涉及的二分类子问题太多, 无法在 48 小时内输出结果

数据集	mcSVM	ovrSVM	ovoSVM	ecocSVM	mcODM
<i>iris</i>	84.7 $\pm$ 5.0 $\bullet$	82.0 $\pm$ 5.0 $\bullet$	73.0 $\pm$ 7.1 $\bullet$	73.3 $\pm$ 4.2 $\bullet$	87.3$\pm$3.4
<i>wine</i>	96.5 $\pm$ 2.6 $\bullet$	97.0 $\pm$ 2.4	96.8 $\pm$ 3.1	91.6 $\pm$ 2.7 $\bullet$	98.4$\pm$1.9
<i>glass</i>	62.0 $\pm$ 7.6 $\bullet$	57.8 $\pm$ 2.1 $\bullet$	62.4 $\pm$ 6.0 $\bullet$	60.4 $\pm$ 4.0 $\bullet$	68.2$\pm$7.3
<i>svmguide2</i>	80.9 $\pm$ 2.6 $\bullet$	81.5 $\pm$ 2.3 $\bullet$	74.6 $\pm$ 5.4 $\bullet$	79.0 $\pm$ 3.6 $\bullet$	84.1$\pm$1.8
<i>svmguide4</i>	86.6 $\pm$ 3.2 $\bullet$	77.2 $\pm$ 3.1 $\bullet$	77.1 $\pm$ 6.9 $\bullet$	74.2 $\pm$ 4.3 $\bullet$	87.8$\pm$3.5
<i>vehicle</i>	80.5 $\pm$ 2.1 $\bullet$	78.5 $\pm$ 2.9 $\bullet$	73.5 $\pm$ 3.5 $\bullet$	76.9 $\pm$ 2.5 $\bullet$	85.6$\pm$6.6
<i>vowel</i>	65.4 $\pm$ 2.1	44.1 $\pm$ 2.6 $\bullet$	71.1$\pm$4.9	43.1 $\pm$ 2.0 $\bullet$	65.6 $\pm$ 3.9
<i>segment</i>	95.3 $\pm$ 0.9 $\bullet$	92.3 $\pm$ 0.7 $\bullet$	93.2 $\pm$ 2.2 $\bullet$	90.7 $\pm$ 0.8 $\bullet$	96.7$\pm$1.3
<i>dna</i>	95.1 $\pm$ 0.6 $\bullet$	95.1 $\pm$ 0.7 $\bullet$	93.0 $\pm$ 1.0 $\bullet$	90.9 $\pm$ 1.1 $\bullet$	95.6$\pm$0.7
<i>satimage</i>	81.8 $\pm$ 0.5 $\bullet$	80.1 $\pm$ 0.7 $\bullet$	77.4 $\pm$ 4.2 $\bullet$	76.0 $\pm$ 1.4 $\bullet$	89.1$\pm$8.0
<i>usps</i>	95.1$\pm$0.3	94.2 $\pm$ 0.3 $\bullet$	94.5 $\pm$ 0.6 $\bullet$	92.3 $\pm$ 0.7 $\bullet$	95.1 $\pm$ 0.6
<i>sector</i>	93.3 $\pm$ 0.4 $\bullet$	93.1 $\pm$ 0.5 $\bullet$	89.9 $\pm$ 0.6 $\bullet$	N/A	93.6$\pm$0.6
<i>pendigits</i>	94.8 $\pm$ 0.3 $\bullet$	91.8 $\pm$ 0.5 $\bullet$	95.7 $\pm$ 0.8 $\bullet$	87.6 $\pm$ 0.7 $\bullet$	96.7$\pm$0.9
<i>news20</i>	83.3 $\pm$ 0.3 $\bullet$	83.0 $\pm$ 0.3 $\bullet$	69.4 $\pm$ 0.4 $\bullet$	N/A	83.6$\pm$0.3
<i>letter</i>	76.9 $\pm$ 0.4 $\bullet$	64.9 $\pm$ 1.0 $\bullet$	75.7 $\pm$ 1.2 $\bullet$	N/A	82.7$\pm$1.6
<i>protein</i>	68.7 $\pm$ 0.3	68.7 $\pm$ 0.4	68.1 $\pm$ 0.3 $\bullet$	66.5 $\pm$ 0.5 $\bullet$	70.2$\pm$2.3
<i>shuttle</i>	97.2 $\pm$ 0.1 $\bullet$	89.9 $\pm$ 2.8 $\bullet$	97.4 $\pm$ 0.1 $\bullet$	84.2 $\pm$ 0.0 $\bullet$	99.6$\pm$0.0
<i>connect-4</i>	75.7 $\pm$ 0.1 $\bullet$	75.7 $\pm$ 0.1 $\bullet$	75.7 $\pm$ 0.2 $\bullet$	75.1 $\pm$ 0.2 $\bullet$	94.4$\pm$7.6
<i>mnist</i>	92.5 $\pm$ 0.2 $\bullet$	91.5 $\pm$ 0.2 $\bullet$	90.9 $\pm$ 0.5 $\bullet$	87.6 $\pm$ 0.2 $\bullet$	95.2$\pm$0.3
<i>aloi</i>	90.1 $\pm$ 0.2 $\bullet$	82.2 $\pm$ 0.2 $\bullet$	N/A	N/A	91.4$\pm$0.3
<i>rcv1</i>	92.8 $\pm$ 0.1	92.7 $\pm$ 0.1	92.1 $\pm$ 0.1 $\bullet$	N/A	93.0$\pm$1.1
<i>covtype</i>	71.7 $\pm$ 0.1	71.2 $\pm$ 0.1 $\bullet$	72.7 $\pm$ 0.1	70.6 $\pm$ 0.1 $\bullet$	72.8$\pm$1.6
平均排名	2.45	3.18	3.45	4.82	1.09
最好次数	3	0	4	0	15
mcODM: 胜/平/负	17/5/0	19/3/0	18/3/0	17/0/0	

3.4.2 实验结果

表 3.3 展示了所有算法在 22 个多分类数据集上的性能 (均值 $\pm$ 标准差)。每个数据集上的最好结果加粗显示。 $\bullet/\circ$ 表示在 95% 置信度的成对 t -检验下,

mcODM 的泛化性能显著好于/差于对比方法。平均排名、取得最好性能的次数以及成对 t -检验下 mcODM 胜/平/负的次数在最后三行。ovoSVM 和 ecocSVM 在部分数据集上因为涉及的二分类子问题太多，无法在 48 小时内输出结果。

不难看出，mcODM 的泛化性能几乎都显著好于对比方法，至少也是相当的，从没出现退化的情况。具体来说，在 22 个数据集上，mcODM 显著好于 mcSVM/ovrSVM/ovoSVM/ecocSVM 的次数分别是 17/19/18/17，并且在 15 个数据集上取得最好性能。

3.4.3 类别数目的影响

本节我们研究类别数目对泛化性能和间隔分布的影响。图 3.1 展示了在 segment 数据集上，当类别数从 2 增加到 7 时，5 种方法泛化性能的变化情况。首先考虑只有第 1 类和第 2 类样本的数据集，在其上训练一个分类器并测试其泛化性能，然后依次加入第 3 类的样本并测试其泛化性能，直到全部 7 类的样本都加入进来。可以看出，当类别数不超过 4 时，所有方法的泛化性能都很不错，但是当第 5 类样本加进来以后，4 个多分类 SVM 的泛化性能显著下降，这可能是由于第 5 类样本中包含不少噪声数据，而基于最大间隔准则的方法对噪声极其敏感所致。另一方面，我们的方法由于考虑的是整体间隔分布，显然对噪声要鲁棒得多，因此泛化性能较稳定，不会出现断崖式的下降。其他数据集上的结果或多或少都与图 3.1 类似，因此不一一列举了。




图 3.1: 在 segment 数据集上，当类别数从 2 增加到 7 时，5 种方法泛化性能的变化情况

图 3.2 展示了在 **segment** 数据集上, 当类别数从 2 增加到 7 时, mcSVM、ovrSVM 以及 mcODM 最终输出的间隔分布的频率直方图。可以看出, 当类别数不超过 4 时, 所有方法都得到了不错的间隔分布, 但是当类别数继续增加时, mcSVM 和 ovrSVM 在一些样本上取得了负间隔, 相反, mcODM 的分布却变得越来越“尖锐”, 这归功于最小化方差。由于避免了较小间隔的生成, 因此 mcODM 的泛化性能也好于其他两个方法, 这与图 3.1 中观察到的结果也是一致的。在其他数据集上的结果或多或少都与图 3.2 类似, 因此不一一列举了。




图 3.2: 在 **segment** 数据集上, 当类别数从 2 增加到 7 时, mcSVM、ovrSVM 以及 mcODM 最终输出的间隔分布的频率直方图

3.4.4 时间开销

本节我们对比 mcSVM、ovrSVM、ovoSVM 和 mcODM 在除 **aloi** 之外全部数据集上的时间开销。ecocSVM 因为在许多数据集上都无法在 48 小时内输出结果，因此不纳入比较，**aloi** 数据集有 1,000 个类，ovoSVM 无法在 48 小时内输出结果，因此也不参与比较。所有实验都是在同一台拥有 2.6G 赫兹主频 *8 核 CPU、32GB 主存的服务器上进行，求解的软件是 MATLAB (2012b)。每个数据集的平均时间开销（单位：秒）如图 3.3 所示。mcSVM 以及 ovrSVM、ovoSVM 中用到的二分类 SVM 均由 LIBLINEAR 软件包^[30]实现。

可以看出对于小数据集，4 种方法的效率相当，但是对于类别数超过 10 的数据集，例如 **sector** 和 **rcv1**，不基于分解策略的 mcSVM、mcODM 就要高效得多，注意 LIBLINEAR 软件包是 SVM 非常成熟和高效的实现，因此可以说我们的方法在计算开销上还是可接受的。




图 3.3: mcSVM、ovrSVM、ovoSVM 和 mcODM 在除 **aloi** 之外全部数据集上的时间开销

3.5 小结

本文提出了面向多分类问题的最优间隔分布学习机 mcODM，通过将多类间隔定义为每类与“其他类”的二类间隔的最小值来优化间隔分布。由于最终形式化出的问题不再是一个凸优化，很难直接求解。本文先将其放松成一系列较易处理的 QP 问题，并通过基于块坐标下降的方法来求解其对偶问题；每个块坐标下降子问题是一个含有特殊结构的 QP 问题，本文提出一种基于排序的快速求解算法，比传统的求解 QP 的通用算法要高效。最终实验表明 mcODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的多分类方法。在

以后的工作中，值得研究的问题包括如何定义其他形式的多类间隔，从而使得 mcODM 的形式化更易处理。

本章的主要工作已总结成文：

- T. Zhang and Z.-H. Zhou. Multi-class optimal distribution machine. In: **Proceedings of the 34th International Conference on Machine Learning (ICML'17)**, Sydney, Australia, 2017, pp.4063-4071. (CCF A 类会议)
- T. Zhang and Z.-H. Zhou. Optimal Margin Distribution Machine. **IEEE Transactions on Knowledge and Data Engineering (TKDE)**, in press. (CCF A 类期刊)

第四章 聚类最优间隔

分布学习机

4.1 引言

现实世界中有些问题，其样本的类别标记是未知的，比如古生物研究中从遗迹中挖出的尸骸，可以测量骨骼的形状、大小、尺寸、重量等，但并不知道这属于什么动物；还有一些商业应用中的新用户，商家掌握他们的基本信息，但很难立刻判断他们属于哪个用户类型。此时，往往可先对样本按相似度进行划分，要求相似的样本在同一组，不相似的样本在不同组，这就是“聚类”（clustering）。

聚类将数据集 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ 划分成若干互不相交的子集 $C_1, \dots, C_k$ ，每个子集 C_i 称作一个“样本簇”（cluster），那么如何衡量一个划分结果 $C = \{C_1, \dots, C_k\}$ 好不好呢？直观来说，应该考察“物以类聚”的程度，即是否簇内相似度（intra-cluster similarity）高且簇间相似度（inter-cluster similarity）低。假设领域专家给出的划分结果为 $C' = \{C'_1, \dots, C'_l\}$ ， C 和 C' 对所有样本赋予的簇标记向量为 $\mathbf{y}$ 和 $\mathbf{y}'$ ，这时有两种方法：

一是考虑每个样本，比较领域专家给出的簇标记和聚类算法给出的是否相同，由此计算聚类精度^[131]。

二是考虑每个样本对，定义

$$\begin{aligned} a &= |A|, & A &= \{(\mathbf{x}_i, \mathbf{x}_j) \mid y_i = y_j, y'_i = y'_j, i < j\} \\ b &= |B|, & B &= \{(\mathbf{x}_i, \mathbf{x}_j) \mid y_i = y_j, y'_i \neq y'_j, i < j\} \\ c &= |C|, & C &= \{(\mathbf{x}_i, \mathbf{x}_j) \mid y_i \neq y_j, y'_i = y'_j, i < j\} \\ d &= |D|, & D &= \{(\mathbf{x}_i, \mathbf{x}_j) \mid y_i \neq y_j, y'_i \neq y'_j, i < j\} \end{aligned} \tag{4.1}$$

即集合 A 包含了在 C 中隶属相同簇且在 C' 中也隶属相同簇的样本对；集合 B 包含了在 C 中隶属相同簇但在 C' 中不隶属相同簇的样本对；集合 C 包含了在

C 中不隶属相同簇但在 C' 中隶属相同簇的样本对；集合 D 包含了在 C 中不隶属相同簇且在 C' 中也不隶属相同簇的样本对。计算领域专家给出的簇标记和聚类算法给出的在任意一个样本对上的一致性可能性，这就是 Rand 指数 (Rand Index, 简称 RI^[91])：

$$RI = \frac{a + d}{a + b + c + d} = \frac{2(a + d)}{m(m - 1)} \quad (4.2)$$

显然聚类精度和 RI 的值均在 $[0, 1]$ 区间内，越大越好。

这种对目标按相似度进行分组，在很多领域都有类似要求的任务，例如信息检索、计算机视觉、生物信息学等等，因此过去的几十年间提出了各种各样聚类算法^[51,52,132]。其中最著名的莫过于“ k -均值” (k-means) 算法，其针对最终划分 $C_1, \dots, C_k$ 最小化平方误差：

$$\min_{\mu_i} \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (4.3)$$

其中 $\mu = \sum_{x \in C_i} x_i / |C_i|$ 是第 i 个簇 C_i 的均值向量。 k -均值算法属于“原型聚类” (prototype-based clustering) 的范畴，即假设聚类结构能通过一组原型来刻画。后来研究者们又提出了许多 k -均值的变种，比如 k -medoids^[58] 要求原型样本必须也是训练样本； k -modes 算法^[48] 可处理离散特征；引入核技巧则得到核 k -均值 (kernel k -means)^[99]。

除了基于原型的策略外，还有基于密度的 (density-based clustering)，此类方法从样本密度的角度来考察样本之间的可连接性，并基于可连接样本不断扩展样本簇以获得最终的聚类结果，其中比较有代表性的方法是 DBSCAN^[27]、OPTICS^[2]、DENCLUE^[42]。此外，还有试图在不同层次对数据集进行划分，从而形成树状结构的层次聚类^[59]，划分的方式既可采用“自底向上”的聚合策略，也可采用“自顶向下”的分解策略。

聚类本属于“无监督学习”的范畴，近年有研究者将统计学习中的最大间隔准则的思想引入到了聚类中，提出了最大间隔聚类 (Maximum Margin Clustering, 简称 MMC) 准则，其基本想法是给定一个聚类结果，在将簇标记赋予给每个簇时可以得到一个“有监督信息”的数据集。如果这个聚类结果好，在此有监督数据集上，必然可以得到一个大间隔的划分超平面。因此最终的优化问题其实就是将软间隔 SVM 中的类别标记 y_i 也当做优化变量，即考虑如下

优化问题:

$$\begin{aligned}
 \min_{\mathbf{y} \in \{-1,1\}^m} \min_{\mathbf{w}, \xi_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \xi_i \\
 \text{s.t.} \quad & y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \xi_i \\
 & \xi_i \geq 0, \forall i \in [m]
 \end{aligned} \tag{4.4}$$

或者对偶形式:

$$\begin{aligned}
 \min_{\mathbf{y} \in \{-1,1\}^m} \max_{\boldsymbol{\alpha}} \quad & -\frac{1}{2} \boldsymbol{\alpha}^\top [(\mathbf{y}\mathbf{y}^\top) \circ \mathbf{K}] \boldsymbol{\alpha} + \mathbf{e}^\top \boldsymbol{\alpha} \\
 \text{s.t.} \quad & \mathbf{0} \leq \boldsymbol{\alpha} \leq \frac{\lambda}{m} \mathbf{e}
 \end{aligned} \tag{4.5}$$

其中 $\mathbf{K}$ 是核矩阵。由于 $y_i \in \{+1, -1\}$, 因此这不再是一个凸优化问题, 而是一个混合整数规划 (mixed-integer programming) 的问题, 这类问题理论上是 NP-hard 的, 直接求得最优解是不现实的, 于是很多近似求解的方法被提了出来, 大致可以分为两大类:

第一类考虑先将对偶形式, 即优化问题 (4.5) 放松成凸优化问题再求解。注意优化变量 $\mathbf{y}$ 是以 $\mathbf{y}\mathbf{y}^\top$ 这种外积的形式出现的, 于是 Xu 等人^[131] 用一个半正定矩阵 $\mathbf{M}$ 来替代它, 并将 $\mathbf{M} = \mathbf{y}\mathbf{y}^\top$ 用一些线性约束替代掉, 从而得到一个半定规划 (Semi-Definite Programming, 简称 SDP), 这是凸优化, 有一些成熟的软件包可以求解, 例如 SeDuMi。但是由于变量个数显著增加, 变成了 $O(m^2)$, 因此只能解一些很小的数据集。在此基础上, Valizadegan 和 Jin^[119] 提出了一个新的放松, 虽然还是基于 SDP 的, 但是变量个数依然保持在 $O(m)$ 。最终 Li 等人^[71,73] 提出一个基于极大极小不等式的放松, 并在理论上证明了它比基于 SDP 的放松要紧, 最终求解该问题可以转化为生成一系列候选的 $\mathbf{y}$ 并将其组合起来的多核学习 (multiple kernel learning) 问题。该类方法的性能取决于放松得是否够紧, 即放松后问题的最优解与原问题的最优解的近似程度。

第二类考虑用非凸优化算法直接求解原始形式, 即优化问题 (4.4) 的局部最优解。Zhang 等人^[134,135] 采用交替优化的算法, 即每轮先固定 $\mathbf{y}$, 求解 SVM 的划分超平面; 再根据划分超平面, 重新优化类别标记 $\mathbf{y}$ 的指派, 如此交替迭代直至收敛。Zhao 等人^[124,142] 则先将 $\mathbf{y}$ 用绝对值函数吸收掉, 虽然整型优化变量 y_i 没有了, 但这将使得约束变得非凸, 然后采取 CCCP (Constrained Convex-Concave Procedure) 的方法, 将非凸约束写成两个凸函数的差, 并将后

者进一步用其一阶泰勒展式 (Taylor's formula) 代替, 从而整体变成了一个易于求解的凸优化问题。该类方法只能求得一个局部最优解, 因此需要多次初始化取最优的模型。

此外还有很多研究者尝试将 MMC 扩展到其他学习设置下, 例如 Zhou 等人^[144] 假设数据中存在隐变量, 由此提出了 LMMC 学习框架。Niu 等人^[86] 提出了一个类似于 MMC 的准则, 叫 MVC (Maximum Volume Clustering), 相对于 MMC, 它有更好的理论保障。Saradhi 和 Charly^[123] 还提出了增量学习 (incremental learning) 版本的 MMC。

上面提到的各种基于 MMC 的算法都利用了监督学习中的最大间隔准则, 然而正如前文所指出的, 优化最小间隔未必会得到好的结果, 间隔分布才是更重要的, 这意味着 MMC 或许还有很大的提升空间。

4.2 问题形式化

将最优间隔分布学习的思想引入到聚类问题中, 就是要求将类别标记赋予给每个簇时, 在此“有监督数据”上可以训练得到一个有好的间隔分布的划分超平面。回想二分类核 ODM 的形式化为

$$\min_{\mathbf{w}, \xi_i, \epsilon_i} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} \quad (4.6)$$

$$\text{s.t. } y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i \quad (4.7)$$

$$y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \forall i \in [m] \quad (4.8)$$

记 $\hat{\mathbf{y}} = [\hat{y}_1, \dots, \hat{y}_m] \in \{\pm 1\}^m$ 表示未知类别标记, 则聚类最优间隔分布学习机 (Optimal margin Distribution Machine Clustering, 简称 ODMC) 可以形式化为

$$\min_{\hat{\mathbf{y}} \in \mathcal{B}} \min_{\mathbf{w}, \xi_i, \epsilon_i} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} \quad (4.9)$$

$$\text{s.t. } \hat{y}_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i$$

$$\hat{y}_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \forall i \in [m]$$

其中 $\mathcal{B}$ 是候选类别标记集合, 可以根据用户的领域知识来设置。例如当知道类别的平衡度时, 可以设 $\mathcal{B} = \{\hat{\mathbf{y}} \mid -\beta \leq \mathbf{e}^\top \hat{\mathbf{y}} \leq \beta\}$, 其中 β 是控制类别平衡度的参数。当有一些“必连” (must-link) 约束构成的集合 M , 或者“勿连”

(cannot-link) 约束构成的集合 C ，即某两个样本必须在或不在同一个簇里，可以设：

$$\mathcal{B} = \{\hat{\mathbf{y}} \mid \hat{y}_i = \hat{y}_j, \hat{y}_j \neq \hat{y}_k, \forall (\mathbf{x}_i, \mathbf{x}_j) \in M, \forall (\mathbf{x}_j, \mathbf{x}_k) \in C\} \quad (4.10)$$

由于核的存在，问题 (4.9) 的内部问题一般通过对偶形式来解决，

$$\begin{aligned} \min_{\hat{\mathbf{y}} \in \mathcal{B}} \max_{\alpha \geq 0} \quad & -\frac{1}{2} \alpha^\top \begin{bmatrix} \mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top & -\mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top \\ -\mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top & \mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top \end{bmatrix} \alpha \\ & -\frac{m(1-\theta)^2}{4\lambda} \alpha^\top \begin{bmatrix} \mathbf{I} & 0 \\ 0 & \frac{1}{\mu} \mathbf{I} \end{bmatrix} \alpha - \begin{bmatrix} (\theta-1)\mathbf{e} \\ (\theta+1)\mathbf{e} \end{bmatrix}^\top \alpha \end{aligned} \quad (4.11)$$

其中 $\odot$ 表示按位乘。问题 (4.11) 依然还是个混合整数规划问题，此时有两种处理的技巧：第一种是将 $\hat{\mathbf{y}} \hat{\mathbf{y}}^\top$ 用一个半正定矩阵 $\mathbf{M}$ 替代掉，并将非凸约束 $\mathbf{M} = \hat{\mathbf{y}} \hat{\mathbf{y}}^\top$ 用一些线性约束替代掉，从而得到一个 SDP 问题。第二种是通过如下的极大极小不等式^[60]来放松：

$$\max_{\mathbf{x} \in \mathcal{X}} \min_{\mathbf{y} \in \mathcal{Y}} f(\mathbf{x}, \mathbf{y}) \leq \min_{\mathbf{y} \in \mathcal{Y}} \max_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}, \mathbf{y}) \quad (4.12)$$

即将 $\min$ 和 $\max$ 的顺序调换，考虑原问题的一个下界。Li 等人^[71,73] 已经指出基于极大极小不等式的放松比基于 SDP 的放松要紧，因此我们也选择这种放松方式。为了表示方便，我们记 (4.11) 式中的目标函数为 $G(\alpha, \hat{\mathbf{y}})$ ，并记 α 的可行域为 $\mathcal{A}$ ，于是放松后的问题为

$$\max_{\alpha \in \mathcal{A}} \min_{\hat{\mathbf{y}} \in \mathcal{B}} G(\alpha, \hat{\mathbf{y}}) \quad (4.13)$$

将 $\min_{\hat{\mathbf{y}} \in \mathcal{B}}$ 交换到内层的好处是可以将其吸收进目标函数中，从而避免了对整型优化变量的处理，下面对内部问题进行改写：

$$\max_{\alpha \in \mathcal{A}} \min_{\delta} (-\delta) \quad (4.14)$$

$$\text{s.t. } G(\alpha, \hat{\mathbf{y}}_k) \geq \delta, \forall \hat{\mathbf{y}}_k \in \mathcal{B} \quad (4.15)$$

为约束引入拉格朗日乘子 $\mu \geq 0$ ，于是得到拉格朗日函数：

$$L(\delta, \mu) = -\delta - \sum_{k: \hat{\mathbf{y}}_k \in \mathcal{B}} \mu_k (G(\alpha, \hat{\mathbf{y}}_k) - \delta) \quad (4.16)$$

为了求得对偶函数, 需令拉格朗日函数关于原始优化变量 δ 取极小, 求导并令导数为零可得

$$\frac{\partial L}{\partial \delta} = -1 + \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k = 0 \longrightarrow \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k = 1 \quad (4.17)$$

即 μ 属于某个单纯形 $\mathcal{M}$, 回代入拉格朗日函数可得对偶函数:

$$g(\mu) = - \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k G(\alpha, \hat{y}_k) \quad (4.18)$$

令对偶函数关于拉格朗日乘子 μ 取极大可得对偶问题:

$$\max_{\alpha \in \mathcal{A}} \max_{\mu \in \mathcal{M}} - \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k G(\alpha, \hat{y}_k) \quad (4.19)$$

记 $\varphi(\mu, \alpha) = \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k G(\alpha, \hat{y}_k)$, 则上述问题等价于

$$\max_{\alpha \in \mathcal{A}} \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha) \quad (4.20)$$

注意 $G(\alpha, \hat{y}_k)$ 是关于 α 的负定二次型, 因此 $\varphi(\mu, \alpha)$ 是负定二次型的非负组合, 因此它关于 α 是凹的, 关于 μ 是线性的, 当然也是凸的, 因此由极大极小定理^[108] 可知存在鞍点 $(\hat{\mu}, \hat{\alpha}) \in \mathcal{M} \times \mathcal{A}$ 使得下式成立

$$\begin{aligned} \min_{\mu \in \mathcal{M}} \max_{\alpha \in \mathcal{A}} \varphi(\mu, \alpha) &\leq \max_{\alpha \in \mathcal{A}} \varphi(\hat{\mu}, \alpha) = \varphi(\hat{\mu}, \hat{\alpha}) \\ &= \min_{\mu \in \mathcal{M}} \varphi(\mu, \hat{\alpha}) \leq \max_{\alpha \in \mathcal{A}} \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha) \end{aligned} \quad (4.21)$$

结合极大极小不等式^[60]

$$\max_{\alpha \in \mathcal{A}} \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha) \leq \min_{\mu \in \mathcal{M}} \max_{\alpha \in \mathcal{A}} \varphi(\mu, \alpha), \quad (4.22)$$

可知 (4.21) 式中的不等号全部取等号, 于是 ODMC 最终的形式化为

$$\min_{\mu \in \mathcal{M}} \max_{\alpha \in \mathcal{A}} \varphi(\mu, \alpha) \quad (4.23)$$

求得极大极小问题 (4.23) 的鞍点 $(\hat{\mu}, \hat{\alpha})$ 后, 可以通过下式恢复出聚类结果:

$$\text{sign} \sum_{k: \hat{y}_k \in \mathcal{B}} \hat{\mu}_k \hat{y}_k \quad (4.24)$$

4.3 优化算法

本节我们先简单介绍下极大极小问题，然后给出一个基于随机镜像下降的求解方法，最后给出收敛率分析。

4.3.1 极大极小问题

由于 $\varphi(\cdot, \alpha)$ 是凸函数而 $\varphi(\mu, \cdot)$ 是凹函数，根据凸函数的一阶不等式可知，对于任意 $(\bar{\mu}, \bar{\alpha}) \in \mathcal{M} \times \mathcal{A}$ 有

$$\varphi(\bar{\mu}, \bar{\alpha}) - \varphi(\mu, \bar{\alpha}) \leq \partial_{\mu} \varphi(\bar{\mu}, \bar{\alpha})^{\top} (\bar{\mu} - \mu), \quad \forall \mu \in \mathcal{M} \quad (4.25)$$

$$\varphi(\bar{\mu}, \alpha) - \varphi(\bar{\mu}, \bar{\alpha}) \leq -\partial_{\alpha} \varphi(\bar{\mu}, \bar{\alpha})^{\top} (\bar{\alpha} - \alpha), \quad \forall \alpha \in \mathcal{A} \quad (4.26)$$

将两式相加可得

$$\varphi(\bar{\mu}, \alpha) - \varphi(\mu, \bar{\alpha}) \leq g(\bar{w})^{\top} (\bar{w} - w), \quad \forall \mu, \alpha \quad (4.27)$$

其中

$$w = (\mu, \alpha), \quad \bar{w} = (\bar{\mu}, \bar{\alpha}), \quad g(\bar{w}) = (\partial_{\mu} \varphi(\bar{\mu}, \bar{\alpha}), -\partial_{\alpha} \varphi(\bar{\mu}, \bar{\alpha})) \quad (4.28)$$

由于式 (4.27) 对任意 μ 和 α 都成立，因此特别的有

$$\max_{\alpha \in \mathcal{A}} \varphi(\bar{\mu}, \alpha) - \min_{\mu \in \mathcal{M}} \varphi(\mu, \bar{\alpha}) \leq g(\bar{w})^{\top} (\bar{w} - w). \quad (4.29)$$

上式不等号左边称为“对偶间隙”（duality gap），可以进一步分解为两部分：

$$\max_{\alpha \in \mathcal{A}} \varphi(\bar{\mu}, \alpha) - \min_{\mu \in \mathcal{M}} \varphi(\mu, \bar{\alpha}) \quad (4.30)$$

$$= \max_{\alpha \in \mathcal{A}} \varphi(\bar{\mu}, \alpha) - \varphi(\hat{\mu}, \hat{\alpha}) + \varphi(\hat{\mu}, \hat{\alpha}) - \min_{\mu \in \mathcal{M}} \varphi(\mu, \bar{\alpha}) \quad (4.31)$$

$$= \underbrace{\max_{\alpha \in \mathcal{A}} \varphi(\bar{\mu}, \alpha) - \min_{\mu \in \mathcal{M}} \max_{\alpha \in \mathcal{A}} \varphi(\mu, \alpha)}_{\mu\text{-间隙}} + \underbrace{\max_{\alpha \in \mathcal{A}} \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha) - \min_{\mu \in \mathcal{M}} \varphi(\mu, \bar{\alpha})}_{\alpha\text{-间隙}}. \quad (4.32)$$

可以看出， μ -间隙和 α -间隙均非负，且越靠近鞍点，这两个间隙越小，因此对偶间隙可以用来度量当前点 $(\bar{\mu}, \bar{\alpha})$ 与鞍点 $(\hat{\mu}, \hat{\alpha})$ 的接近程度，从而给算法设置停止条件提供了便利。

4.3.2 随机镜像下降

注意优化变量 μ 、 α 的可行域分别是单纯形和箱型约束，若直接套用黑盒算法投影梯度下降（projected gradient descent），则没有将这些结构信息充分利用起来，对于此类问题，最常用的是镜像下降（mirror descent）^[4]。

这两个域上最合适的镜像映射分别为

$$\Phi_{\mathcal{M}}(\mu) = \sum_k \mu_k \log \mu_k \quad (4.33)$$

$$\Phi_{\mathcal{A}}(\alpha) = \frac{1}{2} \|\alpha\|_2^2 \quad (4.34)$$

引入联合映射 $\Phi(w) = a\Phi_{\mathcal{M}}(\mu) + b\Phi_{\mathcal{A}}(\alpha)$ ，其中 a 和 b 是待定参数。易知有

$$\nabla \Phi_{\mathcal{M}}(\mu) = \log \mu + e \quad (4.35)$$

$$\nabla \Phi_{\mathcal{A}}(\alpha) = \alpha \quad (4.36)$$

$$\nabla \Phi(w) = (a \log \mu + ae, b\alpha) \quad (4.37)$$

在第 t -轮迭代中，我们先将 $w_t = (\mu_t, \alpha_t)$ 通过 $\nabla \Phi(w_t) = (a \log \mu_t + ae, b\alpha_t)$ 映射到对偶空间，然后在对偶空间做一步梯度下降，

$$\nabla \Phi(y_{t+1}) = \nabla \Phi(w_t) - \eta \tilde{g}(w_t) \quad (4.38)$$

$$= (a \log \mu_t + ae - \eta \partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t), b\alpha_t + \eta \partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t)) \quad (4.39)$$

其中 $\partial_{\mu} \tilde{\varphi}$ 、 $\partial_{\alpha} \tilde{\varphi}$ 、 $\tilde{g}$ 分别是 $\partial_{\mu} \varphi$ 、 $\partial_{\alpha} \varphi$ 、 g 的无偏估计， η 是步长。

然后将 $\nabla \Phi(y_{t+1})$ 映射回原始空间，即求 $y_{t+1} = (u_{t+1}, v_{t+1})$ 使得

$$a \log u_{t+1} + ae = a \log \mu_t + ae - \eta \partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t) \quad (4.40)$$

$$bv_{t+1} = b\alpha_t + \eta \partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t) \quad (4.41)$$

经过简单的代数运算可得

$$u_{t+1} = \mu_t \exp\left(-\frac{\eta}{a} \partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t)\right) \quad (4.42)$$

$$v_{t+1} = \alpha_t + \frac{\eta}{b} \partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t) \quad (4.43)$$

最后将 (u_{t+1}, v_{t+1}) 投影回可行域 $\mathcal{M} \times \mathcal{A}$ ，其中前者基于 Kullback-Leibler 距

离，后者基于标准的 Euclidean 距离，即求解如下两个子优化问题：

$$\boldsymbol{\mu} = \arg \min_{\boldsymbol{\mu} \in \mathcal{M}} \boldsymbol{\mu}^\top \log \frac{\boldsymbol{\mu}}{\mathbf{u}_{t+1}} \quad (4.44)$$

$$\boldsymbol{\alpha} = \arg \min_{\boldsymbol{\alpha} \in \mathcal{A}} \|\boldsymbol{\alpha} - \mathbf{v}_{t+1}\|_2^2, \quad (4.45)$$

幸运的是这两个问题都是有闭式解的。

先看后者，这是将 $\mathbf{v}_{t+1}$ 往箱型约束的可行域 $\mathcal{A}$ 上投影，因此只需将超出边界的部分去掉即可：

$$\boldsymbol{\alpha}_{t+1} = \max\{\min\{\mathbf{v}_{t+1}, \tau \mathbf{e}\}, \mathbf{0}\} \quad (4.46)$$

再看前者，约束是单纯形约束，引入拉格朗日乘子 $\zeta \geq 0$ 可得拉格朗日函数：

$$L(\boldsymbol{\mu}, \zeta) = \boldsymbol{\mu}^\top \log \frac{\boldsymbol{\mu}}{\mathbf{u}_{t+1}} + \zeta(\mathbf{e}^\top \boldsymbol{\mu} - 1) \quad (4.47)$$

为了求得对偶函数，需令拉格朗日函数关于原始优化变量 $\boldsymbol{\mu}$ 取极小，故求导并令导数为零可得：

$$\frac{\partial L}{\partial \boldsymbol{\mu}} = \log(\boldsymbol{\mu}/\mathbf{u}_{t+1}) + \mathbf{e} + \zeta \mathbf{e} = \mathbf{0} \longrightarrow \boldsymbol{\mu}_{t+1} = \mathbf{u}_{t+1} \exp(-1 - \zeta) \quad (4.48)$$

由于 $\boldsymbol{\mu}_{t+1}$ 属于单纯形，因此有

$$1 = \mathbf{e}^\top \boldsymbol{\mu}_{t+1} = \mathbf{e}^\top \mathbf{u}_{t+1} \exp(-1 - \zeta) = \|\mathbf{u}_{t+1}\|_1 \exp(-1 - \zeta) \quad (4.49)$$

这意味着 $\exp(-1 - \zeta) = 1/\|\mathbf{u}_{t+1}\|_1$ ，从而有 $\boldsymbol{\mu}_{t+1} = \mathbf{u}_{t+1}/\|\mathbf{u}_{t+1}\|_1$ ，图 4.1 给出了随机镜像下降一轮迭代的示意图。

最后剩下的是如何求得随机梯度 $\partial_{\boldsymbol{\mu}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t)$ 和 $\partial_{\boldsymbol{\alpha}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t)$ 。注意 $\varphi(\boldsymbol{\mu}, \boldsymbol{\alpha}) = \sum_{k: \hat{\mathbf{y}}_k \in \mathcal{B}} \mu_k G(\boldsymbol{\alpha}, \hat{\mathbf{y}}_k)$ ，于是有

$$\partial_{\boldsymbol{\mu}} \varphi(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t) = [G(\boldsymbol{\alpha}_t, \hat{\mathbf{y}}_1), \dots, G(\boldsymbol{\alpha}_t, \hat{\mathbf{y}}_{|\mathcal{B}|})] \quad (4.50)$$

$$\partial_{\boldsymbol{\alpha}} \varphi(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t) = [\partial_{\boldsymbol{\alpha}} G(\boldsymbol{\alpha}_t, \hat{\mathbf{y}}_1), \dots, \partial_{\boldsymbol{\alpha}} G(\boldsymbol{\alpha}_t, \hat{\mathbf{y}}_{|\mathcal{B}|})] \boldsymbol{\mu}_t \quad (4.51)$$

从 $\{1, 2, \dots, |\mathcal{B}|\}$ 中均匀采样 i_t ，则有 $\partial_{\boldsymbol{\mu}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t, i_t) = [0, \dots, |\mathcal{B}| G(\boldsymbol{\alpha}_t, \hat{\mathbf{y}}_{i_t}), \dots, 0]$ ；

另一方面，从 $\{1, 2, \dots, |\mathcal{B}|\}$ 中根据分布 $\boldsymbol{\mu}_t$ 采样 j_t ，则有 $\partial_{\boldsymbol{\alpha}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t, j_t) = \partial_{\boldsymbol{\alpha}} G(\boldsymbol{\alpha}_t, \hat{\mathbf{y}}_{j_t})$ ，




图 4.1: 随机镜像下降一轮迭代的示意图

于是

$$\mathbb{E}[\partial_{\mu}\tilde{\varphi}(\mu_t, \alpha_t, i_t) \mid \mu_t, \alpha_t] = \partial_{\mu}\varphi(\mu_t, \alpha_t) \quad (4.52)$$

$$\mathbb{E}[\partial_{\alpha}\tilde{\varphi}(\mu_t, \alpha_t, j_t) \mid \mu_t, \alpha_t] = \partial_{\alpha}\varphi(\mu_t, \alpha_t) \quad (4.53)$$

即 $\tilde{g}(w_t) = (\partial_{\mu}\tilde{\varphi}(\mu_t, \alpha_t, i_t), -\partial_{\alpha}\tilde{\varphi}(\mu_t, \alpha_t, j_t))$ 是 $g(w_t)$ 的一个无偏估计。

算法 4.1 描述了用随机镜像下降求解 ODMC 的详细过程：

4.3.3 收敛性分析

基于割平面的算法已经被证明时间复杂度是 $O(1/\epsilon^2)^{[142]}$ ，换言之，要想得到精度为 ϵ 的解，算法需要迭代 $O(1/\epsilon^2)$ 轮。本节我们证明随机镜像下降与基于割平面的算法有相同的收敛率，但是注意到基于割平面的算法每轮需寻找最破坏约束的类别标记，然后重新训练一个 SVM 模型，而随机镜像下降每轮只需做一步随机采样，一步梯度下降，以及一个有闭式解的投影，因此我们的方法要高效得多。

定理 4.1 设对任意 $\hat{y}_k \in \mathcal{B}$ 有 $|G(\alpha, \hat{y}_k)| \leq L_1$ ，对任意 $\alpha \in \mathcal{A}$ 有 $\|\partial_{\alpha}G(\alpha, \hat{y}_k)\|_2 \leq L_2$ 。令 $a = |\mathcal{B}|L_1/\sqrt{\log|\mathcal{B}|}$ ， $b = \sqrt{2}L_2/\sqrt{m}\tau$ ，以及 $\eta = \sqrt{2/T}$ ，则在算法迭代 T 轮后的平均点 $(\sum_{t=1}^T \mu_t/T, \sum_{t=1}^T \alpha_t/T)$ 处，对偶间隙的期望满足

$$\mathbb{E} \left[\max_{\alpha \in \mathcal{A}} \varphi \left(\frac{1}{T} \sum_{t=1}^T \mu_t, \alpha \right) - \min_{\mu \in \mathcal{M}} \varphi \left(\mu, \frac{1}{T} \sum_{t=1}^T \alpha_t \right) \right] \leq \frac{|\mathcal{B}|L_1 \sqrt{2 \log |\mathcal{B}|} + L_2 \tau \sqrt{m}}{\sqrt{T}} \quad (4.54)$$

算法 4.1 随机镜像下降算法

```

1: 算法输入: 数据集  $\mathbf{X}$ , 最大迭代轮数  $T$ , ODM 参数  $\lambda$ 、 $\nu$ 、 $\theta$ , 约束上界参
   数  $\tau$ , 阈值  $\iota$ 
2: 算法过程:
3: 初始化  $\mu_0 \leftarrow [1/|\mathcal{B}|, \dots, 1/|\mathcal{B}|]$ ,  $\alpha_0 \leftarrow \mathbf{0}$ ,  $t \leftarrow 0$ 
4: while  $t < T$  do
5:   从  $\{1, 2, \dots, |\mathcal{B}|\}$  中随机采样出  $i_t$ 
6:    $\partial_\mu \tilde{\varphi}(\mu_t, \alpha_t, i_t) \leftarrow [0, \dots, |\mathcal{B}|G(\alpha_t, \hat{y}_{i_t}), \dots, 0]$ 
7:   根据分布  $\mu_t$  从  $\{1, 2, \dots, |\mathcal{B}|\}$  中采样出  $j_t$ 
8:    $\partial_\alpha \tilde{\varphi}(\mu_t, \alpha_t, j_t) \leftarrow \partial_\alpha G(\alpha_t, \hat{y}_{j_t})$ 
9:    $\mathbf{u}_{t+1} \leftarrow \mu_t \exp(-\eta \partial_\mu \tilde{\varphi}(\mu_t, \alpha_t, i_t)/a)$ 
10:   $\mathbf{v}_{t+1} \leftarrow \alpha_t + \eta \partial_\alpha \tilde{\varphi}(\mu_t, \alpha_t, j_t)/b$ 
11:   $\mu_{t+1} \leftarrow \mathbf{u}_{t+1}/\|\mathbf{u}_{t+1}\|_1$ 
12:   $\alpha_{t+1} \leftarrow \max\{\min\{\mathbf{v}_{t+1}, \tau \mathbf{e}\}, \mathbf{0}\}$ 
13:   $t \leftarrow t + 1$ 
14:  if 对偶间隙小于给定阈值  $\iota$  then
15:    停止迭代
16:  end if
17: end while
18: 算法输出:  $\mu$ ,  $\alpha$ 

```

证明: 证明的思路类似于标准的梯度下降, 考虑平均点处的梯度 $\tilde{g}(\mathbf{w}_t)$ 和间隙 $\mathbf{w}_t - \mathbf{w}$ 的内积,

$$\mathbb{E} \left[\max_{\alpha \in \mathcal{A}} \varphi \left(\frac{1}{T} \sum_{t=1}^T \mu_t, \alpha \right) - \min_{\mu \in \mathcal{M}} \varphi \left(\mu, \frac{1}{T} \sum_{t=1}^T \alpha_t \right) \right] \quad (4.55)$$

$$\leq \mathbb{E} \left[\max_{\alpha \in \mathcal{A}} \frac{1}{T} \sum_{t=1}^T \varphi(\mu_t, \alpha) - \min_{\mu \in \mathcal{M}} \frac{1}{T} \sum_{t=1}^T \varphi(\mu, \alpha_t) \right] \quad (4.56)$$

$$\leq \mathbb{E} \left[\frac{1}{T} \sum_{t=1}^T \left(\max_{\alpha \in \mathcal{A}} \varphi(\mu_t, \alpha) - \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha_t) \right) \right] \quad (4.57)$$

$$\leq \frac{1}{T} \sum_{t=1}^T \mathbb{E}[g(\mathbf{w}_t)^\top (\mathbf{w}_t - \mathbf{w})] \quad (4.58)$$

$$= \frac{1}{T} \sum_{t=1}^T \mathbb{E}[\mathbb{E}[\tilde{g}(\mathbf{w}_t)^\top (\mathbf{w}_t - \mathbf{w}) \mid \mathbf{w}_t]] \quad (4.59)$$

$$= \frac{1}{T} \sum_{t=1}^T \mathbb{E}[\tilde{g}(\mathbf{w}_t)^\top (\mathbf{w}_t - \mathbf{w})] \quad (4.60)$$

其中第一个不等号是因为 $\varphi(\mu, \alpha)$ 关于 μ 是凸函数而关于 α 是凹函数, 由

凸函数的性质可得；第二个不等号是根据 $\max$ 的次加性，即 $\max(a+b) \leq \max a + \max b$ ；第三个不等号是根据式 (4.29)，最后一个等号是根据全期望公式（law of total expectation）。

下面我们考虑求和里的每一项，根据随机镜像下降的更新公式可知

$$\widetilde{g}(\mathbf{w}_t)^\top (\mathbf{w}_t - \mathbf{w}) \quad (4.61)$$

$$= \frac{1}{\eta} (\nabla \Phi(\mathbf{w}_t) - \nabla \Phi(\mathbf{y}_{t+1}))^\top (\mathbf{w}_t - \mathbf{w}) \quad (4.62)$$

$$= \frac{1}{\eta} (\Delta_\Phi(\mathbf{w}, \mathbf{w}_t) + \Delta_\Phi(\mathbf{w}_t, \mathbf{y}_{t+1}) - \Delta_\Phi(\mathbf{w}, \mathbf{y}_{t+1})) \quad (4.63)$$

$$\leq \frac{1}{\eta} (\Delta_\Phi(\mathbf{w}, \mathbf{w}_t) + \Delta_\Phi(\mathbf{w}_t, \mathbf{y}_{t+1}) - \Delta_\Phi(\mathbf{w}, \mathbf{w}_{t+1}) - \Delta_\Phi(\mathbf{w}_{t+1}, \mathbf{y}_{t+1})) \quad (4.64)$$

其中 $\Delta_\Phi(\mathbf{w}, \mathbf{w}_t) = \Phi(\mathbf{w}) - \Phi(\mathbf{w}_t) - \nabla \Phi(\mathbf{w}_t)^\top (\mathbf{w} - \mathbf{w}_t)$ 是 Bregman 距离（Bregman divergence）。由于 $\mathbf{w}_{t+1}$ 是 $\mathbf{y}_{t+1}$ 在凸集 $\mathcal{M} \times \mathcal{A}$ 上的投影，最后一个不等号是根据广义三角不等式（generalized triangle inequality）。注意第一项和第三项在累计求和时可以交错相抵，因此只需考虑剩下的两项：

$$\Delta_\Phi(\mathbf{w}_t, \mathbf{y}_{t+1}) - \Delta_\Phi(\mathbf{w}_{t+1}, \mathbf{y}_{t+1}) \quad (4.65)$$

$$= \Phi(\mathbf{w}_t) - \Phi(\mathbf{w}_{t+1}) - \nabla \Phi(\mathbf{y}_{t+1})^\top (\mathbf{w}_t - \mathbf{w}_{t+1}) \quad (4.66)$$

$$\leq \eta \widetilde{g}(\mathbf{w}_t)^\top (\mathbf{w}_t - \mathbf{w}_{t+1}) - \frac{1}{2} \|\mathbf{w}_t - \mathbf{w}_{t+1}\|^2 \quad (4.67)$$

$$\leq \eta \|\widetilde{g}(\mathbf{w}_t)\|_* \|\mathbf{w}_t - \mathbf{w}_{t+1}\| - \frac{1}{2} \|\mathbf{w}_t - \mathbf{w}_{t+1}\|^2 \quad (4.68)$$

$$= -\frac{1}{2} (\|\mathbf{w}_t - \mathbf{w}_{t+1}\| - \eta \|\widetilde{g}(\mathbf{w}_t)\|_*)^2 + \frac{1}{2} (\eta \|\widetilde{g}(\mathbf{w}_t)\|_*)^2 \quad (4.69)$$

$$\leq \frac{\eta^2 \|\widetilde{g}(\mathbf{w}_t)\|_*^2}{2} \quad (4.70)$$

其中 $\|\mathbf{w}\|^2 = a\|\boldsymbol{\mu}\|_1^2 + b\|\boldsymbol{\alpha}\|_2^2$ ， $\|\mathbf{w}\|_*^2 = \|\boldsymbol{\mu}\|_\infty^2/a + \|\boldsymbol{\alpha}\|_2^2/b$ ， $\|\cdot\|_*$ 是 $\|\cdot\|$ 的对偶范数（dual norm）。第一个不等号是因为 $\Phi(\cdot)$ 是关于范数 $\|\cdot\|$ 的 1-强凸函数（strongly convex function），第二个不等号是根据赫尔德不等式（Hölder's inequality）。

由于 $|G(\boldsymbol{\alpha}, \hat{\mathbf{y}}_k)| \leq L_1$ 、 $\|\partial_\alpha G(\boldsymbol{\alpha}, \hat{\mathbf{y}}_k)\|_2 \leq L_2$ ，因此

$$\|\widetilde{g}(\mathbf{w}_t)\|_*^2 = \frac{1}{a} \|\partial_\mu \widetilde{\varphi}(\mathbf{w}_t, i_t)\|_\infty^2 + \frac{1}{b} \|\partial_\alpha \widetilde{\varphi}(\mathbf{w}_t, j_t)\|_2^2 \quad (4.71)$$

$$\leq \frac{1}{a} |\mathcal{B}|^2 L_1^2 + \frac{1}{b} L_2^2 = |\mathcal{B}| L_1 \sqrt{\log |\mathcal{B}|} + L_2 \tau \sqrt{m/2} \quad (4.72)$$

又

$$\Delta_{\Phi}(\mathbf{w}, \mathbf{w}_1) = \Phi(\mathbf{w}) - \Phi(\mathbf{w}_1) - \nabla\Phi(\mathbf{w}_1)^{\top}(\mathbf{w} - \mathbf{w}_1) \quad (4.73)$$

$$= a\mu \log(\mu/\mu_1) + b\|\mu - \mu_1\|_2^2/2 \quad (4.74)$$

$$\leq a \log |\mathcal{B}| + bm\tau^2/2 \quad (4.75)$$

$$= |\mathcal{B}|L_1 \sqrt{\log |\mathcal{B}|} + L_2\tau \sqrt{m/2}. \quad (4.76)$$

合到一起有

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}[\widetilde{g}(\mathbf{w}_t)^{\top}(\mathbf{w}_t - \mathbf{w})] \leq \frac{1}{T} \sum_{t=1}^T \frac{\eta \|\widetilde{g}(\mathbf{w}_t)\|_*^2}{2} + \frac{\Delta_{\Phi}(\mathbf{w}, \mathbf{w}_1) - \Delta_{\Phi}(\mathbf{w}, \mathbf{w}_{T+1})}{\eta T} \quad (4.77)$$

$$= (|\mathcal{B}|L_1 \sqrt{\log |\mathcal{B}|} + L_2\tau \sqrt{m/2}) \left(\frac{\eta}{2} + \frac{1}{\eta T} \right). \quad (4.78)$$

代入 $\eta = \sqrt{2/T}$ 可知定理结论成立。 $\square$

该定理表明对偶间隙以 $O(1/\sqrt{T})$ 的速率下降，即要想得到精度为 ϵ 的解，算法需要迭代 $O(1/\epsilon^2)$ 轮，这与基于割平面的方法是相同的。

4.4 实验验证

本节我们通过实验验证 ODMC 的性能。4.4.1节和4.4.2节分别介绍实验设置与对比方法。4.4.3展示了 ODMC 在 24 个 UCI 数据集上的性能。最后4.4.4节对比了 IterSVR^[134]、CPMMC^[142]、LG-MMC^[71] 和 ODMC 的时间开销。

4.4.1 实验设置

实验中共用到 24 个 UCI 数据集，表 4.1 列出了这些数据集的所有信息。可以看出，这 24 个数据集，样本数最小的仅有 62 个，最大的有 3,175 个，特征数的跨度也很大，小至 2，大到 4,702，因此可以说覆盖了很大的范围。对于每个数据集，所有的特征都归一化到 $[0, 1]$ 之间。

我们将样本簇的个数就设为每个数据集上的真实类别数，对于每种方法，统计聚类精度^[131] 和 Rand 指数^[91]。

表 4.1: 数据集信息

ID	数据集	样本数	特征数	ID	数据集	样本数	特征数
1	<i>echocardiogram</i>	62	8	13	<i>ionosphere</i>	351	33
2	<i>dbworld</i>	64	4,702	14	<i>vehicle</i>	435	16
3	<i>hepatitis</i>	80	19	15	<i>credit-a</i>	653	15
4	<i>colic</i>	188	13	16	<i>diabetes</i>	768	8
5	<i>house</i>	232	16	17	<i>fourclass</i>	862	2
6	<i>heart-h</i>	261	10	18	<i>tic-tac-toe</i>	958	9
7	<i>heart</i>	270	9	19	<i>credit-g</i>	1,000	20
8	<i>heart-statlog</i>	270	13	20	<i>german</i>	1,000	59
9	<i>breast</i>	277	9	21	<i>optdigits</i>	1,143	42
10	<i>cylinder-bands</i>	277	39	22	<i>svmguide3</i>	1,284	22
11	<i>heart-c</i>	296	13	23	<i>sick</i>	2,643	28
12	<i>haberman</i>	306	14	24	<i>splice</i>	3,175	60

4.4.2 对比方法

ODMC 的对比方法有 k -均值、归一化切割 (normalized cut, 简称 NC)^[104]、基于 SDP 放松的 GMMC^[119]、交替优化非凸问题的 IterSVR^[134]、基于割平面方法的 CPMMC^[142]，以及基于极大极小不等式放松的 LG-MMC^[71]。MMC^[131] 未被纳入对比方法是因为即使在最小的数据集上，都无法在 48 小时内输出结果。

对于 GMMC、IterSVR、CPMMC、LG-MMC、ODMC，参数 C 和 λ 通过 5-折交叉验证从集合 $\{2^0, 2^2, \dots, 2^{20}\}$ 中选取。对于 ODMC，参数 μ 和 θ 通过 5-折交叉验证从集合 $\{0.2, 0.4, 0.6, 0.8\}$ 中选取，对所有方法，输出线性核和高斯核中的最好结果，其中高斯核的“带宽”参数 σ 通过 5-折交叉验证从集合 $\{2^{-4}\delta, 2^{-2}\delta, 2^0\delta, 2^2\delta, 2^4\delta\}$ 中选取，其中 δ 是特征数的倒数。类别平衡约束的参数按照和^[134]中相同的方式进行设置：对平衡数据集设为 $0.03m$ ，对非平衡数据集设为 $0.3m$ 。所有实验重复 10 次，记录平均性能。

4.4.3 实验结果

表 4.2 和表 4.2 分别展示了所有算法在 24 个 UCI 数据集上取得的聚类精度和 Rand 指数的结果。GMMC 由于是基于 SDP 放松的，计算开销较大，在部分数据集上无法在 48 小时内输出结果。可以看出，无论哪个评价指标，ODMC

表 4.2: 24 个 UCI 数据集上的聚类精度, 每个数据集上的最好结果加粗显示, ●/○ 表示在 95% 置信度的成对 t -检验下, ODMC 的结果显著好于/差于对比方法, GMMC 因为基于 SDP 放松, 计算开销较大, 在部分数据集上无法在 48 小时内输出结果

数据集	KM	NC	GMMC	IterSVR	CPMMC	LG-MMC	ODMC
<i>echocardiogram</i>	69.6●	67.7●	69.4●	53.7●	71.0●	77.4●	79.2
<i>dbworld</i>	59.9●	62.5●	57.8●	84.0	54.7●	85.9	85.7
<i>hepatitis</i>	69.3●	52.5●	57.5●	63.8●	83.8	83.8	84.1
<i>colic</i>	74.9●	62.2●	53.7●	74.0●	62.2●	84.0●	86.2
<i>house</i>	89.3	53.4●	73.7●	90.1	53.4●	90.5	90.2
<i>heart-h</i>	74.2●	53.6●	61.7●	78.0	62.5●	78.9	79.5
<i>heart</i>	67.0●	56.7●	56.3●	68.4●	55.6●	74.4●	77.2
<i>heart-statlog</i>	76.5●	50.4●	74.1●	76.1●	55.6●	79.6●	81.1
<i>breast</i>	62.9●	59.2●	53.8●	57.5●	70.8●	72.6	72.6
<i>cylinder-bands</i>	63.4●	53.4●	57.4●	62.6●	64.3●	65.7●	67.5
<i>heart-c</i>	66.2●	55.1●	58.8●	78.0	54.1●	77.7	77.5
<i>haberman</i>	60.4●	73.5	58.2●	52.0●	73.5	73.9	73.6
<i>ionosphere</i>	70.8●	54.1●	72.1●	69.1●	64.1●	73.8●	75.4
<i>vehicle</i>	65.9●	51.0●	55.4●	69.3●	50.1●	71.5●	74.2
<i>credit-a</i>	73.0●	57.6●	52.2●	77.1	54.7●	77.2	77.0
<i>diabetes</i>	66.7●	63.7●	66.3●	62.9●	65.1●	73.3●	74.5
<i>fourclass</i>	65.9●	62.4●	51.5●	64.0●	64.4●	76.3●	78.8
<i>tic-tac-toe</i>	54.7●	55.1●	51.1●	54.8●	65.3	65.3	65.8
<i>credit-g</i>	53.9●	68.3●	N/A	53.4●	70.0	70.4	71.0
<i>german</i>	56.9●	70.0	N/A	54.6●	70.0	70.0	70.0
<i>optdigits</i>	96.2●	50.1●	N/A	99.5 ○	50.0●	97.8	98.0
<i>svmguide3</i>	59.3●	65.7●	N/A	57.2●	73.8	73.9	74.1
<i>sick</i>	73.1●	51.8●	N/A	51.5●	92.0	92.0	92.0
<i>splice</i>	66.5	51.9●	N/A	63.0●	51.9●	64.1	65.5
ODMC: 胜/平/负	22/2/0	22/2/0	18/0/0	18/5/1	17/7/0	9/15/0	

都显著好于基于 MMC 的方法。具体来说, 在全部 24 个 UCI 数据集上, 关于聚类精度 ODMC 显著好于 KM/NC/GMMC/IterSVR/CPMMC/LG-MMC 的次数分别是 22/22/18/18/17/9 次, 并且在 17 个数据集上取得最好结果; 关于 Rand 指数, ODMC 显著好于 KM/NC/GMMC/IterSVR/CPMMC/LG-MMC 的次数分别是 22/22/18/19/17/9 次, 并且在 17 个数据集上取得最好结果。

表 4.3: 24 个 UCI 数据集上的 Rand 指数, 每个数据集上的最好结果加粗显示, ●/○ 表示在 95% 置信度的成对 t -检验下, ODMC 的结果显著好于/差于对比方法, GMMC 因为基于 SDP 放松, 计算开销较大, 在部分数据集上无法在 48 小时内输出结果

数据集	KM	NC	GMMC	IterSVR	CPMMC	LG-MMC	ODMC
<i>echocardiogram</i>	57.2●	55.6●	56.8●	49.8●	58.1●	64.5●	66.1
<i>dbworld</i>	53.4●	52.4●	50.4●	74.3●	49.7●	75.4	74.8
<i>hepatitis</i>	57.6●	49.5●	50.5●	53.4●	72.4	72.4	73.1
<i>colic</i>	62.2●	52.7●	50.0●	61.3●	52.7●	73.0●	75.2
<i>house</i>	80.8●	50.0●	61.1●	82.1	50.0●	82.8	82.5
<i>heart-h</i>	63.6●	50.1●	52.5●	66.2	52.9●	66.6	66.9
<i>heart</i>	57.2●	50.7●	50.6●	58.9●	50.4●	61.8●	63.7
<i>heart-statlog</i>	64.9●	49.8●	61.4●	64.5●	50.4●	67.4	68.1
<i>breast</i>	55.0●	51.5●	50.1●	51.8●	58.5●	60.0	60.0
<i>cylinder-bands</i>	53.4●	50.1●	50.9●	53.0●	53.9●	54.8●	57.1
<i>heart-c</i>	55.9●	50.3●	51.4●	65.7	50.2●	65.2	65.2
<i>haberman</i>	53.0●	60.9	51.2●	50.0●	60.9	61.3	61.1
<i>ionosphere</i>	58.6●	50.2●	59.6●	57.2●	53.8●	61.2●	63.6
<i>vehicle</i>	55.6●	49.9●	50.5●	58.1●	49.9●	59.1●	62.4
<i>credit-a</i>	63.6●	51.1●	50.0●	66.9	50.4●	64.7●	66.2
<i>diabetes</i>	55.5●	53.7●	55.2●	53.3●	54.5●	60.8●	62.5
<i>fourclass</i>	55.2●	53.0●	50.0●	54.6●	54.1●	63.8●	66.6
<i>tic-tac-toe</i>	50.4●	50.5●	50.0●	50.5●	54.7	54.7	55.1
<i>credit-g</i>	50.7●	56.7●	N/A	50.9●	58.0	58.3	58.5
<i>german</i>	51.0●	58.0	N/A	50.5●	58.0	58.0	58.0
<i>optdigits</i>	95.2	50.0●	N/A	98.9 ○	50.0●	95.7	95.8
<i>svmguide3</i>	51.8●	54.9●	N/A	51.1●	61.3	61.4	61.8
<i>sick</i>	62.8●	50.0●	N/A	50.1●	85.2	85.2	85.2
<i>splice</i>	55.4	50.1●	N/A	53.4●	50.1●	53.9	55.0
ODMC: 胜/平/负	22/2/0	22/2/0	18/0/0	19/4/1	17/7/0	9/15/0	

4.4.4 时间开销

本节我们对比 IterSVR、CPMMC、LG-MMC、ODMC 在部分数据集上的时间开销, 所有实验都是在同一台拥有 2.6G 赫兹主频 *8 核 CPU、32GB 主存的服务器上, 求解的软件是 MATLAB (2012b)。IterSVR 和 LG-MMC 的

子问题 SVR、SVM 都通过软件包 LIBSVM^[15] 求解。最终的平均时间开销（单位：秒）如图 4.2 所示，不难看出我们的方法在大部分数据集上都快于其他方法，除了在数据集上 credit-g。




图 4.2: IterSVR、CPMMC、LG-MMC、ODMC 在部分数据集上的时间开销

4.5 小结

本文提出了面向聚类问题的最优间隔分布学习机 ODMC。对于聚类问题，一个好的结果是在将簇标记指派给每个簇之后，可以寻找一个划分超平面在这个“有监督”数据集上产生最优间隔分布。因此 ODMC 同时优化簇标记和间隔分布，最终形式化出的问题是一个混合整数规划，难以直接求解，本文采用极大极小技巧先将其放松成一个鞍点问题，然后提出一种基于随机镜像下降的方法进行求解。最终实验表明 ODMC 的聚类性能显著优于、且在最坏情况下不差于优化最小间隔的聚类方法。在以后的工作中，值得研究的问题包括如何设计更好的优化算法来加速 ODMC。

本章的主要工作已总结成文：

- T. Zhang and Z.-H. Zhou. Optimal margin distribution clustering. In: **Proceedings of the 32nd AAAI Conference on Artificial Intelligence (AAAI'18)**, New Orleans, LA, 2018, pp.4474-4481. (CCF A 类会议)

第五章 半监督最优间隔 分布学习机

5.1 引言

现实世界中有些学习任务，获取其样本的类别标记的代价是很昂贵的，甚至是不现实的。例如，在进行计算机辅助医学影像分析时，可以从医院获得大量医学影像，但若希望医学专家把影像中的病灶全都标识出来则是不可能的。在商品推荐中，需要用户对商品进行评价，但很少有用户愿意花时间来给商品打分，因此有用户评分的商品只是少数，大部分商品是没有用户评分的，类似场景非常多见。

用数学符号表示就是现在的数据集 D 由两部分构成 $D = D_l \cup D_u$ ，其中 $D_l = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_l, y_l)\}$ 是“有标记”（labeled）数据集， $D_u = \{\mathbf{x}_{l+1}, \dots, \mathbf{x}_{l+u}\}$ 是“未标记”（unlabeled）数据集， $l \ll u$ 。此时最简单的方法就是忽略未标记数据，直接使用传统监督学习技术，那么只有 D_l 可以用来构建模型， D_u 所包含的信息都被浪费了。另一方面，若 D_l 较小，则用于训练的样本个数不够多，学得模型的泛化能力往往不佳，因此更好的方法是在构建学习模型的过程中将 D_u 也利用起来，这就是“半监督学习”，它提供了一条利用“廉价”的大量未标记样本的途径。

如果要利用未标记样本辅助学习，必然要假设它所揭示的数据分布信息与类别标记是有联系的，否则可能会适得其反，还不如不用。最常见的假设是“聚类假设”（cluster assumption），即数据存在簇结构，同一个簇的样本属于同一个类别。这样未标记样本可以起到一个“桥梁”的作用，将待预测样本和有标记样本联系起来。另一种常见的假设是“流形假设”（manifold assumption），即假设数据分布在一个流形结构上，邻近的样本应该有相似的输出值。流形假设可以看作聚类假设的推广，但流形假设对输出值没有限制，只要求“相似”不要求“相同”，因此比聚类假设的适用范围更广，可用于更多类型的学习任务。事实上，无论聚类假设还是流形假设，其本质都是“相似的样本拥有相似的输

出”这个基本假设。

半监督学习根据最终目标的不同可以分为两类：纯（pure）半监督学习和直推式学习（transductive learning），前者假定训练数据中的未标记样本并非待预测的数据，而只是作辅助构建模型用；后者则假设未标记样本就是待预测数据，学习的目的就是在这些未标记样本上获得最好的泛化性能。

半监督学习算法大致可以分为如下四大类^[158]：

第一大类是生成式方法（generative methods），这类算法假设所有数据都是由同一个潜在的模型“生成”的，这使得我们能通过潜在模型的参数将未标记数据与学习目标联系起来。具体来说，由条件概率公式有 $P(\mathbf{x}) = P(y)P(\mathbf{x}|y)$ ，其中 $P(\mathbf{x}|y)$ 就将未标记数据和类别标记联系了起来。一般假设 $P(\mathbf{x}|y)$ 为高斯混合模型（Gaussian mixture model），即

$$P(\mathbf{x}) = \sum_i P(y_i)P(\mathbf{x}|y_i) \quad (5.1)$$

其中 y_i 是第 i 个混合成分的类别标记，因此不难看出生成式方法是基于聚类假设的。每个高斯分布的参数，通常用期望最大化（Expectation Maximization，简称 EM）算法来估计，然后再利用少量的有标记样本确定各混合成分所代表的类别。

这类算法简单，易于实现，在有标记数据极少的情形下往往比其它方法性能更好，但前提是对模型的假设必须准确。此外，EM 算法只能取得局部最优解也是较难克服的问题，而且该类算法很难分析^[16]。

第二大类是基于分歧的方法（disagreement-based methods）^[157]，其中最具代表性的是“协同训练”（co-training）^[8,148]。这类方法通常将特征集合划分为若干不相交的子集，然后在每个子集上基于有标记样本分别训练出一个分类器，并让每个分类器分别去挑选自己最有把握的未标记样本赋予伪类别标记，这些伪标记样本将被提供给其它分类器作为新增的有标记样本用于训练更新，于是不断重复这个“互相帮助、共同进步”的过程直到收敛，或达到预先设定的迭代轮数。

这些子集有个专门的名字叫“视图”（view），协同训练的假设是不同的视图间须条件独立，且每个视图都包含足以产生最优分类器的信息，此时利用未标记样本可将每个视图上的分类器的泛化性能提升到任意高。但是现实任务中这个假设通常很难满足，因此性能提升幅度不会那么大，但是有研究表明，即使在更弱的条件下，协同训练仍可有效地提升每个单独的分类器的性能。

第三大类是基于图的半监督算法，这类算法基于流形假设。给定一个数据集，先将其映射为一个无向图，数据集中每个样本（包括有标记样本和未标记样本）对应于图中一个结点，若两个样本之间的相似度很高，则对应的结点之间存在一条边，边上的“权重”正比于样本之间的相似度。于是半监督学习的目标变成学习一个实值函数 $f: \mathcal{X} \mapsto \mathbb{R}$ 最小化如下的“能量函数”（energy function）^[153]

$$E(f) = \sum_{i,j=1}^m w_{ij}(f(\mathbf{x}_i) - f(\mathbf{x}_j))^2 = \mathbf{f}^\top (\mathbf{D} - \mathbf{W}) \mathbf{f} \quad (5.2)$$

其中 w_{ij} 就是 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 之间连边的权重，表示两个样本间的相似程度， $\mathbf{f} = [f(\mathbf{x}_1); \dots; f(\mathbf{x}_{l+u})]$ ， $\mathbf{D}$ 是一个对角阵，其对角线元素 d_{ii} 为 $\mathbf{W}$ 的第 i 行行和，即 $d_{ii} = \sum_{j=1}^{l+u} w_{ij}$ 。

图半监督学习方法很容易通过对矩阵运算的分析来探索算法性质，但此类算法的缺陷也相当明显：一是无法处理大规模数据集，因为算法中所涉及的矩阵规模为 $O(m^2)$ ；二是当出现新的未标记样本时，整个图要重构，上面的优化问题也要重新解，非常麻烦。

第四大类是基于低密度分隔（low-density separation）的方法，就是要尽量让划分超平面通过密度较低区域，这是对聚类假设的另一种描述。再将最大间隔准则考虑进来就得到了半监督支持向量机（Semi-Supervised Support Vector Machine，简称 S3VM）^[6]。

S3VM 中最著名的是直推式 SVM（Transductive Support Vector Machine，简称 TSVM）^[53]，其试图对未标记样本赋予各种可能的类别标记，即尝试将每个未标记样本分别作为正类样本和负类样本，然后在所有这些结果中，寻找一个在所有样本（包括有标记样本和进行了类别标记赋予的未标记样本）上间隔最大化的划分超平面，一旦划分超平面得以确定，未标记样本的最终类别标记也就确定了，其最终形式化为：

$$\min_{\hat{\mathbf{y}}} \min_{\mathbf{w}, \xi_i} \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda_1}{l} \sum_{i=1}^l \xi_i + \frac{\lambda_2}{u} \sum_{i=l+1}^{l+u} \xi_i \quad (5.3)$$

$$\text{s.t.} \quad y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \xi_i, \quad i \in [l] \quad (5.4)$$

$$\hat{y}_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 - \xi_i, \quad i \in [l+u] \setminus [l] \quad (5.5)$$

$$\xi_i \geq 0, \quad \forall i \in [m] \quad (5.6)$$

此外还有如下一些变种：

- 拉普拉斯 SVM (Laplacian SVM) ^[5], S3VM 与基于图的半监督算法相结合的产物, 它将 TSVM 中未标记样本的损失部分换成了上面的能量函数。
- MeanS3VM^[70] 不考虑直接给每个未标记样本赋予类别标记, 而是考虑一个较简单的问题: 估计两类未标记样本的均值 (label mean), 这样算法的计算开销大大降低, 而且有理论保证, 这样得到的划分超平面与知道全部未标记样本的真实类别标记训练出的 SVM 的划分超平面很接近。
- CS4VM^[72] 则是为不同类别的误分类引入了不同的代价。
- S4VM (Safe S3VM) ^[69] 则是追求安全的 S3VM, 即只要用了未标记数据, 就一定可以提升性能。

5.2 问题形式化

将最优间隔分布学习的思想引入到半监督问题中, 就是要求将类别标记赋予给每个未标记样本时, 在此“有监督数据”上可以训练得到一个有好的间隔分布的划分超平面。回想二分类核 ODM 的形式化为

$$\min_{\mathbf{w}, \xi_i, \epsilon_i} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda}{m} \sum_{i=1}^m \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} \quad (5.7)$$

$$\text{s.t. } y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i \quad (5.8)$$

$$y_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \forall i \in [m] \quad (5.9)$$

记 $\hat{\mathbf{y}} = [\hat{y}_1, \dots, \hat{y}_m] \in \{\pm 1\}^m$ 表示未知类别标记, 则半监督最优间隔分布学习机 (Semi-Supervised Optimal margin Distribution Machine, 简称 ssODM) 可以形式化为

$$\min_{\hat{\mathbf{y}} \in \mathcal{B}} \min_{\mathbf{w}, \xi_i, \epsilon_i} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{\lambda_1}{l} \sum_{i=1}^l \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} + \frac{\lambda_2}{u} \sum_{i=l+1}^{l+u} \frac{\xi_i^2 + \mu \epsilon_i^2}{(1 - \theta)^2} \quad (5.10)$$

$$\text{s.t. } \hat{y}_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i$$

$$\hat{y}_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \forall i \in [m]$$

其中 $\mathcal{B}$ 是为了防止出现平凡解而引入的平衡性约束:

$$\mathcal{B} = \left\{ \hat{\mathbf{y}} \mid \frac{\mathbf{e}^\top \hat{\mathbf{y}}_U}{m - l} = \frac{\mathbf{e}^\top \mathbf{y}_L}{l} \right\} \quad (5.11)$$

记 $\lambda_i = \frac{\lambda_1(m-l)-\lambda_2 l}{l(m-l)} 1_{i \in L} + \frac{\lambda_2}{m-l}$, and λ_1, λ_2 , 则上述问题可进一步写成:

$$\begin{aligned} \min_{\hat{\mathbf{y}} \in \mathcal{B}} \min_{\mathbf{w}, \xi_i, \epsilon_i} & \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \lambda_i \frac{\xi_i^2 + \mu \epsilon_i^2}{(1-\theta)^2} \\ \text{s.t.} & \hat{\mathbf{y}}_i \mathbf{w}^\top \phi(\mathbf{x}_i) \geq 1 - \theta - \xi_i, \\ & \hat{\mathbf{y}}_i \mathbf{w}^\top \phi(\mathbf{x}_i) \leq 1 + \theta + \epsilon_i, \forall i \in [m] \end{aligned} \quad (5.12)$$

由于核的存在, 问题 (5.12) 的内部问题一般通过对偶形式来解决,

$$\begin{aligned} \min_{\hat{\mathbf{y}} \in \mathcal{B}} \max_{\alpha \geq 0} & -\frac{1}{2} \alpha^\top \begin{bmatrix} \mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top & -\mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top \\ -\mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top & \mathbf{K} \odot \hat{\mathbf{y}} \hat{\mathbf{y}}^\top \end{bmatrix} \alpha \\ & - \frac{(1-\theta)^2}{4} \alpha^\top \begin{bmatrix} \mathbf{I} \oslash \lambda & \mathbf{0} \\ \mathbf{0} & \frac{1}{\mu} \mathbf{I} \oslash \lambda \end{bmatrix} \alpha - \begin{bmatrix} (\theta-1)\mathbf{e} \\ (\theta+1)\mathbf{e} \end{bmatrix}^\top \alpha \end{aligned} \quad (5.13)$$

其中 $\odot$ 和 $\oslash$ 分别表示按位乘和按位除。问题 (5.13) 依然还是个混合整数规划问题, 此时有两种处理的技巧: 第一种是将 $\hat{\mathbf{y}} \hat{\mathbf{y}}^\top$ 用一个半正定矩阵 $\mathbf{M}$ 替代掉, 并将非凸约束 $\mathbf{M} = \hat{\mathbf{y}} \hat{\mathbf{y}}^\top$ 用一些线性约束替代掉, 从而得到一个 SDP 问题。第二种是通过极大极小不等式来放松, 即将 $\min$ 和 $\max$ 的顺序调换, 考虑原问题的一个下界。Li 等人^[71,73] 已经指出基于极大极小不等式的放松比基于 SDP 的放松要紧, 因此我们也选择这种放松方式。为了表示方便, 我们记 (5.13) 式中的目标函数为 $G(\alpha, \hat{\mathbf{y}})$, 并记 α 的可行域为 $\mathcal{A}$, 于是放松后的问题为

$$\max_{\alpha \in \mathcal{A}} \min_{\hat{\mathbf{y}} \in \mathcal{B}} G(\alpha, \hat{\mathbf{y}}) \quad (5.14)$$

将 $\min_{\hat{\mathbf{y}} \in \mathcal{B}}$ 交换到内层的好处是可以将其吸收进目标函数中, 从而避免了对整型优化变量的处理, 下面对内部问题进行改写:

$$\max_{\alpha \in \mathcal{A}} \min_{\delta} (-\delta) \quad (5.15)$$

$$\text{s.t.} \quad G(\alpha, \hat{\mathbf{y}}_k) \geq \delta, \forall \hat{\mathbf{y}}_k \in \mathcal{B} \quad (5.16)$$

为约束引入拉格朗日乘子 $\mu \geq 0$, 于是得到拉格朗日函数:

$$L(\delta, \mu) = -\delta - \sum_{k: \hat{\mathbf{y}}_k \in \mathcal{B}} \mu_k (G(\alpha, \hat{\mathbf{y}}_k) - \delta) \quad (5.17)$$

为了求得对偶函数, 需令拉格朗日函数关于原始优化变量 δ 取极小, 求导并令导

数为零可得

$$\frac{\partial L}{\partial \delta} = -1 + \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k = 0 \longrightarrow \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k = 1 \quad (5.18)$$

即 μ 属于某个单纯形 $\mathcal{M}$ ，回代入拉格朗日函数可得对偶函数：

$$g(\mu) = - \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k G(\alpha, \hat{y}_k) \quad (5.19)$$

令对偶函数关于拉格朗日乘子 μ 取极大可得对偶问题：

$$\max_{\alpha \in \mathcal{A}} \max_{\mu \in \mathcal{M}} - \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k G(\alpha, \hat{y}_k) \quad (5.20)$$

记 $\varphi(\mu, \alpha) = \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k G(\alpha, \hat{y}_k)$ ，则上述问题等价于

$$\max_{\alpha \in \mathcal{A}} \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha) \quad (5.21)$$

注意 $G(\alpha, \hat{y}_k)$ 是关于 α 的负定二次型，因此 $\varphi(\mu, \alpha)$ 是负定二次型的非负组合，因此它关于 α 是凹的，关于 μ 是线性的，当然也是凸的，因此由极大极小定理^[108]可知存在鞍点 $(\hat{\mu}, \hat{\alpha}) \in \mathcal{M} \times \mathcal{A}$ 使得下式成立

$$\begin{aligned} \min_{\mu \in \mathcal{M}} \max_{\alpha \in \mathcal{A}} \varphi(\mu, \alpha) &\leq \max_{\alpha \in \mathcal{A}} \varphi(\hat{\mu}, \alpha) = \varphi(\hat{\mu}, \hat{\alpha}) \\ &= \min_{\mu \in \mathcal{M}} \varphi(\mu, \hat{\alpha}) \leq \max_{\alpha \in \mathcal{A}} \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha) \end{aligned} \quad (5.22)$$

结合极大极小不等式^[60]

$$\max_{\alpha \in \mathcal{A}} \min_{\mu \in \mathcal{M}} \varphi(\mu, \alpha) \leq \min_{\mu \in \mathcal{M}} \max_{\alpha \in \mathcal{A}} \varphi(\mu, \alpha), \quad (5.23)$$

可知 (5.22) 式中的不等号全部取等号，于是 ssODM 最终的形式化为

$$\min_{\mu \in \mathcal{M}} \max_{\alpha \in \mathcal{A}} \varphi(\mu, \alpha) \quad (5.24)$$

求得极大极小问题 (5.24) 的鞍点 $(\hat{\mu}, \hat{\alpha})$ 后，可以通过下式预测未标记样本的类别标记：

$$\text{sign} \sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k^* \hat{y}_k \quad (5.25)$$

5.3 优化算法

本节我们先给出一个基于随机镜像近端下降的求解方法，最后给出收敛率分析。

5.3.1 随机镜像近端下降

注意优化变量 μ 、 α 的可行域分别是单纯形和箱型约束，若直接套用黑盒算法投影梯度下降，则没有将这些结构信息充分利用起来，对于此类问题，最常用的是镜像下降（mirror descent），又由于优化目标函数是平滑的，镜像下降可以进一步加速到 $O(1/t)$ 的收敛率，这就是镜像近端下降（mirror prox）^[82]。

这两个域上最合适的镜像映射分别为

$$\Phi_{\mathcal{M}}(\mu) = \sum_k \mu_k \log \mu_k \quad (5.26)$$

$$\Phi_{\mathcal{A}}(\alpha) = \frac{1}{2} \|\alpha\|_2^2 \quad (5.27)$$

引入联合映射 $\Phi(w) = a\Phi_{\mathcal{M}}(\mu) + b\Phi_{\mathcal{A}}(\alpha)$ ，其中 a 和 b 是待定参数。易知有

$$\nabla \Phi_{\mathcal{M}}(\mu) = \log \mu + e \quad (5.28)$$

$$\nabla \Phi_{\mathcal{A}}(\alpha) = \alpha \quad (5.29)$$

$$\nabla \Phi(w) = (a \log \mu + ae, b\alpha) \quad (5.30)$$

在第 t -轮迭代中，我们先将 $w_t = (\mu_t, \alpha_t)$ 通过 $\nabla \Phi(w_t) = (a \log \mu_t + ae, b\alpha_t)$ 映射到对偶空间，然后在对偶空间做一步梯度下降，

$$\nabla \Phi(y_{t+1}) = \nabla \Phi(w_t) - \eta \tilde{g}(w_t) \quad (5.31)$$

$$= (a \log \mu_t + ae - \eta \partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t), b\alpha_t + \eta \partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t)) \quad (5.32)$$

其中 $\partial_{\mu} \tilde{\varphi}$ 、 $\partial_{\alpha} \tilde{\varphi}$ 、 $\tilde{g}$ 分别是 $\partial_{\mu} \varphi$ 、 $\partial_{\alpha} \varphi$ 、 g 的无偏估计， η 是步长。然后将 $\nabla \Phi(y_{t+1})$ 映射回原始空间，即求 $y_{t+1} = (u_{t+1}, v_{t+1})$ 使得

$$a \log u_{t+1} + ae = a \log \mu_t + ae - \eta \partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t) \quad (5.33)$$

$$bv_{t+1} = b\alpha_t + \eta \partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t) \quad (5.34)$$

经过简单的代数运算可得

$$\mathbf{u}_{t+1} = \boldsymbol{\mu}_t \exp\left(-\frac{\eta}{a} \partial_{\boldsymbol{\mu}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t)\right) \quad (5.35)$$

$$\mathbf{v}_{t+1} = \boldsymbol{\alpha}_t + \frac{\eta}{b} \partial_{\boldsymbol{\alpha}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t) \quad (5.36)$$

最后将 $(\mathbf{u}_{t+1}, \mathbf{v}_{t+1})$ 投影回可行域 $\mathcal{M} \times \mathcal{A}$ ，其中前者基于 Kullback-Leibler 距离，后者基于标准的 Euclidean 距离，即求解如下两个子优化问题：

$$\boldsymbol{\mu} = \arg \min_{\boldsymbol{\mu} \in \mathcal{M}} \boldsymbol{\mu}^\top \log \frac{\boldsymbol{\mu}}{\mathbf{u}_{t+1}} \quad (5.37)$$

$$\boldsymbol{\alpha} = \arg \min_{\boldsymbol{\alpha} \in \mathcal{A}} \|\boldsymbol{\alpha} - \mathbf{v}_{t+1}\|_2^2, \quad (5.38)$$

幸运的是这两个问题都是有闭式解的，后者是将 $\mathbf{v}_{t+1}$ 往箱型约束上投影，只需超出部分取边界即可：

$$\boldsymbol{\alpha}_{t+1} = \max\{\min\{\mathbf{v}_{t+1}, \tau \mathbf{e}\}, \mathbf{0}\} \quad (5.39)$$

对于前者，引入拉格朗日乘子 $\zeta \geq 0$ 可得拉格朗日函数：

$$L(\boldsymbol{\mu}, \zeta) = \boldsymbol{\mu}^\top \log \frac{\boldsymbol{\mu}}{\mathbf{u}_{t+1}} + \zeta(\mathbf{e}^\top \boldsymbol{\mu} - 1) \quad (5.40)$$

为了求得对偶函数，需令拉格朗日函数关于原始优化变量 $\boldsymbol{\mu}$ 取极小，故求导并令导数为零可得：

$$\log(\boldsymbol{\mu}/\mathbf{u}_{t+1}) + \mathbf{e} + \zeta \mathbf{e} = \mathbf{0} \longrightarrow \boldsymbol{\mu}_{t+1} = \mathbf{u}_{t+1} \exp(-1 - \zeta) \quad (5.41)$$

由于 $\boldsymbol{\mu}_{t+1}$ 属于单纯形，因此有

$$1 = \mathbf{e}^\top \boldsymbol{\mu}_{t+1} = \mathbf{e}^\top \mathbf{u}_{t+1} \exp(-1 - \zeta) = \|\mathbf{u}_{t+1}\|_1 \exp(-1 - \zeta) \quad (5.42)$$

这意味着 $\exp(-1 - \zeta) = 1/\|\mathbf{u}_{t+1}\|_1$ ，从而有 $\boldsymbol{\mu}_{t+1} = \mathbf{u}_{t+1}/\|\mathbf{u}_{t+1}\|_1$ 。

一旦有了 $\mathbf{y}_{t+1} = (\bar{\boldsymbol{\mu}}_{t+1}, \bar{\boldsymbol{\alpha}}_{t+1})$ ，再次重复上述过程，只不过这次在对偶空间使用的是 $\mathbf{y}_{t+1}$ 处的梯度，而不是 $\mathbf{w}_t$ 处的，换句话说镜像近端下降每轮做两步镜像下降，下降的点是一样的，只是使用的梯度方向不同。图 5.1 给出了随机镜像近端下降一轮迭代的示意图。

最后剩下的是如何求得随机梯度 $\partial_{\boldsymbol{\mu}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t)$ 和 $\partial_{\boldsymbol{\alpha}} \tilde{\varphi}(\boldsymbol{\mu}_t, \boldsymbol{\alpha}_t)$ 。注意 $\varphi(\boldsymbol{\mu}, \boldsymbol{\alpha}) =$




图 5.1: 随机镜像近端下降一轮迭代的示意图

$\sum_{k: \hat{y}_k \in \mathcal{B}} \mu_k G(\alpha, \hat{y}_k)$, 于是有

$$\partial_{\mu} \varphi(\mu_t, \alpha_t) = [G(\alpha_t, \hat{y}_1), \dots, G(\alpha_t, \hat{y}_{|\mathcal{B}|})] \quad (5.43)$$

$$\partial_{\alpha} \varphi(\mu_t, \alpha_t) = [\partial_{\alpha} G(\alpha_t, \hat{y}_1), \dots, \partial_{\alpha} G(\alpha_t, \hat{y}_{|\mathcal{B}|})] \mu_t \quad (5.44)$$

从 $\{1, 2, \dots, |\mathcal{B}|\}$ 中均匀采样 i_t , 则 $\partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t, i_t) = [0, \dots, |\mathcal{B}|G(\alpha_t, \hat{y}_{i_t}), \dots, 0]$; 另一方面从 $\{1, 2, \dots, |\mathcal{B}|\}$ 中根据分布 μ_t 采样 j_t , 则有 $\partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t, j_t) = \partial_{\alpha} G(\alpha_t, \hat{y}_{j_t})$, 于是

$$\mathbb{E}[\partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t, i_t) \mid \mu_t, \alpha_t] = \partial_{\mu} \varphi(\mu_t, \alpha_t) \quad (5.45)$$

$$\mathbb{E}[\partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t, j_t) \mid \mu_t, \alpha_t] = \partial_{\alpha} \varphi(\mu_t, \alpha_t) \quad (5.46)$$

即 $\tilde{g}(w_t) = (\partial_{\mu} \tilde{\varphi}(\mu_t, \alpha_t, i_t), -\partial_{\alpha} \tilde{\varphi}(\mu_t, \alpha_t, j_t))$ 是 $g(w_t)$ 的一个无偏估计。

算法 5.1 描述了用随机镜像近端下降求解 ssODM 的详细过程:

5.3.2 收敛性分析

本节我们证明随机镜像近端下降的收敛率为 $O(1/t)$, 即要想得到精度为 ϵ 的解, 算法需要迭代 $O(1/\epsilon)$ 轮。

定理 5.1 对任意 $\hat{y}_k \in \mathcal{B}$, 设 $G(\alpha, \hat{y}_k)$ 是关于 α 的 L_1 -利普希茨连续函数, $\partial_{\alpha} G(\alpha, \hat{y}_k)$ 是关于 α 的 L_2 -利普希茨连续函数且 $\|\partial_{\alpha} G(\alpha, \hat{y}_k)\|_2 \leq L_3$ 。令 $a =$

算法 5.1 随机镜像近端下降算法

```

1: 算法输入: 数据集  $\mathbf{X}$ , 最大迭代轮数  $T$ , ODM 参数  $\lambda_1, \lambda_2, \nu, \theta$ , 约束上
   界参数  $\tau$ , 阈值  $\iota$ 
2: 算法过程:
3: 初始化  $\mu_0 \leftarrow [1/|\mathcal{B}|, \dots, 1/|\mathcal{B}|]$ ,  $\alpha_0 \leftarrow \mathbf{0}$ ,  $t \leftarrow 0$ 
4: while  $t < T$  do
5:   从  $\{1, 2, \dots, |\mathcal{B}|\}$  中随机采样出  $i_t$  和  $i'_t$ 
6:    $\partial_{\mu}\tilde{\varphi} \leftarrow [0, \dots, |\mathcal{B}|G(\alpha_t, \hat{\mathbf{y}}_{i_t}), \dots, 0]$ 
7:   根据分布  $\mu_t$  从  $\{1, 2, \dots, |\mathcal{B}|\}$  中采样出  $j_t$ 
8:    $\partial_{\alpha}\tilde{\varphi} \leftarrow \partial_{\alpha}G(\alpha_t, \hat{\mathbf{y}}_{j_t})$ 
9:    $\bar{\mu}_t \leftarrow \mu_t \exp(-\eta \partial_{\mu}\tilde{\varphi}/a)$ 
10:   $\bar{\alpha}_t \leftarrow \alpha_t + \eta \partial_{\alpha}\tilde{\varphi}/b$ 
11:   $\bar{\mu}_{t+1} \leftarrow \bar{\mu}_t / \|\bar{\mu}_t\|_1$ 
12:   $\bar{\alpha}_{t+1} \leftarrow \max\{\min\{\bar{\alpha}_t, \tau e\}, \mathbf{0}\}$ 
13:   $\partial_{\mu}\tilde{\varphi} \leftarrow [0, \dots, |\mathcal{B}|G(\bar{\alpha}_{t+1}, \hat{\mathbf{y}}_{i'_t}), \dots, 0]$ 
14:  根据分布  $\bar{\mu}_{t+1}$  从  $\{1, 2, \dots, |\mathcal{B}|\}$  中采样出  $j'_t$ 
15:   $\partial_{\alpha}\tilde{\varphi} \leftarrow \partial_{\alpha}G(\bar{\alpha}_{t+1}, \hat{\mathbf{y}}_{j'_t})$ 
16:   $\bar{\mu}_{t+1} \leftarrow \mu_t \exp(-\eta \partial_{\mu}\tilde{\varphi}/a)$ 
17:   $\bar{\alpha}_{t+1} \leftarrow \alpha_t + \eta \partial_{\alpha}\tilde{\varphi}/b$ 
18:   $\mu_{t+1} \leftarrow \bar{\mu}_{t+1} / \|\bar{\mu}_{t+1}\|_1$ 
19:   $\alpha_{t+1} \leftarrow \max\{\min\{\bar{\alpha}_{t+1}, \tau e\}, \mathbf{0}\}$ 
20:   $t \leftarrow t + 1$ 
21:  if 对偶间隙小于给定阈值  $\iota$  then
22:    停止迭代
23:  end if
24: end while
25: 算法输出:  $\mu, \alpha$ 

```

$1/\tau^2$, $b = 1/\log |\mathcal{B}|$, $\beta = 2 \max\{L_1 \log |\mathcal{B}|, L_2 \tau^2, 2L_3 \tau \sqrt{\log |\mathcal{B}|}\}$, 取 $\eta = 1/\beta$, 则在算法迭代 T 轮后的平均点 $(\sum_{t=1}^T \mu_t/T, \sum_{t=1}^T \alpha_t/T)$ 处, 对偶间隙的期望满足

$$\mathbb{E} \left[\max_{\alpha \in \mathcal{A}} \varphi \left(\frac{1}{T} \sum_{t=1}^T \bar{\mu}_{t+1}, \alpha \right) - \min_{\mu \in \mathcal{M}} \varphi \left(\mu, \frac{1}{T} \sum_{t=1}^T \bar{\alpha}_{t+1} \right) \right] \leq \frac{2\beta}{T} \quad (5.47)$$

证明: 证明的思路类似于标准的梯度下降, 考虑平均点处的梯度 $g(\mathbf{y}_{t+1})$ 和间隙 $\mathbf{y}_{t+1} - \mathbf{w}$ 的内积,

$$\mathbb{E} \left[\max_{\alpha \in \mathcal{A}} \varphi \left(\frac{1}{T} \sum_{t=1}^T \bar{\mu}_{t+1}, \alpha \right) - \min_{\mu \in \mathcal{M}} \varphi \left(\mu, \frac{1}{T} \sum_{t=1}^T \bar{\alpha}_{t+1} \right) \right] \quad (5.48)$$

$$\leq \mathbb{E} \left[\max_{\alpha \in \mathcal{A}} \frac{1}{T} \sum_{t=1}^T \varphi(\bar{\mu}_{t+1}, \alpha) - \min_{\mu \in \mathcal{M}} \frac{1}{T} \sum_{t=1}^T \varphi(\mu, \bar{\alpha}_{t+1}) \right] \quad (5.49)$$

$$\leq \mathbb{E} \left[\frac{1}{T} \sum_{t=1}^T \left(\max_{\alpha \in \mathcal{A}} \varphi(\bar{\mu}_{t+1}, \alpha) - \min_{\mu \in \mathcal{M}} \varphi(\mu, \bar{\alpha}_{t+1}) \right) \right] \quad (5.50)$$

$$\leq \frac{1}{T} \sum_{t=1}^T \mathbb{E}[g(\mathbf{y}_{t+1})^\top (\mathbf{y}_{t+1} - \mathbf{w})] \quad (5.51)$$

$$= \frac{1}{T} \sum_{t=1}^T \mathbb{E}[\mathbb{E}[g(\mathbf{y}_{t+1})^\top (\mathbf{y}_{t+1} - \mathbf{w}) \mid \mathbf{w}_t]] \quad (5.52)$$

$$= \frac{1}{T} \sum_{t=1}^T \mathbb{E}[g(\mathbf{y}_{t+1})^\top (\mathbf{y}_{t+1} - \mathbf{w})] \quad (5.53)$$

其中第一个不等号是因为 $\varphi(\mu, \alpha)$ 关于 μ 是凸函数而关于 α 是凹函数，由凸函数的性质可得；第二个不等号是根据 $\max$ 的次加性，即 $\max(a + b) \leq \max a + \max b$ ；第三个不等号是根据式 (4.29)，最后一个等号是根据全期望公式。

下面我们考虑求和里的每一项，根据随机镜像近端下降的更新公式可知

$$g(\mathbf{y}_{t+1})^\top (\mathbf{y}_{t+1} - \mathbf{w}) = g(\mathbf{y}_{t+1})^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1} + \mathbf{w}_{t+1} - \mathbf{w}) \quad (5.54)$$

$$= g(\mathbf{y}_{t+1})^\top (\mathbf{w}_{t+1} - \mathbf{w}) + g(\mathbf{y}_{t+1})^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1}) \quad (5.55)$$

$$= g(\mathbf{y}_{t+1})^\top (\mathbf{w}_{t+1} - \mathbf{w}) + g(\mathbf{w}_t)^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1}) \quad (5.56)$$

$$+ (g(\mathbf{y}_{t+1}) - g(\mathbf{w}_t))^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1})$$

分别考虑这三个部分，对于第一部分，

$$\eta g(\mathbf{y}_{t+1})^\top (\mathbf{w}_{t+1} - \mathbf{w}) = (\nabla \Phi(\mathbf{w}_t) - \nabla \Phi(\mathbf{v}_t))^\top (\mathbf{w}_{t+1} - \mathbf{w}) \quad (5.57)$$

$$\leq (\nabla \Phi(\mathbf{w}_t) - \nabla \Phi(\mathbf{w}_{t+1}))^\top (\mathbf{w}_{t+1} - \mathbf{w}) \quad (5.58)$$

$$= D_\Phi(\mathbf{w}, \mathbf{w}_t) - D_\Phi(\mathbf{w}, \mathbf{w}_{t+1}) - D_\Phi(\mathbf{w}_{t+1}, \mathbf{w}_t) \quad (5.59)$$

其中不等号是因为 $\mathbf{w}_{t+1}$ 是 $\mathbf{v}_{t+1}$ 的投影，从而由投影定理有 $(\nabla \Phi(\mathbf{w}_{t+1}) - \nabla \Phi(\mathbf{v}_{t+1}))^\top (\mathbf{w}_{t+1} - \mathbf{w}) \leq 0$ 。同理对于第二部分有，

$$\eta g(\mathbf{w}_t)^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1}) = (\nabla \Phi(\mathbf{w}_t) - \nabla \Phi(\mathbf{u}_t))^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1}) \quad (5.60)$$

$$\leq (\nabla \Phi(\mathbf{w}_t) - \nabla \Phi(\mathbf{y}_{t+1}))^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1}) \quad (5.61)$$

$$= D_\Phi(\mathbf{w}_{t+1}, \mathbf{w}_t) - D_\Phi(\mathbf{w}_{t+1}, \mathbf{y}_{t+1}) - D_\Phi(\mathbf{y}_{t+1}, \mathbf{w}_t) \quad (5.62)$$

$$\leq D_\Phi(\mathbf{w}_{t+1}, \mathbf{w}_t) - \frac{1}{2} \|\mathbf{w}_{t+1} - \mathbf{y}_{t+1}\|^2 - \frac{1}{2} \|\mathbf{y}_{t+1} - \mathbf{w}_t\|^2 \quad (5.63)$$

其中第二个不等号由 Φ 是 1-强凸函数可得。对于第三部分，

$$(g(\mathbf{y}_{t+1}) - g(\mathbf{w}_t))^\top (\mathbf{y}_{t+1} - \mathbf{w}_{t+1}) \leq \|g(\mathbf{y}_{t+1}) - g(\mathbf{w}_t)\|_* \|\mathbf{y}_{t+1} - \mathbf{w}_{t+1}\|. \quad (5.64)$$

$$\leq \beta \|\mathbf{y}_{t+1} - \mathbf{w}_t\| \cdot \|\mathbf{y}_{t+1} - \mathbf{w}_{t+1}\|. \quad (5.65)$$

$$\leq \frac{\beta}{2} \|\mathbf{y}_{t+1} - \mathbf{w}_t\|^2 + \frac{\beta}{2} \|\mathbf{y}_{t+1} - \mathbf{w}_{t+1}\|^2. \quad (5.66)$$

代入 $\eta = 1/\beta$ ，将三部分合起来有

$$g(\mathbf{y}_{t+1})^\top (\mathbf{y}_{t+1} - \mathbf{w}) \leq \beta(D_\Phi(\mathbf{w}, \mathbf{w}_t) - D_\Phi(\mathbf{w}, \mathbf{w}_{t+1}) - D_\Phi(\mathbf{w}_{t+1}, \mathbf{w}_t)) \quad (5.67)$$

$$+ \beta(D_\Phi(\mathbf{w}_{t+1}, \mathbf{w}_t) - \frac{1}{2} \|\mathbf{w}_{t+1} - \mathbf{y}_{t+1}\|^2 - \frac{1}{2} \|\mathbf{y}_{t+1} - \mathbf{w}_t\|^2) \quad (5.68)$$

$$+ \frac{\beta}{2} \|\mathbf{y}_{t+1} - \mathbf{w}_t\|^2 + \frac{\beta}{2} \|\mathbf{y}_{t+1} - \mathbf{w}_{t+1}\|^2. \quad (5.69)$$

$$= \beta(D_\Phi(\mathbf{w}, \mathbf{w}_t) - D_\Phi(\mathbf{w}, \mathbf{w}_{t+1})) \quad (5.70)$$

于是

$$\max_{\alpha \in \mathcal{A}} \varphi\left(\frac{1}{T} \sum_{t=1}^T \bar{\mu}_{t+1}, \alpha\right) - \min_{\mu \in \mathcal{M}} \varphi\left(\mu, \frac{1}{T} \sum_{t=1}^T \bar{\alpha}_{t+1}\right) \leq \frac{\beta}{T} D_\Phi(\mathbf{w}, \mathbf{w}_1) \quad (5.71)$$

又

$$D_\Phi(\mathbf{w}, \mathbf{w}_1) = aD_{\Phi_U}(\mathbf{u}, \mathbf{u}_1) + bD_{\Phi_V}(\mathbf{v}, \mathbf{v}_1) \leq a\tau^2 + b \log |\mathcal{B}| = 2 \quad (5.72)$$

故

$$\mathbb{E} \left[\max_{\alpha \in \mathcal{A}} \varphi\left(\frac{1}{T} \sum_{t=1}^T \bar{\mu}_{t+1}, \alpha\right) - \min_{\mu \in \mathcal{M}} \varphi\left(\mu, \frac{1}{T} \sum_{t=1}^T \bar{\alpha}_{t+1}\right) \right] \leq \frac{2\beta}{T} \quad (5.73)$$

□

5.4 实验验证

本节我们通过实验验证 ssODM 的性能。实验中共用到 20 个 UCI 数据集，表 5.1 列出了这些数据集的所有信息。可以看出，这 20 个数据集，样本数最小的仅有 62 个，最大的有 72,309 个，特征数的跨度也从 6 大到 20,958，因此可以说覆盖了很大的范围。对于每个数据集，所有的特征都归一化到 $[0, 1]$ 之间。

表 5.1: 数据集信息

ID	数据集	样本数	特征数	ID	数据集	样本数	特征数
1	<i>echocardiogram</i>	62	8	11	<i>wdbc</i>	569	14
2	<i>house</i>	232	16	12	<i>isolet</i>	600	51
3	<i>heart</i>	270	9	13	<i>austra</i>	690	15
4	<i>heart-statlog</i>	270	13	14	<i>australian</i>	690	42
5	<i>haberman</i>	306	14	15	<i>diabetes</i>	768	8
6	<i>live-discorders</i>	345	6	16	<i>german</i>	1,000	59
7	<i>ionosphere</i>	351	33	17	<i>optdigits</i>	1,143	42
8	<i>vehicle</i>	435	16	18	<i>krvsnp</i>	3,196	36
9	<i>house-votes</i>	435	16	19	<i>sick</i>	2,643	28
10	<i>clean1</i>	476	166	20	<i>real-sim</i>	72,309	20,958

5.4.1 实验设置

对每个数据集，75% 的样本随机选做训练数据集，剩余的作为测试集。我们考察两种情况，分别只有 5% 的有标记数据和 10% 的有标记数据。

我们对比的方法包括标准的 SVM（只使用有标记数据）以及 4 种半监督支持向量机：TSVM^[53]、拉普拉斯 SVM^[5]、UniverSVM（USVM）^[17]、S4VM^[69]。注意由于 TSVM 和 USVM 考虑的是同样的形式化，只是采用了不同的优化算法，前者使用了局部搜索，而后者使用了 CCCP（Constrained Convex-Concave Procedure），因此它们可能得到不同的局部最优解。

对于所有方法，参数 C 、 λ_1 、 λ_2 通过 5-折交叉验证从集合 $\{1, 10, 100, 1000\}$ 中选取。对于 ssODM，参数 ν 、 θ 通过 5-折交叉验证从集合 $[0.2, 0.4, 0.6, 0.8]$ 中选取。对所有方法，输出线性核和高斯核中的最好结果。其中高斯核的“带宽”参数 σ 通过 5-折交叉验证从集合 $\{2^{-4}\delta, 2^{-2}\delta, 2^0\delta, 2^2\delta, 2^4\delta\}$ 中选取，其中 δ 是特征数的倒数。所有实验重复 10 次，记录平均性能。

5.4.2 实验结果

表 5.2 和表 5.3 分别展示了所有算法在 20 个 UCI 数据集上取得的性能。可以看出，无论是 5% 的有标记数据还是 10% 的有标记数据的情形，ssODM 都显著好于对比方法。具体来说，在只有 5% 的有标记数据的情形下，ssODM 显著

表 5.2: 20 个 UCI 数据集上的结果, 5% 有标记数据, 每个数据集上的最好结果加粗显示, $\bullet/\circ$ 表示在 95% 置信度的成对 t -检验下, ssODM 的结果显著好于/差于对比方法

数据集	SVM	TSVM	LapSVM	USVM	S4VM	ssODM
<i>echocardiogram</i>	80.0±7.1 $\bullet$	74.1±8.2 $\bullet$	64.4±22.1 $\bullet$	80.1±6.1 $\bullet$	80.4±7.8 $\bullet$	81.9±1.1
<i>house</i>	90.0±4.1 $\bullet$	90.3±5.6 $\bullet$	90.6±6.7 $\bullet$	90.3±6.8 $\bullet$	90.9±7.3 $\bullet$	91.7±1.4
<i>heart</i>	70.0±8.0 $\bullet$	75.2±6.2 $\bullet$	73.3±6.3 $\bullet$	76.2±6.3 $\bullet$	77.2±6.1 $\bullet$	78.3±5.4
<i>heart-statlog</i>	73.0±1.0 $\bullet$	76.2±6.1 $\bullet$	75.3±6.8 $\bullet$	78.1±5.3 $\bullet$	79.1±6.1	78.9±5.4
<i>haberman</i>	65.1±7.1 $\bullet$	61.4±5.3 $\bullet$	57.7±11.2 $\bullet$	74.3±12.3	73.2±12.1	73.7±14.1
<i>live-discorders</i>	56.8±5.1 $\bullet$	55.5±5.3 $\bullet$	55.6±5.5 $\bullet$	59.0±5.2	53.0±7.1 $\bullet$	58.8±4.8
<i>ionosphere</i>	67.8±6.1 $\bullet$	82.2±11.3$\circ$	65.6±5.8 $\bullet$	77.0±6.4 $\bullet$	70.1±6.4 $\bullet$	79.1±4.1
<i>vehicle</i>	74.8±4.1 $\bullet$	75.1±8.3 $\bullet$	77.3±5.2 $\bullet$	74.1±6.9 $\bullet$	78.9±6.2	79.1±4.1
<i>house-votes</i>	88.8±3.1 $\bullet$	89.1±4.3 $\bullet$	89.9±3.2 $\bullet$	90.1±5.3 $\bullet$	91.2±4.1	92.5±3.5
<i>clean1</i>	58.0±6.1 $\bullet$	62.1±7.4 $\bullet$	64.1±6.5 $\bullet$	62.3±6.5 $\bullet$	64.1±4.1 $\bullet$	66.1±4.5
<i>wdbc</i>	81.3±6.4 $\bullet$	80.3±3.4 $\bullet$	80.8±4.8 $\bullet$	82.0±6.1 $\bullet$	82.1±4.8	82.9±3.9
<i>isolet</i>	97.0±2.9 $\bullet$	97.6±3.1 $\bullet$	98.0±3.8 $\bullet$	98.7±3.7 $\bullet$	98.8±4.8	99.1±4.0
<i>austra</i>	77.0±5.9 $\bullet$	82.0±3.0	76.6±3.3 $\bullet$	78.1±4.5 $\bullet$	77.5±4.1 $\bullet$	81.3±4.0
<i>australian</i>	67.2±8.1 $\bullet$	68.1±3.4 $\bullet$	78.2±3.1 $\bullet$	78.9±4.1 $\bullet$	78.8±4.2 $\bullet$	79.9±3.5
<i>diabetes</i>	67.9±8.0 $\bullet$	68.3±3.9 $\bullet$	76.1±6.9 $\bullet$	77.1±4.9 $\bullet$	76.8±4.8 $\bullet$	79.0±4.9
<i>german</i>	70.0±3.0 $\bullet$	70.3±1.0 $\bullet$	70.8±2.1 $\bullet$	71.0±2.9 $\bullet$	71.5±4.1 $\bullet$	72.6±4.5
<i>optdigits</i>	92.2±2.0	89.1±9.0 $\bullet$	90.2±5.0 $\bullet$	91.3±6.9 $\bullet$	91.8±4.1	91.9±4.2
<i>krvsnp</i>	91.1±2.3 $\bullet$	89.9±9.1 $\bullet$	92.1±5.4 $\bullet$	91.6±6.8 $\bullet$	92.6±4.2 $\bullet$	93.2±4.0
<i>sick</i>	94.1±2.1	93.2±9.0 $\bullet$	93.9±3.4 $\bullet$	93.5±4.8 $\bullet$	92.9±4.5 $\bullet$	94.8±4.8
<i>real-sim</i>	90.1±2.2 $\bullet$	91.3±6.5 $\bullet$	92.2±3.5 $\bullet$	93.0±4.3 $\bullet$	92.4±4.9 $\bullet$	92.2±3.3
ssODM: 胜/平/负	18/2/0	18/1/1	20/0/0	18/2/0	13/7/0	

好于 SVM/TSVM/LapSVM/USVM/S4VM 的次数分别是 18/18/20/18/13 次, 并在 14 个数据集上取得最好性能; 在只有 10% 的有标记数据的情形下, ssODM 显著好于 SVM/TSVM/LapSVM/USVM/S4VM 的次数分别是 18/18/20/18/11 次, 并在 13 个数据集上取得最好性能。此外, ssODM 从来不会出现使用未标记数据后, 泛化性能下降的情况。

5.5 小结

本文提出了面向半监督学习问题的最优间隔分布学习机 ssODM, 根据半监督学习的流形假设, 在将类别标记指派给每个未标记样本之后, 可以寻找一个划分超平面在这个“有监督”数据集上产生最优间隔分布。因此 ssODM 同时优化未标记样本的类别标记和间隔分布, 最终形式化出的问题是一个混合整数规

表 5.3: 20 个 UCI 数据集上的结果, 10% 有标记数据, 每个数据集上的最好结果加粗显示, ●/○ 表示在 95% 置信度的成对 t -检验下, ssODM 的结果显著好于/差于对比方法

数据集	SVM	TSVM	LapSVM	USVM	S4VM	ssODM
<i>echocardiogram</i>	81.2±7.7●	76.1±8.7●	68.4±20.1●	82.1±6.3●	82.4±7.3●	83.9±1.5
<i>house</i>	91.2±4.7●	92.1±5.7●	91.8±17.1●	91.1±5.3●	92.4±6.6	92.3±1.8
<i>heart</i>	75.1±4.9●	78.3±4.7●	75.6±4.1●	77.9±5.3●	78.4±5.6	79.8±1.6
<i>heart-statlog</i>	75.1±0.8●	79.2±6.2●	79.3±5.8●	79.1±4.1●	83.1±5.6	82.4±4.5
<i>haberman</i>	68.3±6.7●	63.4±4.7●	60.1±9.8●	79.4±11.3	78.7±11.1	78.8±1.1
<i>live-discorders</i>	58.3±6.7●	58.4±4.7●	60.1±8.8●	64.2±10.3	59.0±9.1●	63.9±8.0
<i>ionosphere</i>	69.1±5.7●	86.1±4.7○	68.1±5.8●	79.1±4.3●	76.1±5.4●	83.1±1.5
<i>vehicle</i>	76.1±3.5●	77.2±6.2●	79.1±4.6●	76.0±6.0●	81.9±6.7	82.3±3.5
<i>house-votes</i>	89.7±2.6●	89.9±3.1●	90.1±3.2●	91.0±4.5●	92.5±3.5	92.9±3.1
<i>clean1</i>	59.1±5.4●	64.1±5.4●	64.9±5.5●	63.4±5.4●	65.1±3.8●	67.1±3.5
<i>wdbc</i>	83.1±5.4●	82.3±3.1●	81.8±4.4●	82.5±6.0●	82.9±4.3	83.5±3.3
<i>isolet</i>	97.3±2.5●	97.8±3.0●	98.5±3.2●	98.9±3.5●	98.9±4.3	99.2±4.5
<i>austra</i>	79.0±5.1●	85.0±3.2	79.6±3.1●	78.8±3.7●	79.9±3.6●	84.3±3.4
<i>australian</i>	68.1±7.5●	69.2±3.8●	79.1±3.0●	79.2±4.0●	79.7±4.1●	80.5±3.9
<i>diabetes</i>	70.3±7.1●	70.3±3.4●	77.0±6.3●	77.6±4.0●	77.1±4.4●	79.8±4.0
<i>german</i>	70.0±3.0●	70.8±1.0●	70.9±1.6●	71.3±2.3●	71.8±4.3●	73.1±3.7
<i>optdigits</i>	92.5±2.3	89.4±9.1●	91.2±5.5●	91.7±6.4●	91.3±4.0	92.1±4.0
<i>krvsnp</i>	91.9±2.0●	90.3±9.0●	92.7±5.0●	92.5±6.9●	92.9±4.0●	93.6±4.5
<i>sick</i>	94.6±2.0	93.8±8.8●	94.1±3.3●	93.9±4.1●	93.4±4.1●	95.5±4.3
<i>real-sim</i>	90.9±2.0●	91.9±6.2●	92.9±3.1●	93.3±4.0●	92.8±4.3●	94.1±2.8
ssODM: 胜/平/负	18/2/0	18/1/1	20/0/0	18/2/0	11/9/0	

划, 难以直接求解, 本文采用极大极小技巧先将其放松成一个鞍点问题, 然后提出一种基于随机镜像近端下降的方法进行求解。最终实验表明 ssODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的半监督学习方法。在以后的工作中, 值得研究的问题包括如何设计更好的优化算法来加速 ssODM。

本章的主要工作已总结成文:

- T. Zhang and Z.-H. Zhou. Semi-supervised optimal margin distribution machines. In: **Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI'18)**, Stockholm, Sweden, 2018, pp.3104-3110. (CCF A 类会议)

第六章 结束语

本文工作主要涉及国家自然科学基金项目“开放动态环境下的在线机器学习理论与方法”(61333014)、“新型深度学习模型与方法的研究”(61751306)与国家重点研发计划“大数据分析的基础理论和技术方法”(2018YFB1004300)等科研项目的内容。

统计学习中经典的大间隔方法以“最小间隔”为优化目标,这种忽略了大部分样本的信息而只关注少数样本的做法是有潜在风险的。另一方面,关于 AdaBoost 的一系列理论研究表明,优化最小间隔并不能保证良好的泛化性能,“间隔分布”才是更重要的概念。因此,以优化间隔分布为准则,不妨称为最优间隔分布准则,设计学习算法是个值得探索的问题。本文针对四种常见的机器学习任务,分别提出相应的显式优化间隔分布的方法,完整地建立起了这一新型统计学习范型,本文主要取得了以下创新成果:

第 2 章提出二分类最优间隔分布学习机 ODM。通过将任务形式化为最大化间隔均值同时最小化间隔方差来优化间隔分布,并提出一种基于对偶坐标下降的方法进行求解。对于大规模数据集,本文提出基于 SVRG 的快速求解算法。实验结果表明 ODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的传统大间隔方法。

第 3 章提出多分类最优间隔分布学习机 mcODM。通过将多类间隔定义为每类与“其他类”的二类间隔的最小值来优化间隔分布。最终形式化出的问题是个非凸优化,本文将其放松成一系列较易处理的 QP 问题,并提出一种基于块坐标下降的方法来求解其对偶问题。实验结果表明 mcODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的多分类方法。

第 4 章提出聚类最优间隔分布学习机 ODMC。一个好的聚类结果是在将簇标记指派给每个簇后,存在超平面在此“有监督”数据集上产生最优间隔分布,ODMC 同时优化簇标记和间隔分布。对于最终形式化,本文提出一种基于随机镜像下降的求解方法。实验结果表明 ODMC 的聚类性能显著优于、且在最坏情况下不差于优化最小间隔的聚类方法。

第 5 章提出半监督最优间隔分布学习机 ssODM。根据流形假设在将类别标

记指派给未标记样本后，存在超平面在此“有监督”数据集上产生最优间隔分布，ssODM 同时优化未标记样本类别标记和间隔分布。对于最终形式化，本文提出一种基于随机镜像近端下降的求解方法。实验结果表明 ssODM 的泛化性能显著优于、且在最坏情况下不差于优化最小间隔的半监督学习方法。

在未来的工作中还一些有待进一步研究的问题：

本文目前的工作主要着眼于间隔分布优化算法的设计，能否在理论层面上，为显式优化间隔分布的算法证明更紧的基于间隔分布的泛化界是个很有意思的问题。目前优化最小间隔的大间隔方法的泛化界是通过 VC 维理论来证明的，因此同样的理论可能无法用来证明优化间隔分布的算法的泛化界了，这可能会反过来促进一些新的理论工具的诞生。

随着大数据时代的到来，机器学习的数据量越来越大，数据不仅难以在单个机器上存储，甚至在单个机器上进行运算都做不到。此时如何进行最优间隔分布学习？现在有很多成熟的分布式运算平台，比如 Spark，一个可能的解法就是在 Spark 上开发 ADMM (Alternating Direction Method of Multipliers) [13]，使得现有的最优间隔分布学习框架能适应大规模分布式计算。

对于一些输入特征与输出类别标记之间的关系更加复杂的机器学习问题，比如多标记学习 (multi-label learning) [136,137]、多示例学习 (multi-instance learning) [149,151]、多示例多标记学习 (multi-instance multi-label learning) [150,152]，如何将最优间隔分布学习的思想引入其中？此时的间隔如何定义？是否存在高效的优化算法？

实际应用中经常会碰到环境变化的问题，反映到数据层面，就是样本个数、特征个数、类别标记的数目等都会动态地发生变化。现在已经有一些工作在考虑这方面的问题，例如 Hou 等人 [46] 就考虑了特征数随环境变化增加的问题，Zhu 等人 [154] 考虑了新类出现的问题。在此动态环境下，如何计算间隔？间隔分布又该如何优化呢？

参考文献

- [1] F. Aioli, G. S. Martino, and A. Sperduti. A kernel method for the optimization of the margin distribution. In *Proceedings of the 18th International Conference on Artificial Neural Networks*, pp. 305–314, Prague, Czech, 2008.
- [2] M. Ankerst, M. M. Breunig, H.-P. Kriegel, and J. Sander. Optics: Ordering points to identify the clustering structure. In *Proceedings of the 1999 ACM SIGMOD International Conference on Management of Data*, pp. 49–60, Philadelphia, PA, 1999.
- [3] E. Bauer and R. Kohavi. An empirical comparison of voting classification algorithms: Bagging, boosting and variants. *Machine Learning*, 36(1-2):105–139, 1999.
- [4] A. Beck and M. Teboulle. Mirror descent and nonlinear projected subgradient methods for convex optimization. *Operations Research Letters*, 31(3):167–175, 2003.
- [5] M. Belkin, P. Niyogi, and V. Sindhwani. Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. *Journal of Machine Learning Research*, 7:2399–2434, 2006.
- [6] K. P. Bennett and A. Demiriz. Semi-supervised support vector machines. In *Advances in Neural Information Processing Systems II*, pp. 368–374, Denver, CO, 1999.
- [7] J. C. Bezdek, R. J. Hathaway, R. E. Howard, C. A. Wilson, and M. P. Windham. Local convergence analysis of a grouped variable version of coordinate descent. *Journal of Optimization Theory and Applications*, 54(3):471–477, 1987.

- [8] A. Blum and T. Mitchell. Combining labeled and unlabeled data with co-training. In *Proceedings of the 11th Conference on Learning Theory*, pp. 92–100, Madison, WI, 1998.
- [9] H. D. Bondell and B. J. Reich. Simultaneous regression shrinkage, variable selection, and supervised clustering of predictors with oscar. *Biometrics*, 64(1): 115–123, 2008.
- [10] A. Bordes, L. Bottou, and P. Gallinari. Sgd-qn: Careful quasi-newton stochastic gradient descent. *Journal of Machine Learning Research*, 10:1737–1754, 2009.
- [11] L. Bottou. Large-scale machine learning with stochastic gradient descent. In *Proceedings of the 19th International Conference on Computational Statistics*, pp. 177–186, Paris, France, 2010.
- [12] S. Boyd and L. Vandenberghe. *Convex Optimization*. Cambridge University Press, Cambridge, UK, 2004.
- [13] S. Boyd, N. Parikh, E. Chu, B. Peleato, and J. Eckstein. Distributed optimization and statistical learning via the alternating direction method of multipliers. *Foundations and Trends in Machine Learning*, 3(1):1–122, 2011.
- [14] L. Breiman. Prediction games and arcing algorithms. *Neural Computation*, 11(7):1493–1517, 1999.
- [15] C.-C. Chang and C.-J. Lin. LIBSVM: A library for support vector machines. *ACM Transactions on Intelligent Systems and Technology*, 2(3):1–27, 2011.
- [16] O. Chapelle, B. Schölkopf, and A. Zien. *Semi-Supervised Learning*. MIT Press, Cambridge, MA, 2010.
- [17] R. Collobert, F. Sinz, J. Weston, and L. Bottou. Large scale transductive svms. *Journal of Machine Learning Research*, 7:1687–1712, 2006.
- [18] C. Cortes and V. N. Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.

- [19] A. Cotter, S. Shalev-Shwartz, and N. Srebro. Learning optimally sparse support vector machines. In *Proceedings of the 30th International Conference on Machine Learning*, pp. 266–274, Atlanta, GA, 2013.
- [20] K. Crammer and Y. Singer. On the algorithmic implementation of multiclass kernel-based vector machines. *Journal of Machine Learning Research*, 2:265–292, 2001.
- [21] K. Crammer and Y. Singer. On the learnability and design of output codes for multiclass problems. *Machine Learning*, 47(2-3):201–233, 2002.
- [22] N. Cristianini and J. Shawe-Taylor. *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge University Press, Cambridge, UK, 2000.
- [23] T. G. Dietterich. An experimental comparison of three methods for constructing ensembles of decision trees: Bagging, boosting and randomization. *Machine Learning*, 40(2):139–157, 2000.
- [24] T. G. Dietterich and G. Bakiri. Solving multiclass learning problems via error-correcting output codes. *Journal of Artificial Intelligence Research*, 2(1):263–286, 1995.
- [25] H. Do and A. Kalousis. Convex formulations of radius-margin based support vector machines. In *Proceedings of the 30th International Conference on Machine Learning*, pp. 169–177, Atlanta, GA, 2013.
- [26] H. Drucker, C. J. C. Burges, L. Kaufman, A. Smola, and V. Vapnik. Support vector regression machines. In *Advances in Neural Information Processing Systems 9*, pp. 155–161, Denver, Colorado, 1996.
- [27] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu. Density-based spatial clustering of applications with noise. In *Proceedings of the 2nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 226–231, Portland, OR, 1996.
- [28] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun. Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542:115–118, 2017.

- [29] R.-E. Fan, P.-H. Chen, and C.-J. Lin. Working set selection using the second order information for training svm. *Journal of Machine Learning Research*, 6: 1889–1918, 2005.
- [30] R.-E. Fan, K.-W. Chang, C.-J. Hsieh, X.-R. Wang, and C.-J. Lin. LIBLINEAR: A library for large linear classification. *Journal of Machine Learning Research*, 9:1871–1874, 2008.
- [31] R. A. Fisher. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2):179–188, 1936.
- [32] Y. Freund and R. E. Schapire. A decision-theoretic generalization of on-line learning and an application to boosting. In *Proceedings of the 2nd European Conference on Computational Learning Theory*, pp. 23–37, Barcelona, Spain, 1995.
- [33] Y. Freund and R. E. Schapire. Experiments with a new boosting algorithm. In *Proceedings of the 13th International Conference on Machine Learning*, pp. 148–156, Bari, Italy, 1996.
- [34] Y. Freund and R. E. Schapire. Large margin classification using the perceptron algorithm. *Machine Learning*, 37:277–296, 1999.
- [35] J. Friedman, T. Hastie, and R. Tibshirani. Additive logistic regression: a statistical view of boosting. *Annals of Statistics*, 28(2):337–407, 2000.
- [36] J. Friedman, T. Hastie, and R. Tibshirani. *The elements of statistical learning*. Springer, New York, NY, 2001.
- [37] W. Gao and Z.-H. Zhou. On the doubt about margin explanation of boosting. *Artificial Intelligence*, 203:1–18, 2013.
- [38] A. Garg and D. Roth. Margin distribution and learning algorithms. In *Proceedings of the 20th International Conference on Machine Learning*, pp. 210–217, Washington, DC, 2003.

- [39] A. Garg, S. Har-Peled, and D. Roth. On generalization bounds, projection profile and margin distribution. In *Proceedings of 19th International Conference on Machine Learning*, pp. 171–178, Sydney, Australia, 2002.
- [40] A. Geiger, P. Lenz, and R. Urtasun. Are we ready for autonomous driving? the kitti vision benchmark suite. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3354–3361, Providence, RI, 2012.
- [41] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, Las Vegas, NV, 2016.
- [42] A. Hinneburg and D. A. Keim. An efficient approach to clustering in large multimedia databases with noise. In *Proceedings of the 4th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 58–65, New York, NY, 1998.
- [43] W. Hoeffding. Probability inequalities for sums of bounded random variables. *Journal of the American Statistical Association*, 58(301):13–30, 1963.
- [44] A. E. Hoerl and R. W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.
- [45] D. W. Hosmer Jr, S. Lemeshow, and R. X. Sturdivant. *Applied logistic regression*. John Wiley & Sons, New York, NY, 2013.
- [46] B.-J. Hou, L. Zhang, and Z.-H. Zhou. Learning with feature evolvable streams. In *Advances in Neural Information Processing Systems 30*, pp. 1417–1427, Long Beach, CA, 2017.
- [47] C. J. Hsieh, K. W. Chang, C.-J. Lin, S. S. Keerthi, and S. Sundararajan. A dual coordinate descent method for large-scale linear svm. In *Proceedings of the 25th International Conference on Machine Learning*, pp. 408–415, Helsinki, Finland, 2008.
- [48] Z. Huang. Extensions to the k-means algorithm for clustering large data sets with categorical values. *Data Mining and Knowledge Discovery*, 2(3):283–304, 1998.

- [49] S. Ioffe and C. Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning*, pp. 448–456, Lille, France, 2015.
- [50] L. Jacob, G. Obozinski, and J.-P. Vert. Group lasso with overlap and graph lasso. In *Proceedings of the 26th International Conference on Machine Learning*, pp. 433–440, Montreal, Canada, 2009.
- [51] A. K. Jain. Data clustering: 50 years beyond k-means. *Pattern Recognition Letters*, 31(8):651–666, 2010.
- [52] A. K. Jain and R. C. Dubes. *Algorithms for Clustering Data*. Prentice-Hall, Upper Saddle River, NJ, 1988.
- [53] T. Joachims. Transductive inference for text classification using support vector machines. In *Proceedings of the 16th International Conference on Machine Learning*, pp. 200–209, Bled, Slovenia, 1999.
- [54] T. Joachims. Training linear svms in linear time. In *Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 217–226, Philadelphia, PA, 2006.
- [55] T. Joachims, T. Finley, and C.-N. J. Yu. Cutting-plane training of structural svms. *Machine Learning*, 77(1):27–59, 2009.
- [56] R. Johnson and T. Zhang. Accelerating stochastic gradient descent using predictive variance reduction. In *Advances in Neural Information Processing Systems 26*, pp. 315–323, Lake Tahoe, NV, 2013.
- [57] C. Jose, P. Goyal, P. Aggrwal, and M. Varma. Local deep kernel learning for efficient non-linear svm prediction. In *Proceedings of the 30th International Conference on Machine Learning*, pp. 486–494, Atlanta, GA, 2013.
- [58] L. Kaufman and P. J. Rousseeuw. Clustering by means of medoids. In *Statistical Data Analysis Based on the L_1 -Norm and Related Methods*, pp. 405–416. North-Holland, Amsterdam, Nederland, 1987.

- [59] L. Kaufman and P. J. Rousseeuw. *Finding groups in data: an introduction to cluster analysis*. John Wiley & Sons, New York, NY, 2009.
- [60] S.-J. Kim and S. Boyd. A minimax theorem with applications to machine learning, signal processing, and finance. *SIAM Journal on Optimization*, 19(3):1344–1367, 2008.
- [61] D. Kong, R. Fujimaki, J. Liu, F. Nie, and C. Ding. Exclusive feature learning on arbitrary structures via $l_{1,2}$ -norm. In *Advances in Neural Information Processing Systems 27*, pp. 1655–1663, Montreal, Canada, 2014.
- [62] A. Krizhevsky, I. Sutskever, and G. E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems 25*, pp. 1097–1105, Lake Tahoe, NV, 2012.
- [63] H. Kushner and G. G. Yin. *Stochastic approximation and recursive algorithms and applications*. Springer, New York, NY, 2003.
- [64] S. Lacoste-Julien, M. Jaggi, M. Schmidt, and P. Pletscher. Block-coordinate frank-wolfe optimization for structural svms. In *Proceedings of the 30th International Conference on Machine Learning*, pp. 53–61, Atlanta, GA, 2013.
- [65] F. Lauer and Y. Guermeur. MSVMpack: a multi-class support vector machine package. *Journal of Machine Learning Research*, 12:2293–2296, 2011.
- [66] M. Ledoux and M. Talagrand. *Probability in Banach spaces: isoperimetry and processes*. Springer, Berlin, Germany, 1991.
- [67] C.-P. Lee and D. Roth. Distributed box-constrained quadratic optimization for dual linear svm. In *Proceedings of the 32nd International Conference on Machine Learning*, pp. 987–996, Lille, France, 2015.
- [68] Y. Lei, Ürün Dogan, A. Binder, and M. Kloft. Multi-class svms: From tighter data-dependent generalization bounds to novel algorithms. In *Advances in Neural Information Processing Systems 28*, pp. 2026–2034, Montreal, Canada, 2015.

- [69] Y.-F. Li and Z.-H. Zhou. Towards making unlabeled data never hurt. In *Proceedings of the 28th International Conference on Machine Learning*, pp. 1081–1088, Bellevue, WA, 2011.
- [70] Y.-F. Li, J. T. Kwok, and Z.-H. Zhou. Semi-supervised learning using label mean. In *Proceedings of the 26th International Conference on Machine Learning*, pp. 633–640, Montreal, Canada, 2009.
- [71] Y.-F. Li, I. W. Tsang, J. T. Kwok, and Z.-H. Zhou. Tighter and convex maximum margin clustering. In *In Proceeding of the 12th International Conference on Artificial Intelligence and Statistics*, pp. 328–335, Clearwater Beach, FL, 2009.
- [72] Y.-F. Li, J. T. Kwok, and Z.-H. Zhou. Cost-sensitive semi-supervised support vector machine. In *Proceedings of the 24th AAAI Conference on Artificial Intelligence*, pp. 500–505, Atlanta, GA, 2010.
- [73] Y.-F. Li, I. W. Tsang, J. T. Kwok, and Z.-H. Zhou. Convex and scalable weakly labeled svms. *Journal of Machine Learning Research*, 14(1):2151–2188, 2013.
- [74] C.-J. Lin. Asymptotic convergence of an smo algorithm without any assumptions. *IEEE Transactions on Neural Networks*, 13(1):248–250, 2002.
- [75] D. W. Marquardt and R. D. Snee. Ridge regression in practice. *The American Statistician*, 29(1):3–20, 1975.
- [76] A. Maurer and M. Pontil. Empirical bernstein bounds and sample-variance penalization. In *Proceedings of the 22nd Conference on Learning Theory*, Montreal, Canada, 2009.
- [77] C. McDiarmid. On the method of bounded differences. *Surveys in Combinatorics*, 141(1):148–188, 1989.
- [78] L. Meier, S. Van De Geer, and P. Bühlmann. The group lasso for logistic regression. *Journal of the Royal Statistical Society*, 70(1):53–71, 2008.
- [79] S. Menard. *Applied logistic regression analysis*. Sage, New York, NY, 2002.
- [80] T. M. Mitchell. *Machine Learning*. McGraw-Hill, New York, NY, 1997.

-
- [81] M. Mohri, A. Talwalkar, and A. Rostamizadeh. *Foundations of Machine Learning*. MIT Press, Cambridge, MA, 2012.
- [82] A. Nemirovski. Prox-method with rate of convergence $\mathcal{O}(1/t)$ for variational inequalities with lipschitz continuous monotone operators and smooth convex-concave saddle point problems. *SIAM Journal on Optimization*, 15(1):229–251, 2005.
- [83] Y. Nesterov. *Introductory Lectures on Convex Optimization: A Basic Course*. Springer, New York, NY, 2003.
- [84] F. Nie, Y. Huang, and H. Huang. Linear time solver for primal svm. In *Proceedings of the 31st International Conference on Machine Learning*, pp. 505–513, Beijing, China, 2014.
- [85] F. Nie, X. Wang, and H. Huang. Multiclass capped l_p -norm SVM for robust classifications. In *Proceedings of the 31st AAAI Conference on Artificial Intelligence*, pp. 2415–2421, San Francisco, CA, 2017.
- [86] G. Niu, B. Dai, L. Shang, and M. Sugiyama. Maximum volume clustering: A new discriminative clustering approach. *Journal of Machine Learning Research*, 14:2641–2687, 2013.
- [87] A. Osokin, J. B. Alayrac, I. Lukasewitz, P. K. Dokania, and S. Lacoste-Julien. Minding the gaps for block frank-wolfe optimization of structured svms. In *Proceedings of the 33rd International Conference on Machine Learning*, pp. 593–602, New York, NY, 2016.
- [88] K. Pelckmans, J. A. K. Suykens, and B. De Moor. A risk minimization principle for a class of parzen estimators. In *Advances in Neural Information Processing Systems 20*, pp. 1137–1144, Vancouver, Canada, 2007.
- [89] J. C. Platt. Fast training of support vector machines using sequential minimal optimization. In *Advances in Kernel Methods*, pp. 185–208. MIT Press, Cambridge, MA, 1999.
- [90] B. T. Polyak and A. B. Juditsky. Acceleration of stochastic approximation by averaging. *SIAM Journal on Control and Optimization*, 30(4):838–855, 1992.

- [91] W. M. Rand. Objective criteria for the evaluation of clustering methods. *Journal of the American Statistical Association*, 66(336):846–850, 1971.
- [92] C. E. Rasmussen. Gaussian processes in machine learning. In *Advanced lectures on machine learning*, pp. 63–71. Springer, New York, NY, 2004.
- [93] S. J. Reddi, A. Hefny, S. Sra, B. Póczos, and A. Smola. On variance reduction in stochastic gradient descent and its asynchronous variants. In *Advances in Neural Information Processing Systems 28*, pp. 2647–2655, Montreal, Canada, 2015.
- [94] L. Reyzin and R. E. Schapire. How boosting the margin can also boost classifier complexity. In *Proceedings of 23rd International Conference on Machine Learning*, pp. 753–760, Pittsburgh, PA, 2006.
- [95] G. Saon, G. Kurata, T. Sercu, K. Audhkhasi, and S. Thomas. English conversational telephone speech recognition by humans and machines. In *Proceedings of the 18th Annual Conference of the International Speech Communication Association*, pp. 20–24, Stockholm, Sweden, 2017.
- [96] R. E. Schapire. The strength of weak learnability. *Machine Learning*, 5(2): 197–227, 1990.
- [97] R. E. Schapire, Y. Freund, P. Barlett, and W. S. Lee. Boosting the margin: A new explanation for the effectiveness of voting methods. In *Proceedings of the 14th International Conference on Machine Learning*, pp. 322–330, Nashville, TN, 1997.
- [98] B. Schölkopf and A. J. Smola. *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT Press, Cambridge, MA, 2001.
- [99] B. Schölkopf, A. Smola, and K.-R. Müller. Nonlinear component analysis as a kernel eigenvalue problem. *Neural Computation*, 10(5):1299–1319, 1998.
- [100] S. Shalev-Shwartz and S. Ben-David. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, Cambridge, UK, 2014.

- [101] S. Shalev-Shwartz, Y. Singer, and N. Srebro. Pegasos: Primal estimated sub-gradient solver for svm. In *Proceedings of the 24th International Conference on Machine Learning*, pp. 807–814, Helsinki, Finland, 2007.
- [102] O. Shamir and T. Zhang. Stochastic gradient descent for non-smooth optimization: Convergence results and optimal averaging schemes. In *Proceedings of the 30th International Conference on Machine Learning*, pp. 71–79, Atlanta, GA, 2013.
- [103] J. Shawe-Taylor and N. Cristianini. *Kernel methods for pattern analysis*. Cambridge University Press, Cambridge, UK, 2004.
- [104] J. Shi and J. Malik. Normalized cuts and image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(8):888–905, 2000.
- [105] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, and D. Hassabis. Mastering the game of go with deep neural networks and tree search. *Nature*, 529:484–489, 2016.
- [106] D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton, Y. Chen, T. Lillicrap, F. Hui, L. Sifre, G. Driessche, T. Graepel, and D. Hassabis. Mastering the game of go without human knowledge. *Nature*, 550:354–359, 2017.
- [107] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations*, 2015.
- [108] M. Sion. On general minimax theorems. *Pacific Journal of Mathematics*, 8(1): 171–176, 1958.
- [109] A. J. Smola and B. Schölkopf. A tutorial on support vector regression. *Statistics and Computing*, 14(3):199–222, 2004.
- [110] I. Steinwart and P. Thomann. liquidsvm: A fast and versatile svm package. *CoRR*, abs/1702.06899, 2017.

- [111] S. Suzumura, K. Ogawa, M. Sugiyama, and I. Takeuchi. Outlier path: A homotopy algorithm for robust svm. In *Proceedings of the 31st International Conference on Machine Learning*, pp. 1098–1106, Beijing, China, 2014.
- [112] M. Takáč, A. Bijral, P. Richtárik, and N. Srebro. Mini-batch primal and dual methods for svms. In *Proceedings of the 30th International Conference on Machine Learning*, pp. 1022–1030, Atlanta, GA, 2013.
- [113] P. Thomann, I. Blaschzyk, M. Meister, and I. Steinwart. Spatial decompositions for large scale svms. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, pp. 1329–1337, Fort Lauderdale, FL, 2017.
- [114] R. Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society*, pp. 267–288, 1996.
- [115] P. Tseng. Convergence of a block coordinate descent method for nondifferentiable minimization. *Journal of Optimization Theory and Applications*, 109(3): 475–494, 2001.
- [116] I. Tsochantaridis, T. Hofmann, T. Joachims, and Y. Altun. Support vector machine learning for interdependent and structured output spaces. In *Proceedings of the 21st International Conference on Machine Learning*, pp. 85–104, Banff, Canada, 2004.
- [117] H. G. K. Ulrich. Pairwise classification and support vector machines. In *Advances in Kernel Methods: Support Vector Machines*, pp. 255–268. MIT Press, Cambridge, MA, 1998.
- [118] L. G. Valiant. A theory of the learnable. *Communications of the ACM*, 27(11): 1134–1142, 1984.
- [119] H. Valizadegan and R. Jin. Generalized maximum margin clustering and unsupervised kernel learning. In *Advances in Neural Information Processing Systems 19*, pp. 1417–1424, Vancouver, Canada, 2006.
- [120] V. N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, New York, NY, 1995.

-
- [121] V. N. Vapnik. *Statistical learning theory*. Wiley-Interscience, Hoboken, NJ, 1998.
- [122] V. N. Vapnik. An overview of statistical learning theory. *IEEE Transactions on Neural Networks*, 10(5):988–999, 1999.
- [123] V. Vijaya Saradhi and P. Charly Abraham. Incremental maximum margin clustering. *Pattern Analysis and Applications*, 19(4):1057–1067, 2016.
- [124] F. Wang, B. Zhao, and C. Zhang. Linear time maximum margin clustering. *IEEE Transactions on Neural Networks*, 21(2):319–332, 2010.
- [125] L. Wang, M. Sugiyama, Z. Jing, C. Yang, Z.-H. Zhou, and J. Feng. A refined margin analysis for boosting algorithms via equilibrium margin. *Journal of Machine Learning Research*, 12:1835–1863, 2011.
- [126] J. Weston and C. Watkins. Multi-class support vector machines. In *Proceedings of the European Symposium on Artificial Neural Networks*, Brussels, Belgium, 1999.
- [127] S. Wold, K. Esbensen, and P. Geladi. Principal component analysis. *Chemometrics and Intelligent Laboratory Systems*, 2(1-3):37–52, 1987.
- [128] W. Xiong, J. Droppo, X. Huang, F. Seide, M. L. Seltzer, A. Stolcke, D. Yu, and G. Zweig. Toward human parity in conversational speech recognition. *IEEE/ACM Transactions on Audio, Speech and Language Processing*, 25(12):2410–2423, 2017.
- [129] W. Xiong, L. Wu, F. Alleva, J. Droppo, X. Huang, and A. Stolcke. The microsoft 2017 conversational speech recognition system. In *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing*, pp. 5934–5938, Calgary, Canada, 2018.
- [130] J. Xu, X. Liu, Z. Huo, C. Deng, F. Nie, and H. Huang. Multi-class support vector machine via maximizing multi-class margins. In *Proceedings of the 26th International Joint Conference on Artificial Intelligence*, pp. 3154–3160, Melbourne, Australia, 2017.

- [131] L. Xu, J. Neufeld, B. Larson, and D. Schuurmans. Maximum margin clustering. In *Advances in Neural Information Processing Systems 17*, pp. 1537–1544, Vancouver, Canada, 2004.
- [132] R. Xu and D. Wunsch, II. Survey of clustering algorithms. *IEEE Transactions on Neural Networks*, 16(3):645–678, 2005.
- [133] G. X. Yuan, C. H. Ho, and C.-J. Lin. Recent advances of large-scale linear classification. *Proceedings of the IEEE*, 100(9):2584–2603, 2012.
- [134] K. Zhang, I. W. Tsang, and J. T. Kwok. Maximum margin clustering made practical. In *Proceedings of the 24th International Conference on Machine Learning*, pp. 1119–1126, Corvalis, OR, 2007.
- [135] K. Zhang, I. W. Tsang, and J. T. Kwok. Maximum margin clustering made practical. *IEEE Transactions on Neural Networks*, 20(4):583–596, 2009.
- [136] M.-L. Zhang and Z.-H. Zhou. Ml-knn: A lazy learning approach to multi-label learning. *Pattern Recognition*, 40(7):2038–2048, 2007.
- [137] M.-L. Zhang and Z.-H. Zhou. A review on multi-label learning algorithms. *IEEE Transactions on Knowledge and Data Engineering*, 26(8):1819 – 1837, 2014.
- [138] T. Zhang. Solving large scale linear prediction problems using stochastic gradient descent algorithms. In *Proceedings of the 21st International Conference on Machine Learning*, pp. 116–123, Banff, Canada, 2004.
- [139] T. Zhang and Z.-H. Zhou. Large margin distribution machine. In *Proceedings of the 20th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 313–322, New York, NY, 2014.
- [140] T. Zhang and Z.-H. Zhou. Optimal margin distribution machine. *CoRR*, abs/1604.03348, 2016.
- [141] W. Zhang, B. Hong, W. Liu, J. Ye, D. Cai, X. He, and J. Wang. Scaling up sparse support vector machines by simultaneous feature and sample reduction. In *Proceedings of the 34th International Conference on Machine Learning*, pp. 4016–4025, Sydney, Australia, 2017.

- [142] B. Zhao, F. Wang, and C. Zhang. Efficient maximum margin clustering via cutting plane algorithm. In *Proceedings of the 2008 SIAM International Conference on Data Mining*, pp. 751–762, Atlanta, GA, 2008.
- [143] P. Zhao and T. Zhang. Stochastic optimization with importance sampling for regularized loss minimization. In *Proceedings of the 32nd International Conference on Machine Learning*, pp. 1–9, Lille, France, 2015.
- [144] G.-T. Zhou, T. Lan, A. Vahdat, and G. Mori. Latent maximum margin clustering. In *Advances in Neural Information Processing Systems 26*, pp. 28–36, Lake Tahoe, NV, 2013.
- [145] Y. Zhou, R. Jin, and S. C.-H. Hoi. Exclusive lasso for multi-task feature selection. In *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics*, pp. 988–995, Chia Laguna Resort, Italy, 2010.
- [146] Z.-H. Zhou. *Ensemble Methods: Foundations and Algorithms*. CRC Press, Boca Raton, FL, 2012.
- [147] Z.-H. Zhou. Large margin distribution learning. In *Proceedings of the 6th IAPR International Workshop on Artificial Neural Networks in Pattern Recognition*, pp. 1–11, Montreal, Canada, 2014.
- [148] Z.-H. Zhou and M. Li. Tri-training: Exploiting unlabeled data using three classifiers. *IEEE Transactions on Knowledge and Data Engineering*, 17(11):1529–1541, 2005.
- [149] Z.-H. Zhou and J.-M. Xu. On the relation between multi-instance learning and semi-supervised learning. In *Proceedings of the 24th International Conference on Machine Learning*, pp. 1167–1174, Corvalis, OR, 2007.
- [150] Z.-H. Zhou and M.-L. Zhang. Multi-instance multi-label learning with application to scene classification. In *Advances in Neural Information Processing Systems 19*, pp. 1609–1616, Vancouver, Canada, 2006.
- [151] Z.-H. Zhou, Y.-Y. Sun, and Y.-F. Li. Multi-instance learning by treating instances as non-i.i.d. samples. In *Proceedings of the 26th International Conference on Machine Learning*, pp. 1249–1256, Montreal, Canada, 2009.

- [152] Z.-H. Zhou, M.-L. Zhang, S.-J. Huang, and Y.-F. Li. Multi-instance multi-label learning. *Artificial Intelligence*, 176(1):2291–2320, 2012.
- [153] X. Zhu, Z. Ghahramani, and J. Lafferty. Semi-supervised learning using gaussian fields and harmonic functions. In *Proceedings of the 20th International Conference on Machine Learning*, pp. 912–919, Washington, DC, 2003.
- [154] Y. Zhu, K. M. Ting, and Z.-H. Zhou. Multi-label learning with emerging new labels. *IEEE Transactions on Knowledge and Data Engineering*, 30(10):1901–1914, 2018.
- [155] H. Zou and T. Hastie. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society*, 67(2):301–320, 2005.
- [156] 周志华. 机器学习与数据挖掘. 中国计算机学会通讯, 3(12):35–44, 2007.
- [157] 周志华. 基于分歧的半监督学习. 自动化学报, 39(11):1871–1878, 2013.
- [158] 周志华. 机器学习. 清华大学出版社, 北京, 中国, 2016.
- [159] 邓乃扬 与 田英杰. 支持向量机: 理论、算法与拓展. 科学出版社, 北京, 中国, 2009.
- [160] 陆汝铃. 人工智能. 科学出版社, 北京, 中国, 1996.

致 谢

时光飞逝，转眼在南大已经第 13 个年头了。在这里，我从一个懵懂的高中毕业生直至而立，完成了一个从学生到研究者的过渡；虽然这个过程中不乏孤独和泪水，但也点缀着许多温暖和欢笑。从 2010 年开始读研，以及 2012 年转为博士生之后，我得到过很多人的帮助和鼓励，在此深深地感谢他们。

首先由衷感谢我的导师周志华老师。回想起从 10 年进组到现在，关于周老师的点点滴滴浮上心头。周老师对专业领域的深刻洞察和见解，常常令我折服，经常几句简单的点拨，就可以解开萦绕我心头许久的困惑；而面对这个纷扰的社会，周老师对学术理想的坚持，也使我敬佩不已。在平常学术讨论中，周老师会指导我们如何看待问题，培养自己的学术品味；在写文章的时候，周老师会熬夜为我们逐字逐句地润色修改，而且还授人以渔，告诉我们为何要这样改；而在平时的活动中，周老师也会主动融入到我们之间，对于科研之外知识的理解也非常独到新奇。我在攻读学位期间的每一点进步都离不开周老师的指导和帮助，在此衷心地感谢周老师。

其次要感谢对我颇为照顾的刘胥影师姐和李宇峰师兄。我的本科毕设就是在刘胥影师姐的指导下完成的，那时的我是个啥也不懂的毛头小子，连文章该怎么读都不知道，全靠师姐手把手的教。李宇峰师兄则在我第一篇文章的完成中给予了许多帮助，帮我打磨初稿，教我写 rebuttal，此外师兄还是我学习优化知识的领路人，帮我后来独自应对解决优化问题打下了基础。

感谢 LAMDA 实验室的师兄师姐和师弟师妹们。在 LAMDA 实验室，很多师兄都给过我学术上的帮助和指导。首先要感谢高尉师兄，在我接触间隔理论这个领域时，给过我很多启示和帮助；感谢钱超师兄，和师兄一起在伯明翰访学期间，教了我许多访问其他研究组要注意的东西，还有师兄每天不辞辛苦地做饭，让我在异国他乡还能吃上中餐；感谢詹德川师兄、俞扬师兄、王魏师兄在科研和科研外的各种事物工作上给过我的帮助。也要感谢实验室的师兄弟们在生活上和学习上也给我各种关心照顾，特别要感谢戴望州，我们同届同寝室，兴趣相近，几乎无话不谈，就像兄弟一样知心；还有丁尧相、赵鹏两位师弟，我很喜欢我们几个“伪数学爱好者”一起交流技术的氛围。

最后要感谢我的父母，让我能够没有后顾之忧，从容地读了这么久的博士。我能感受到你们心中的焦急，但是也只好不动声色。现在终于可以毕业了，感谢你们！

附录 A 攻读博士学位期间的学术成果和获奖情况

一、攻读博士学位期间撰写的主要论文

第一作者论文

1. T. Zhang and Z.-H. Zhou. Large margin distribution machine. In: **Proceedings of the 20th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD'14)**, New York, NY, 2014, pp.313-322. (CCF A 类会议)
2. T. Zhang and Z.-H. Zhou. Multi-class optimal margin distribution machine. In: **Proceedings of the 34th International Conference on Machine Learning (ICML'17)**, Sydney, Australia, 2017, pp.4063-4071. (CCF A 类会议)
3. T. Zhang and Z.-H. Zhou. Optimal margin distribution clustering. In: **Proceedings of the 32nd AAAI Conference on Artificial Intelligence (AAAI'18)**, New Orleans, LA, 2018, pp.4474-4481. (CCF A 类会议)
4. T. Zhang and Z.-H. Zhou. Semi-supervised optimal margin distribution machines. In: **Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI'18)**, Stockholm, Sweden, 2018, pp.3104-3110. (CCF A 类会议)
5. T. Zhang and Z.-H. Zhou. Optimal Margin Distribution Machine. **IEEE Transactions on Knowledge and Data Engineering (TKDE)**, in press. (CCF A 类期刊)

第二作者论文

1. Z.-H. Tan, T. Zhang and W. Wang. Coreset Stochastic Variance-Reduced Gradient with Application to Optimal Margin Distribution Machine. In: **Proceedings of the 33th AAAI Conference on Artificial Intelligence (AAAI'19)**, Honolulu, HI, 2019. (CCF A 类会议)

二、攻读博士学位期间获得的主要奖励

1. 博士研究生国家奖学金，2014 年
2. 南京大学博士研究生创新能力提升计划，2014 年，2017 年
3. 南京大学博士研究生创新能力提升计划被评为“优秀”，2018 年
4. 南京大学博士生国际学术会议奖励计划，2018 年
5. ICML 学生旅行奖，2017 年
6. AAAI 学生旅行奖，2018 年

三、攻读博士学位期间参加的主要科研项目

1. 国家自然科学基金重点项目“开放动态环境下的在线机器学习理论与方法”(61333014)
2. 国家自然科学基金重点项目“新型深度学习模型与方法的研究”(61751306)
3. 国家重点基础研究发展计划课题“大数据分析的基础理论和技术方法”(2018YFB1004300)